

Лабораторная работа №2. Кластеризация клиентов интернет-магазина

Цель:

Освоить методы k-means и агломеративной кластеризации на большом реальном датасете транзакций; научиться применять RFM-анализ для сегментации клиентов; определять оптимальное число кластеров с помощью метода локтя и силуэтного анализа; интерпретировать кластеры как бизнес-сегменты.

Датасет: Online Retail по покупкам в интернет-магазине, локализованном в регионе с индексом 1, пользователями из 39 регионов - 541 909 транзакций, 4 372 клиента, по ссылке <https://docs.google.com/spreadsheets/d/1liM0yHn0kFEBJppNjbipf87wFKeSLvnx/edit?usp=sharing&ouid=114596079979601215791&rtpof=true&sd=true>.

Задача (Бизнес-контекст) - сегментировать клиентов по их покупательскому поведению, чтобы отдел маркетинга мог запускать таргетированные кампании: удерживать «ценных», реактивировать «спящих», стимулировать «новичков».

Признаки (8 штук):

Признак	Описание
InvoiceNo	Номер счёта (6 цифр, уникальный для каждой транзакции)
StockCode	Код товара (5 цифр)
Description	Название товара
Quantity	Количество единиц товара в транзакции
InvoiceDate	Дата и время выставления счёта
UnitPrice	Цена за единицу товара
CustomerID	Идентификатор клиента (5 цифр)
Region	Код региона проживания клиента

Важно. Целевой переменной нет - это задача обучения без учителя. Есть скрытая бизнес-истина: клиентов можно разделить на осмысленные сегменты (VIP, постоянные, новые, потерянные), и нужно проверять, насколько кластеры совпадают с этой интуицией.

Задания

Задание 1. Загрузка и EDA

1. Загрузите датасет.

2. Проверьте пропуски (`df.isna().sum()`). Обратите внимание:

- **CustomerID** содержит пропуски (~135 тыс. записей) - это гостевые покупки, их нужно удалить, потому что кластеризуем именно клиентов.

- **Quantity** и **UnitPrice** могут быть отрицательными - это возвраты и корректировки, их тоже нужно обработать (удалить или вынести отдельно).

3. Постройте распределения **Quantity**, **UnitPrice**, **TotalPrice** = **Quantity** * **UnitPrice**. Что видно? Есть ли выбросы?

4. Постройте топ-10 регионов по числу транзакций. Какой регион доминирует?

5. Постройте график продаж по месяцам. Есть ли сезонность (пик вблизи какой-то даты)?

Очистка данных:

- удалите строки с пропуском CustomerID;
- удалите строки, где Quantity ≤ 0 или UnitPrice ≤ 0 ;
- создайте признак TotalPrice = Quantity * UnitPrice.

Подсказка. Это классический этап data cleaning в IT-проектах. В реальном продакшне грязные данные - норма, а не исключение.

Задание 2. RFM-анализ (Recency, Frequency, Monetary)

RFM - это стандартная методика сегментации клиентов в e-commerce и CRM-системах. Для каждого клиента считаем три метрики:

- Recency - сколько дней прошло с момента последней покупки клиента до «сегодня» (последней даты в датасете);
- Frequency - сколько разных счетов (InvoiceNo) у клиента;
- Monetary - суммарная стоимость всех покупок клиента.

- 1.Сформируйте таблицу rfm размером 4 372 x 3 (по одному клиенту в строке).
- 2.Примените StandardScaler к RFM - это обязательно, потому что Monetary может достигать десятков тысяч, а Frequency - единиц.
- 3.Постройте pairplot для RFM-признаков. Сколько сгустков видно «на глаз»? Какие признаки сильнее всего разделяют клиентов?

Подсказка. RFM - это feature engineering: из «сырых» транзакций мы получаем осмысленные бизнес-признаки. Именно так работают аналитики в Ozon, Wildberries, Amazon.

Задание 3. Определение оптимального числа кластеров

Метод локтя.

- 1.Для k из интервала от 2 до 10 обучите KMeans на RFM-признаках.
- 2.Сохраните inertia_.
- 3.Постройте график « k vs инерция». Определите «локоть».

Силуэтный анализ.

- 1.Для тех же k вычислите silhouette_score.
- 2.Постройте график « k vs silhouette».
- 3.Определите k , при котором silhouette максимален.

Сравнение двух методов.

- 1.Совпадают ли выводы?
- 2.Обратите внимание: на RFM-данных силуэт часто даёт $k=2$, а метод локтя - от $k=3$ до $k=5$. Почему?
- 3.Какое k вы выберете для дальнейшего анализа? Обоснуйте и метрикой, и бизнес-логикой.

Подсказка. Силуэт «предпочитает» 2 кластера, потому что RFM-облако часто имеет сильную асимметрию: 90% клиентов - «мелкие», 10% - «крупные». Силуэт наказывает за дробление маленького, но плотного кластера. Бизнесу же нужно минимум 3–4 сегмента: VIP, постоянные, новые/спящие.

Задание 4. KMeans при $k = 2, 3, 4, 5$

- 1.Обучите KMeans для значений k (2, 3, 4, 5).

2. Для каждого варианта:

- получите метки кластеров;
- вычислите silhouette;
- постройте pairplot RFM-признаков с раскраской по кластерам.

3. Постройте silhouette plot для всех вариантов k рядом. Обратите внимание:

- Где средний силуэт выше?
- Есть ли точки с отрицательным силуэтом?
- Насколько «ровные мечи» у кластеров?

4. Для каждого k постройте профиль кластеров: средние значения Recency, Frequency, Monetary по кластерам сведите в таблицу.

5. Ответьте:

- При каком k силуэт выше?
- При каком k кластеры интерпретируемы как бизнес-сегменты?
- Какая группа клиентов «перетягивает» силуэт вниз?

Задание 5. Агломеративная кластеризация

1. Обучите AgglomerativeClustering с теми же k и 4 вариантами linkage:

- 'ward' (по умолчанию);
- 'complete';
- 'average';
- 'single'.

2. Для каждого варианта вычислите silhouette и сведите в таблицу.

3. Постройте дендрограмму для лучшего linkage:

```
from scipy.cluster.hierarchy import dendrogram, linkage
Z = linkage(rfm_scaled, method='ward')
plt.figure(figsize=(14, 7))
dendrogram(Z, truncate_mode='lastp', p=30, leaf_rotation=90)
plt.axhline(y=..., color='r', linestyle='--')
plt.show()
```

4. Ответьте:

- На какой высоте дендрограмма разрезается на 3 и 4 кластера?
- Какой linkage дал лучший silhouette?
- Совпадает ли результат с KMeans?

Задание 6. Итоговое сравнение и бизнес-интерпретация

Сведите результаты в таблицу:

Алгоритм	k	Silhouette	Комментарий
KMeans	2		
KMeans	3		
KMeans	4		
KMeans	5		
Agglomerative (ward)	3		
Agglomerative (лучший linkage)	3		

1. Постройте bar chart сравнения silhouette.
2. Для лучшего варианта (от $k=3$ до $k=5$) сформулируйте бизнес-портрет каждого кластера:
Например: Кластер 0: Recency = 12 дней, Frequency = 25, Monetary = 900000 -> это VIP-клиенты, покупают часто и много, недавно делали заказ.
Кластер 1: Recency = ... дней, Frequency = ..., Monetary = ... -> это потерянные клиенты, давно не покупали.
3. Предложите для каждого сегмента маркетинговую стратегию, например:
 - VIP -> программа лояльности, персональные скидки;
 - Потерянные -> реактивационная рассылка;
 - Новые -> welcome-серия писем.
4. Ответьте на вопросы:
 - Какой алгоритм и какое k вы рекомендуете использовать на практике?
 - Какие признаки сильнее всего различают кластеры?
 - Главный методический вывод: метрики кластеризации - лишь подсказки. Финальный выбор k должен опираться на бизнес-логику.

Требования к отчёту

- Jupyter Notebook с кодом и письменными выводами после каждого задания.
- Все графики подписаны, оси названы.
- Итоговый раздел «Выводы»:
 - Какой метод кластеризации лучше подошёл и почему?
 - Совпали ли кластеры с интуитивными бизнес-сегментами?
 - Какие RFM-признаки оказались самыми «разделяющими»?
 - Какие ограничения у методов на транзакционных данных?

Подсказки по коду

RFM-анализ:

```
rfm = df.groupby('CustomerID').agg({  
    'InvoiceDate': lambda x: (snapshot_date - x.max()).days, # Recency  
    'InvoiceNo': 'nunique', # Frequency  
    'TotalPrice': 'sum', # Monetary  
}).rename(columns={  
    'InvoiceDate': 'Recency',  
    'InvoiceNo': 'Frequency',  
    'TotalPrice': 'Monetary'  
})
```

```
print(rfm.describe())
```

Масштабирование:

```
from sklearn.preprocessing import StandardScaler  
scaler = StandardScaler()  
rfm_scaled = scaler.fit_transform(rfm)
```

Метод локтя и silhouette:

```
from sklearn.cluster import KMeans  
from sklearn.metrics import silhouette_score
```

```

k_range = range(2, 11)
inertias, silhouettes = [], []
for k in k_range:
    km = KMeans(n_clusters=k, random_state=42, n_init=10)
    labels = km.fit_predict(rfm_scaled)
    inertias.append(km.inertia_)
    silhouettes.append(silhouette_score(rfm_scaled, labels))

```

```

fig, axes = plt.subplots(1, 2, figsize=(14, 5))
axes[0].plot(k_range, inertias, marker='o')
axes[0].set_title('Метод локтя'); axes[0].set_xlabel('k')

axes[1].plot(k_range, silhouettes, marker='o', color='green')
axes[1].set_title('Силуэтный анализ'); axes[1].set_xlabel('k')
plt.tight_layout(); plt.show()

```

Профиль кластеров:

```

rfm['Cluster'] = labels_km4
profile = rfm.groupby('Cluster').agg({
    'Recency': 'mean',
    'Frequency': 'mean',
    'Monetary': ['mean', 'median', 'count']
}).round(1)
profile

```

Дендрограмма:

```

from scipy.cluster.hierarchy import dendrogram, linkage
Z = linkage(rfm_scaled, method='ward')

plt.figure(figsize=(14, 7))
dendrogram(Z, truncate_mode='lastp', p=30, leaf_rotation=90)
plt.axhline(y=..., color='red', linestyle='--', label='Разрез для k=3')
plt.title('Дендрограмма (ward linkage)')
plt.legend(); plt.tight_layout(); plt.show()

```