

Машинное обучение. Кластерный анализ



1. Задача кластеризации
2. Методы кластеризации
3. Алгоритм k-средних
4. Иерархическая кластеризация
5. Другие методы

Задача кластеризации

Задача кластеризации

- Обучение без учителя. В этом случае нет “учителя” и “обучающая выборка” состоит только из объектов, т.е. Y отсутствует.

Задача кластеризации

- Обучение без учителя. В этом случае нет “учителя” и “обучающая выборка” состоит только из объектов, т.е. Y отсутствует.
- Кластер можно охарактеризовать как группу объектов, имеющих общие свойства.

Задача кластеризации

- Обучение без учителя. В этом случае нет “учителя” и “обучающая выборка” состоит только из объектов, т.е. Y отсутствует.
- Кластер можно охарактеризовать как группу объектов, имеющих общие свойства.
- Задача: сгруппировать объекты по “похожести” так, чтобы: объекты внутри одной группы были более похожи друг на друга, чем на объекты из любой другой группы.

Задача кластеризации

- Обучение без учителя. В этом случае нет “учителя” и “обучающая выборка” состоит только из объектов, т.е. Y отсутствует.
- Кластер можно охарактеризовать как группу объектов, имеющих общие свойства.
- Задача: сгруппировать объекты по “похожести” так, чтобы: объекты внутри одной группы были более похожи друг на друга, чем на объекты из любой другой группы.
- Количество групп может как задаваться изначально, так и определяться по ходу дела.
- Под группировкой имеется в виду приписать каждому объекту номер кластера.

Задача кластеризации

Каждый объект характеризуется набором (вектором) признаков (свойств, атрибутов, features).

Вектор $(f_1, f_2, \dots, f_n)$ - признаковое описание объекта f .

Задача кластеризации

Каждый объект характеризуется набором (вектором) признаков (свойств, атрибутов, features).

Вектор $(f_1, f_2, \dots, f_n)$ - признаковое описание объекта f .

Типы признаков:


- $\{0, 1\}$ - бинарный признак;
- $\{1, 2, 3, \dots, s\}$ номинальный (номинативный, категориальный, фактор) признак (красный, зеленый, синий);
- упорядочено - порядковый признак, например, доход (малый, средний, большой), оценка по 5-балльной шкале;
- количественный признак (масса тела, зарплата).

Задача кластеризации

- Похожесть или близость объектов обычно определяется через расстояние в многомерном пространстве признаков.
- Надо определить само пространство (что учитываем) и метрику близости (как именно считаем близость).
- Обычно это точки в евклидовом многомерном пространстве (или в неевклидовом).
- Функция расстояния – Евклидово, косинусное, Жаккардово, Левенштейна, Хэмминга.
- Результат трудно визуализировать, если число измерений больше четырёх
- Результат можно использовать для других методов (например, классификации и регрессии) как новый признак.

Задача кластеризации

- Жесткая и мягкая кластеризация.



Примеры приложений:

- Сегментация пользователей интернет-магазинов по схожести (половозрастной состав, доход и т.д) с целью таргетирования показа рекламы.
- Поиск тесно связанных между собой пользователей соцсетей.
- Определение оптимального местоположения базовых станций сотовой сети.
- Автоматическая сегментация новостей
- Кластеризация результатов поисковой выдачи.

Методы кластеризации

Две разные стратегии:

- Плоская
- Иерархическая (восходящая и нисходящая)

Плоская стратегия

- Определяются первоначальные кластеры
- Точки рассматриваются по очереди и приписываются какому-то кластеру
- Если результат достаточно хорош, итерации останавливаются
- В процессе кластеры могут объединяться или распадаться, а точки терять прописку

Иерархическая стратегия

- Сначала каждая точка – один кластер
- На итерации «ближайшие» кластеры объединяются
- Итерации останавливаются при достижении какого-то критерия
- В нисходящей стратегии все наоборот, начинается с одного большого кластера, включающего все точки

Алгоритм k-средних

Алгоритм k-средних



Схема <https://www.naftaliharris.com/blog/visualizing-k-means-clustering/>

1. Выбрать k точек, находящиеся, вероятно, в разных кластерах и объявить их центроидами.
2. Итерация: для каждой точки найти ближайший центроид и отнести её к соответствующему кластеру.
3. Пересчитать центроиды и если требуется, сделать следующую итерацию.
4. Если ни одна точка не переехала в другой кластер, то уже наверное хватит.

Выбор начальных центроидов


- Случайный, как можно дальше друг от друга, выброс может все испортить
- Случайный с выкидыванием отщепенцев
- Предварительная иерархическая кластеризация и центроиды получившихся кластеров в качестве первоначальных для k-means.
- можно проводить над небольшой случайной выборкой из исходных точек
- Несколько разных наборов начальных центроидов и выбор показавшего лучший результат.

Выбор k


- Если число кластеров неизвестно априорно, то можно перебрать разные k
- Если поставить цель минимизировать общую внутригрупповую сумму квадратов расстояний от центроидов WWS , то лучшее $k = N$
- Можно рассмотреть кривую уменьшения WWS в зависимости от увеличения k , и брать k , соответствующий точкам изгиба.

$$WSS = \sum_{i=1}^k \sum_{j=1}^{n_i} |x_{ij} - c_i|^2$$

Выбор k



Выбор $k = 3$



Плюсы, минусы, подводные камни

- Невысокая сложность
- Простое распараллеливание
- Хорошие результаты для «хороших» данных
- Но не все данные одинаково хороши

Иерархическая кластеризация

Методы иерархической кластеризации основываются на двух идеях:

- агломерации (AGNES, Agglomerative Nesting), т.е. последовательного объединения индивидуальных объектов или их групп во все более крупные подмножества,
- или обратном по смыслу процессе разбиения (DIANA, Divide Analysis), который начинается с корня и на каждом шаге делит образующие группы по степени их гетерогенности (Ким и др., 1989; Kassambara, 2017).

В обоих случаях результат работы алгоритма представляет собой древовидную структуру, или дендрограмму.



Отдельные версии агломеративной иерархической процедур отличаются правилами вычисления расстояния между кластерами. Например, алгоритм средней связи (average linkage clustering) на каждом следующем шаге объединяет два ближайших кластера, рассчитывая среднюю арифметическую дистанцию между всеми парами объектов.

К алгоритму средней связи естественно сразу добавить еще два со взаимно противоположными тенденциями:



алгоритм одиночной связи, или "ближайшего соседа" (single linkage clustering), когда расстояние между кластерами оценивается как минимальное из дистанций между парами объектов, один из которых входит в первый кластер, а другой – во второй;

и алгоритм полной связи или "дальнего соседа" (complete linkage clustering), когда вычисляется расстояние между наиболее удаленными объектами.



Иерархическая кластеризация



Иерархическая кластеризация





Иерархическая кластеризация



Иерархическая кластеризация

Плюсы, минусы, подводные камни


- Может (иногда) находить кластеры причудливой формы
- N^2 первоначальных сравнений и еще порядка N шагов $\Rightarrow$ $N^3 \Rightarrow$ для большого количества точек подходит плохо.



Оценка качества кластеризации

Метрика силуэта (Silhouette score) используется для оценки качества кластеризации. Она показывает, насколько хорошо каждый объект совпадает со своим кластером по сравнению с другими кластерами.

Silhouette Score for Clustering Evaluation



Оценка качества кластеризации

Для каждого объекта вычисляются два значения:


a : среднее расстояние до всех других объектов в своем кластере

b : минимальное среднее расстояние до всех объектов другого кластера (т.е. ближайшего "чужого" кластера)

Силуэт объекта:

$$s = \frac{b - a}{\max(a, b)}$$

s принимает значения от -1 до 1.



s ближе к 1 — объект хорошо соответствует своему кластеру, и далёк от других.

Близко к 0 — объект находится на границе между двумя кластерами.

Отрицательное значение — объект ошибочно попал в кластер.

Зачем используют силуэт:

- Для выбора наилучшего количества кластеров (например, в K-Means).
- Для оценки, насколько хорошо разбиты данные на группы.
- Для визуализации распределения внутри кластеров.

Практика:

- Обычно для всей выборки считают средний силуэт — чем он выше (ближе к 1), тем лучше проведена кластеризация.

Другие методы

- C-means, K-means++.
- Кластеризация на основе распределений (ЕМ-алгоритм).
- Кластеризация на основе плотности (DBSCAN): группирует вместе “плотные” участки. Может находить кластеры очень сложной формы. Проблемы при кластеризации данных с сильно различающейся плотностью. Может быть трудно выбрать параметры для новых неизученных датасетов (а уже изученные кластеризовать неинтересно).
- Графовая и спектральная кластеризация.

Другие методы

