

Машинное обучение. Корреляционно-регрессионный анализ



1. Напоминание некоторых понятий математической статистики
2. Корреляция и коэффициенты корреляции
3. Линейная регрессия
4. Многомерная регрессия

Понятие распределения случайной величины и его основные параметры

- ожидаемое среднее значение случайной величины.
- *Математическое ожидание случайной величины A обозначается $M(A)$.*

$$M(A) = \lim_{N \rightarrow \infty} A_{\text{среднее}}$$

Математическое ожидание

- ожидаемое среднее значение случайной величины.
- Математическое ожидание случайной величины A обозначается $M(A)$.

$$M(A) = \lim_{N \rightarrow \infty} A_{\text{среднее}}$$

- Среднее значение случайной величины A

$$A_{\text{среднее}} = \frac{\text{Сумма всех возможных } A}{\text{Число всех возможных } A} = \frac{\sum_{k=1}^N A_k}{N}$$

Зачем нужна дисперсия?

Зачем нужна дисперсия?




Рис.: Две разных гистограммы

Дисперсия




Рис.: Две разных гистограммы

- У случайных величин на гистограммах одинаковые математические ожидания! Но величины обладают разными свойствами. Справа у случайной величины «разброс» значений меньше!

- количественный параметр для характеристики разброса значений случайной величины, её отклонение от математического ожидания. Записывается дисперсия так:

$$D(A) = M((A - M(A))^2)$$

Полученные в процессе измерений случайные величины чаще всего имеют размерность. Более того, одну и ту же величину можно измерить в разных единицах (например, рост человека в **см** или **м**, массу в **г** или **кг**, дисперсия такой величины имеет размерность **кг²**, что не совпадает с размерностью самой случайной величины).

Среднеквадратичное отклонение – квадратный корень из дисперсии

$$\sigma = \sqrt{D(A)}$$

- Допустим, мы хотим открыть магазин по продаже женской обуви. И вот дошло дело до закупки продукции.
- Встает вопрос, сколько нужно купить пар обуви 35 размера? А 37-го? А 42-го? **Какого размера нужно купить больше, чтобы не прогореть?**

Понятие закона распределения


- Чтобы надежно ответить на эти вопросы, нужно представлять, каково распределение ступней по размерам. Оно то и будет определять спрос.



- Конечно, отдельно взятая посетительница магазина может иметь любой размер ноги. Но если посетительниц окажется много, то обнаружится кое-какая закономерность. Понятно, что очень большие размеры ступни, также, как и очень маленькие, встречаются гораздо реже средних. Попробуем это отразить в графической форме. Договоримся, что будем отмечать столбиком большей высоты размер ступни, который и попадаетея чаще.

Понятие закона распределения

Тогда получится что-нибудь такое:




Функция Гаусса

- самая известная функция распределения.

$$f(A) = \sqrt{\frac{1}{2\pi\sigma^2}} \exp -\frac{(A - A_{cp})^2}{2\sigma^2}$$

Очень многие случайные величины подчиняются этому закону, его даже называют «нормальный закон распределения».



Нормальное распределение с параметрами: $A_{cp}=38$, $\sigma^2=1$.

Корреляция и ее мера

- Иногда можно предположить, что между двумя величинами существует связь (причинно-следственная связь). Часто ее удается записать с использованием какой-нибудь функции. Тогда это функциональная связь.

- Иногда можно предположить, что между двумя величинами существует связь (причинно-следственная связь). Часто ее удается записать с использованием какой-нибудь функции. Тогда это функциональная связь.
- Например, Галилей установил, что расстояние h , которое пролетает падающее тело, зависит от времени t :

$$h(t) = \frac{gt^2}{2}, \quad g = 9,8 \text{ м/с}^2.$$

- В этом выражении никакой случайности нет – это строго определенная, или, как еще говорят, **детерминированная** связь.

- Но если мы имеем дело с реальными измерениями, то из-за различных случайных обстоятельств измеряемые величины становятся случайными.
- Пусть при каком-то фиксированном условии мы получаем несколько значений случайных величин.
- При повторном выполнении условия (испытании) указанные случайные величины могут иметь другие значения — поэтому эти величины и называют случайными.

Корреляция и ее мера



Корреляция и ее мера

- *Пример условия: пусть в ходе медосмотра измерялись масса и рост студента 1 курса. В результате отдельного осмотра мы получаем значение массы и роста.*
- *По итогам этого процесса, мы будем иметь дело с двумя совокупностями случайных величин.*

Номер измерения	Масса, кг	Рост, см
1	51	163
2	80	184
3	65	173
...	...	...
708	45	156

- Как математически установить, если связь между двумя случайными величинами X и Y ?
- Например, для приведенной таблицы X - совокупность значений роста, а Y - это совокупность значений масс. Зависит ли масса от роста?

- Как математически установить, если связь между двумя случайными величинами X и Y ?
- Например, для приведенной таблицы X - совокупность значений роста, а Y - это совокупность значений масс. Зависит ли масса от роста?
- Как математически установить, есть ли связь между массой и ростом? Если просто долго посмотреть на таблицу - никакого разумного вывода сделать не удастся. А если Вы и сделаете какой-нибудь вывод – он будет субъективным!

- Как математически установить, если связь между двумя случайными величинами X и Y ?
- Например, для приведенной таблицы X - совокупность значений роста, а Y - это совокупность значений масс. **Зависит ли масса от роста?**
- Как математически установить, есть ли связь между массой и ростом? Если просто долго посмотреть на таблицу - никакого разумного вывода сделать не удастся. А если Вы и сделаете какой-нибудь вывод – он будет субъективным!
- Попробуем следить за отклонениями от среднего и внесем в таблицу не сами случайные величины, а их **отклонения от их же среднего значения.**

Корреляция и ее мера

Номер измерения	Отклонения для Y	Отклонения для X
1	$Y_1 - Y_{\text{выб}}$	$X_1 - X_{\text{выб}}$
2	$Y_2 - Y_{\text{выб}}$	$X_2 - X_{\text{выб}}$
3	$Y_3 - Y_{\text{выб}}$	$X_3 - X_{\text{выб}}$
...	...	...
n	$Y_n - Y_{\text{выб}}$	$X_n - X_{\text{выб}}$

Здесь $Y_{\text{выб}}$ и $X_{\text{выб}}$ – выборочные средние значения случайных величин Y и X .

- А теперь сложим произведения всех столбцов и разделим на n .

- А теперь сложим произведения всех столбцов и разделим на n .
- Ну и что? И как же по этой сумме судить о взаимосвязанности случайных величин X и Y ?

- А теперь сложим произведения всех столбцов и разделим на n .
- Ну и что? И как же по этой сумме судить о взаимосвязанности случайных величин X и Y ?
- В каждой строке второго и третьего столбцов таблицы будут возникать числа – положительные или отрицательные.
- Если величины не связаны – это будет происходить случайно. Произведение этих чисел будет то положительным, то отрицательным. Сумма случайных (то положительных, то отрицательных) чисел близка к нулю.
- Если это так, то величины X и Y не связаны друг с другом.

- Если же величины X и Y взаимосвязаны, при увеличении X_i , как правило, увеличится и Y_i (и наоборот). Разности часто будут иметь одинаковые знаки. Произведение этих разностей будет очень часто положительным (минус на минус - тоже плюс!). Сумма случайных, но все время положительных чисел будет большой.
- Если это так, то величины X и Y связаны друг с другом.

- Если же величины X и Y взаимосвязаны, при увеличении X_i , как правило, увеличится и Y_i (и наоборот). Разности часто будут иметь одинаковые знаки. Произведение этих разностей будет очень часто положительным (минус на минус - тоже плюс!). Сумма случайных, но все время положительных чисел будет большой.
- Если это так, то величины X и Y связаны друг с другом.
- Лучше, конечно, в таблице указывать относительные разности – это решает проблему разной размерности величин X и Y .
- А еще относительные разности будут меньше единицы.

Корреляция и ее мера

Номер измерения	Относительные отклонения для Y	Относительные отклонения для X
1	$(Y_1 - Y_{\text{выб}}) / \sigma_Y$	$(X_1 - X_{\text{выб}}) / \sigma_X$
2	$(Y_2 - Y_{\text{выб}}) / \sigma_Y$	$(X_2 - X_{\text{выб}}) / \sigma_X$
3	$(Y_3 - Y_{\text{выб}}) / \sigma_Y$	$(X_3 - X_{\text{выб}}) / \sigma_X$
...	...	...
n	$(Y_n - Y_{\text{выб}}) / \sigma_Y$	$(X_n - X_{\text{выб}}) / \sigma_X$

Здесь σ_Y и σ_X – среднеквадратичные отклонения для величин Y и X .

- Математически сумму произведений строк таблицы, деленную на число этих строк, можно записать так (коэффициент корреляции Пирсона)

$$r = \frac{1}{n} \frac{\sum_{i=1}^n (X_i - X_{\text{выб}}) (Y_i - Y_{\text{выб}})}{\sigma_X \sigma_Y}.$$


- Если $r \rightarrow 0$ – то величины X и Y не взаимосвязаны.
- Если $|r| \rightarrow 1$ – то величины X и Y взаимосвязаны.

Корреляция и ее мера

- Если случайных величин не две, а, например, шесть, то можно искать взаимосвязь «каждой величины с каждой».
- Коэффициентов Пирсона теперь будет уже 15!
- Если их разместить в таблицу, то получится **корреляционная матрица**.

	A	B	C	D	E	F
A	1	-0,7	0,2	0,3	0,9	0,4
B		1	0,4	0,1	0,2	0,5
C			1	-0,2	-0,8	0,1
D				1	0,9	0,8
E					1	-0,1
F						1

Графическое представление корреляций



Диаграммы рассеяния (корреляционное облако).

<http://rpsychologist.com/d3/correlation/>

- Важно представлять, а не равен ли нулю коэффициент корреляции в генеральной совокупности, иначе говоря, выяснять его значимость.
- Для этого сравнивают с критической точкой распределения Стьюдента $t(n-2)$ результат оценки

$$T_{эмп} = r \sqrt{\frac{n-2}{1-r^2}},$$

Условия применимости:

- Характер взаимосвязи линейный и монотонный.
- Желательно, чтобы данные подчинялись нормальному распределению и не было выбросов.

- коэффициенты корреляции Спирмена или Кендалла применяются для выявления взаимосвязи между количественными или качественными показателями, если их можно ранжировать. Значения показателя X выставляют в порядке возрастания и присваивают им ранги. Ранжируют значения показателя Y и рассчитывают коэффициент корреляции Кендалла:

$$\tau = \frac{2 S}{n (n - 1)},$$

S - разность суммарных чисел наблюдений, следующих за текущими наблюдениями с большим и меньшим значением рангов Y .

- Коэффициент корреляции Спирмена показывает, как отличается полученная при наблюдении сумма квадратов разностей между рангами от случая отсутствия связи:

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)},$$

d_i - разность между рангами X и Y .

- Ошибка корреляции
- Третья переменная
- З а б а в н ы е к о р р е л я ц и и
https://pikabu.ru/story/lozhnyie_korrelyatsii_2287154

Линейная регрессия


- Пусть теперь установлено, что случайные величины связаны между собой.
- Очень хочется написать формулу для этой связи. Все ведь привыкли, что связь между величинами – это функция. Для формулы нужна **гипотеза** – предположение, какова примерно эта формула?

- Пусть теперь установлено, что случайные величины связаны между собой.
- Очень хочется написать формулу для этой связи. Все ведь привыкли, что связь между величинами – это функция. Для формулы нужна **гипотеза** – предположение, какова примерно эта формула?
- В практике очень часто выдвигают гипотезу, что связь случайных величин **линейная** (разумеется, могут быть и другие гипотезы, но мы остановимся на линейной)

$$y = b_0 + b_1x$$


- Коэффициенты **b_1** и **b_0** – постоянные. Обычно их находят **методом наименьших квадратов**.

Линейная регрессия





- https://gallery.shinyapps.io/slr_diag/

Остатки




Остатки






$$e_1 = Y_1 - \hat{Y}_1$$




$$e_1 = Y_1 - \hat{Y}_1$$

Остатки



$$e_1 = Y_1 - \hat{Y}_1$$

$$e_2 = Y_2 - \hat{Y}_2$$



$$e_1 = Y_1 - \hat{Y}_1$$

$$e_2 = Y_2 - \hat{Y}_2$$

$$e_i^2 \rightarrow \min$$

- Приведем результат вычислений без доказательства


$$b_1 = \frac{\sum_{i=1}^n X_i Y_i - \frac{\sum_{i=1}^n X_i \sum_{i=1}^n Y_i}{n}}{\sum_{i=1}^n X_i^2 - \frac{(\sum_{i=1}^n X_i)^2}{n}} = \frac{\sigma_Y}{\sigma_X} r$$

$$b_0 = y_{\text{сред}} - b_1 x_{\text{сред}}$$

Линейная регрессия

№	Рост, см	Размер обуви
1	162	37
2	175	45
3	160	35
4	162	38
5	173	41
6	172	37
7	178	43
8	186	43
9	163	35
10	180	40
11	195	50
12	167	41



Линейная регрессия



Используя значения $b_1=0,3538$ и $b_0 = - 20,703$, можно оценить размер обуви по росту. Так, при росте 160 см у человека прогнозируется 36 размер обуви.

Коэффициент детерминации

- R^2 - доля дисперсии зависимой переменной Y , объясняемая регрессионной моделью.



$$R^2 = 1 - \frac{e_i^2}{(Y_i - y_{\text{сред}})^2}$$

- Равен квадрату коэффициента корреляции.

Условия применимости

- Характер взаимосвязи линейный и монотонный.
- Желательно, чтобы данные подчинялись нормальному распределению и не было выбросов, а также чтобы и остатки были распределены нормально.
- Гомоскедастичность - постоянная изменчивость остатков на всем интервале значений независимой переменной.

(https://gallery.shinyapps.io/slr_diag/)

Многомерная линейная регрессия

- В этом случае независимых переменных - несколько.

$$y = b_0 + b_1x_1 + b_2x_2 + \dots + b_nx_n$$

Условия применимости

- Характер взаимосвязи линейный.
- Желательно, чтобы переменные и остатки были распределены нормально.
- Гомоскедастичность - постоянная изменчивость остатков на всем интервале значений независимой переменной.
- Нет мультиколлинеарности (наличия линейной зависимости между объясняющими переменными регрессионной модели).

- Подбор оптимальной модели можно производить путем изменения количества предикторов в ней в процессе максимизации исправленного коэффициента детерминации или минимизации информационного критерия Акаике.