Деревья решений



План

1. Понятие и построение деревьев принятия решений
2. Ансамбли моделей

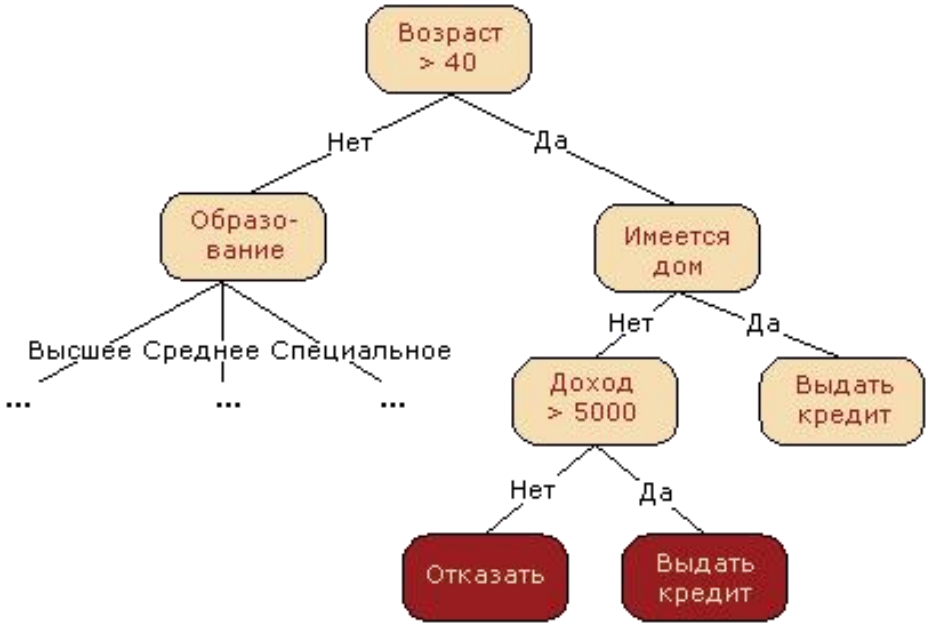
Деревья принятия решений

Деревья принятия решений

Деревья решений – один из самых популярных алгоритмов классификации. Деревья решений используются в повседневной жизни в самых разных областях человеческой деятельности, порой и очень далеких от машинного обучения. Деревом решений можно назвать наглядную инструкцию, что делать в той или иной ситуации.

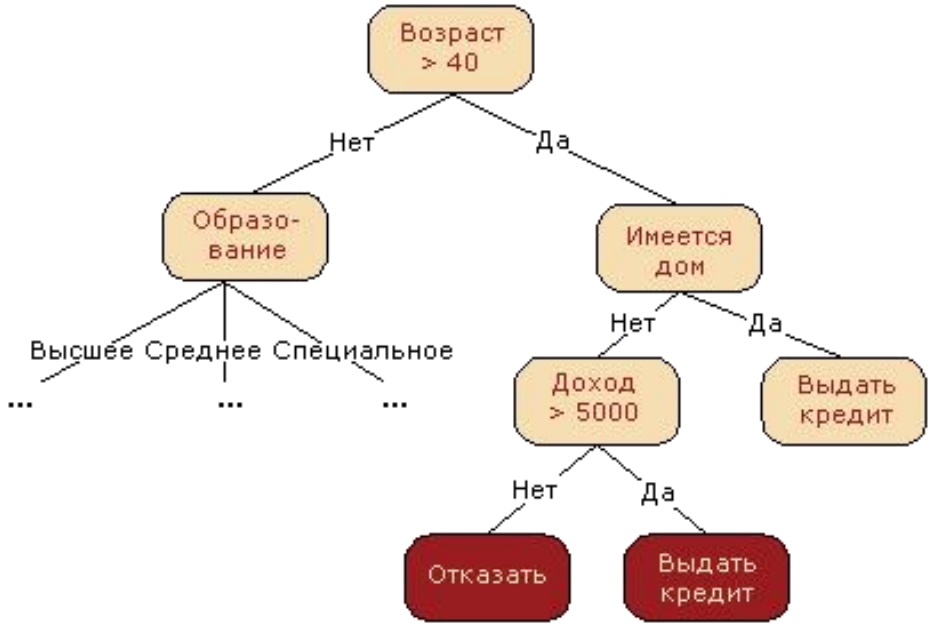
Деревья принятия решений

Часто дерево решений – обобщение опыта экспертов. Например, до внедрения алгоритмов машинного обучения в банковской сфере задача кредитного скоринга решалась экспертами. Решение о выдаче кредита заемщику принималось на основе некоторых интуитивно (или по опыту) выведенных правил, которые можно представить в виде дерева решений.



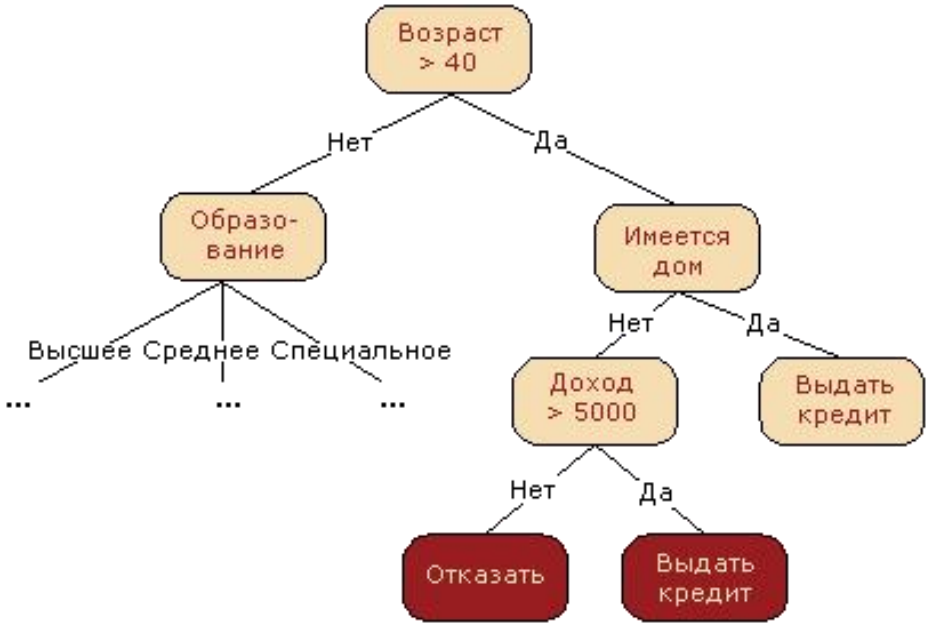
Деревья принятия решений

В этом случае можно сказать, что решается задача бинарной классификации (целевой класс имеет два значения: "Выдать кредит" и "Отказать") по признакам "Возраст", "Наличие дома", "Доход" и "Образование". Огромное преимущество деревьев решений в том, что они легко интерпретируемы, понятны человеку.

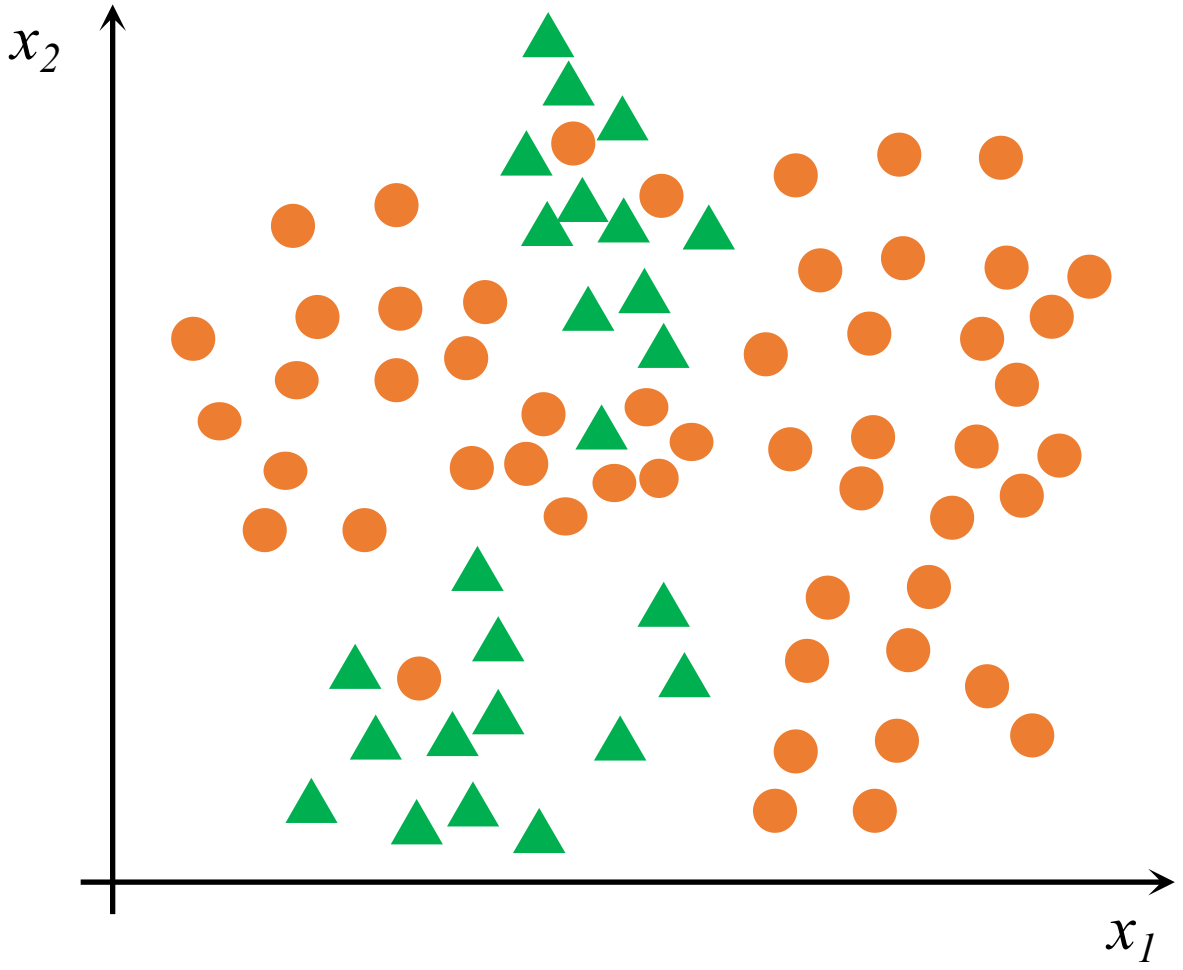


Деревья принятия решений

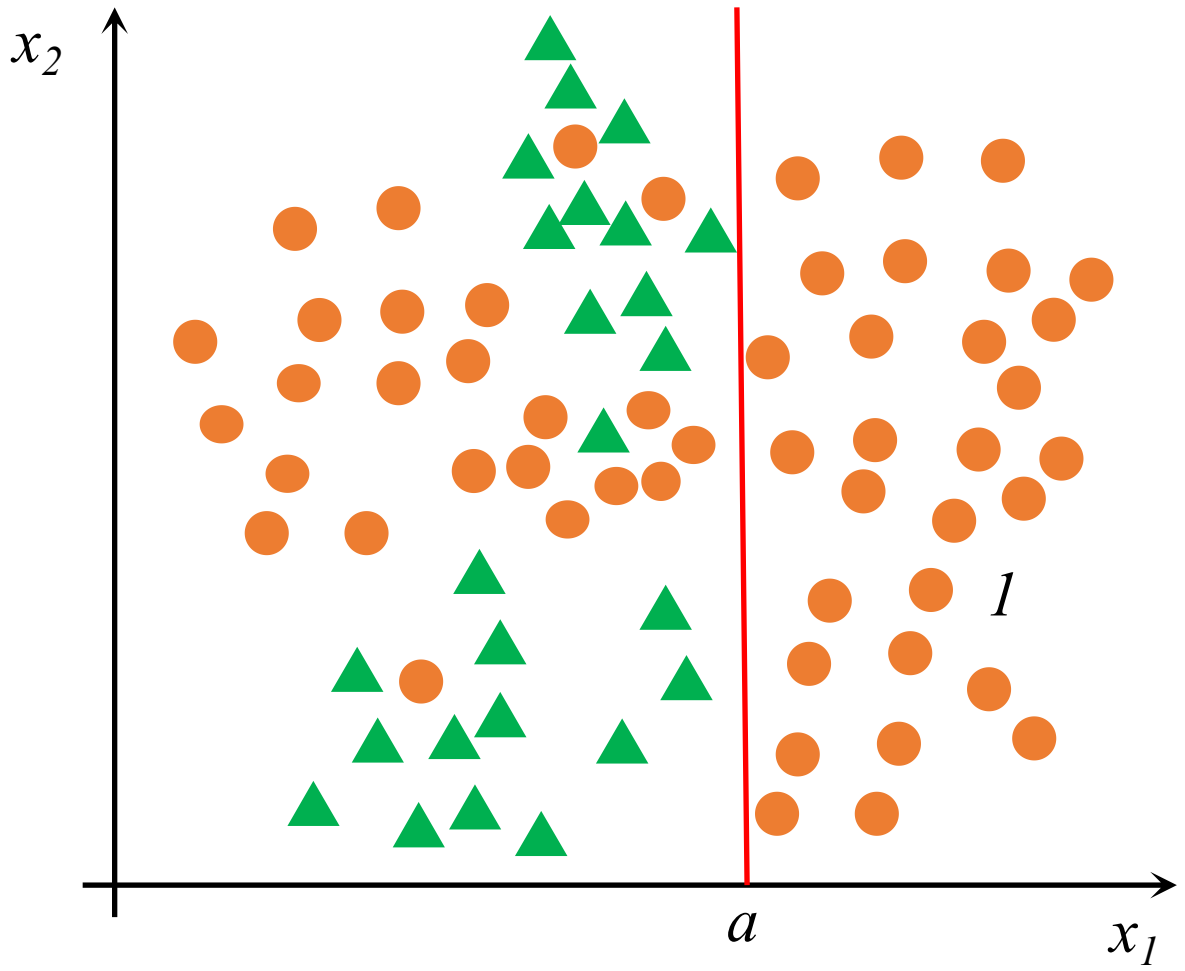
Например, по схеме можно объяснить заемщику, почему ему было отказано в кредите. Скажем, потому, что у него нет дома и доход меньше 5000. В связи с этой "понятностью" и сходством с моделью принятия решений человеком, деревья решений и получили большую популярность.



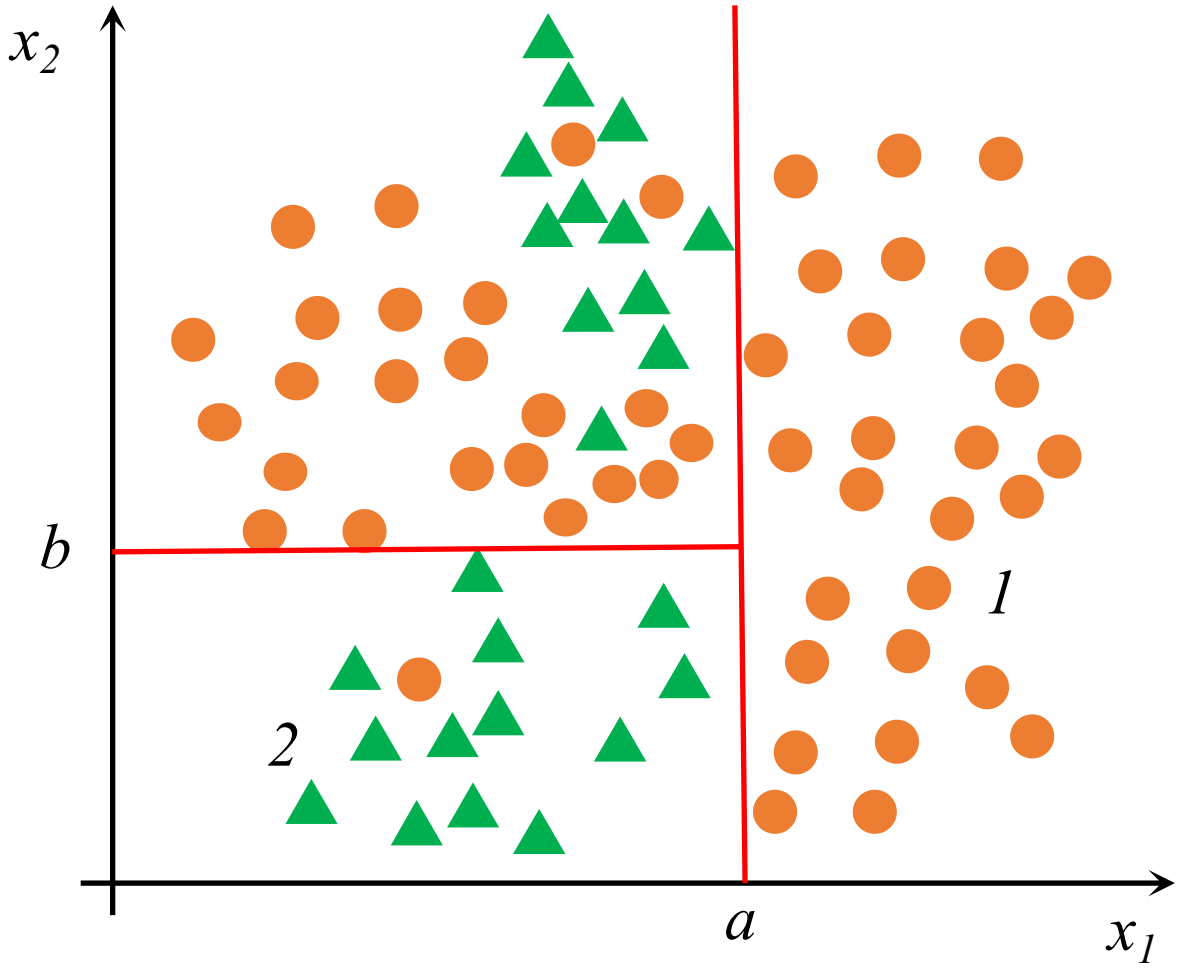
Деревья принятия решений



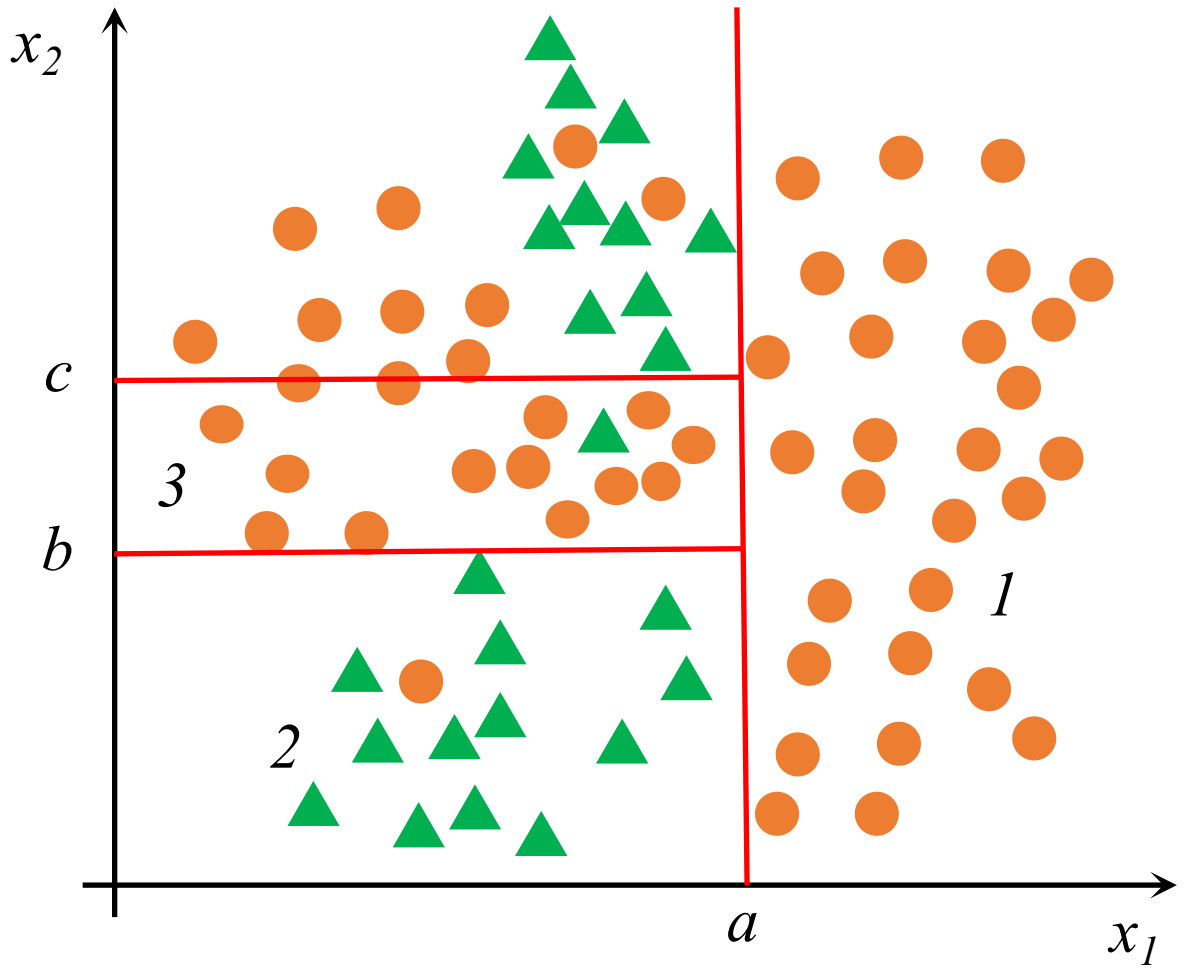
Деревья принятия решений



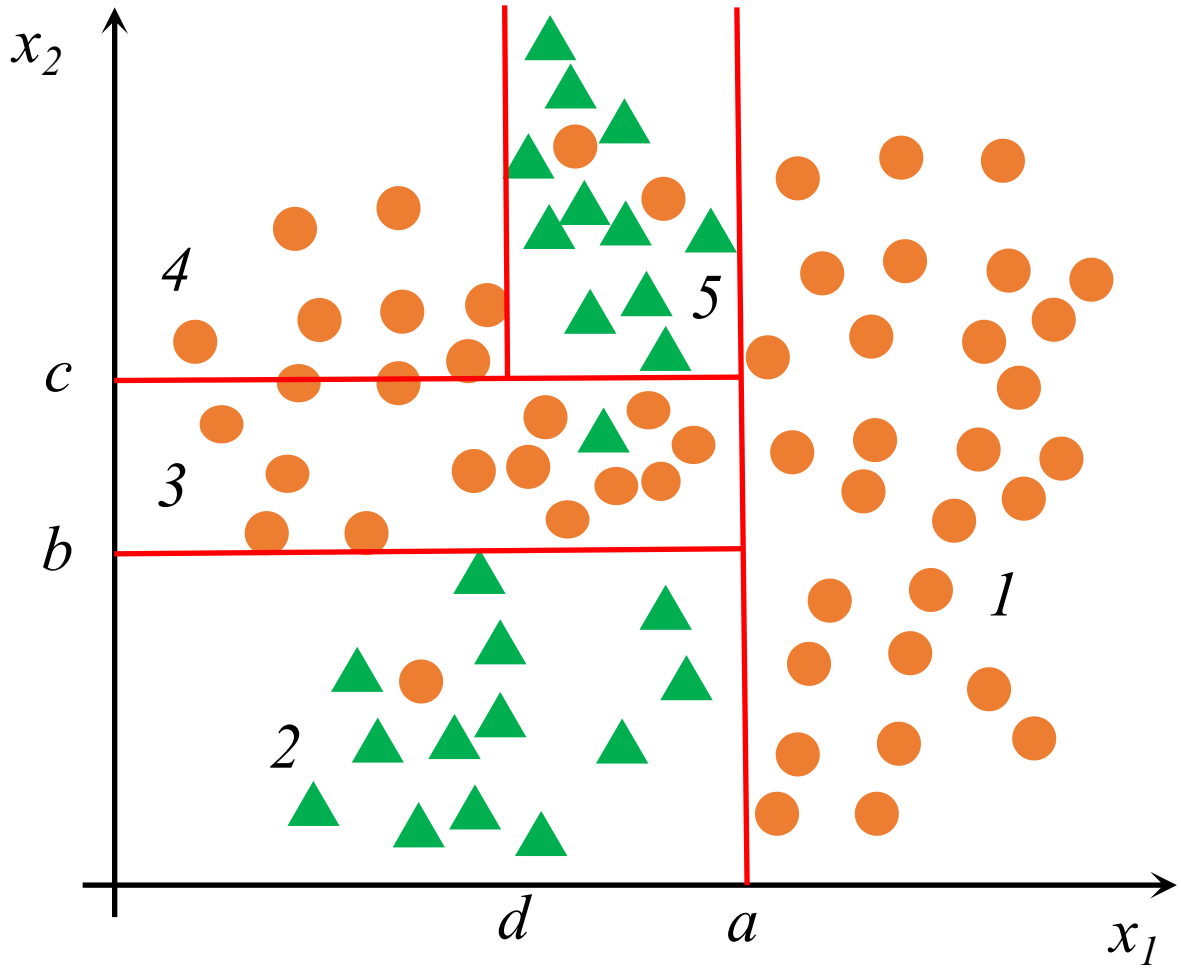
Деревья принятия решений



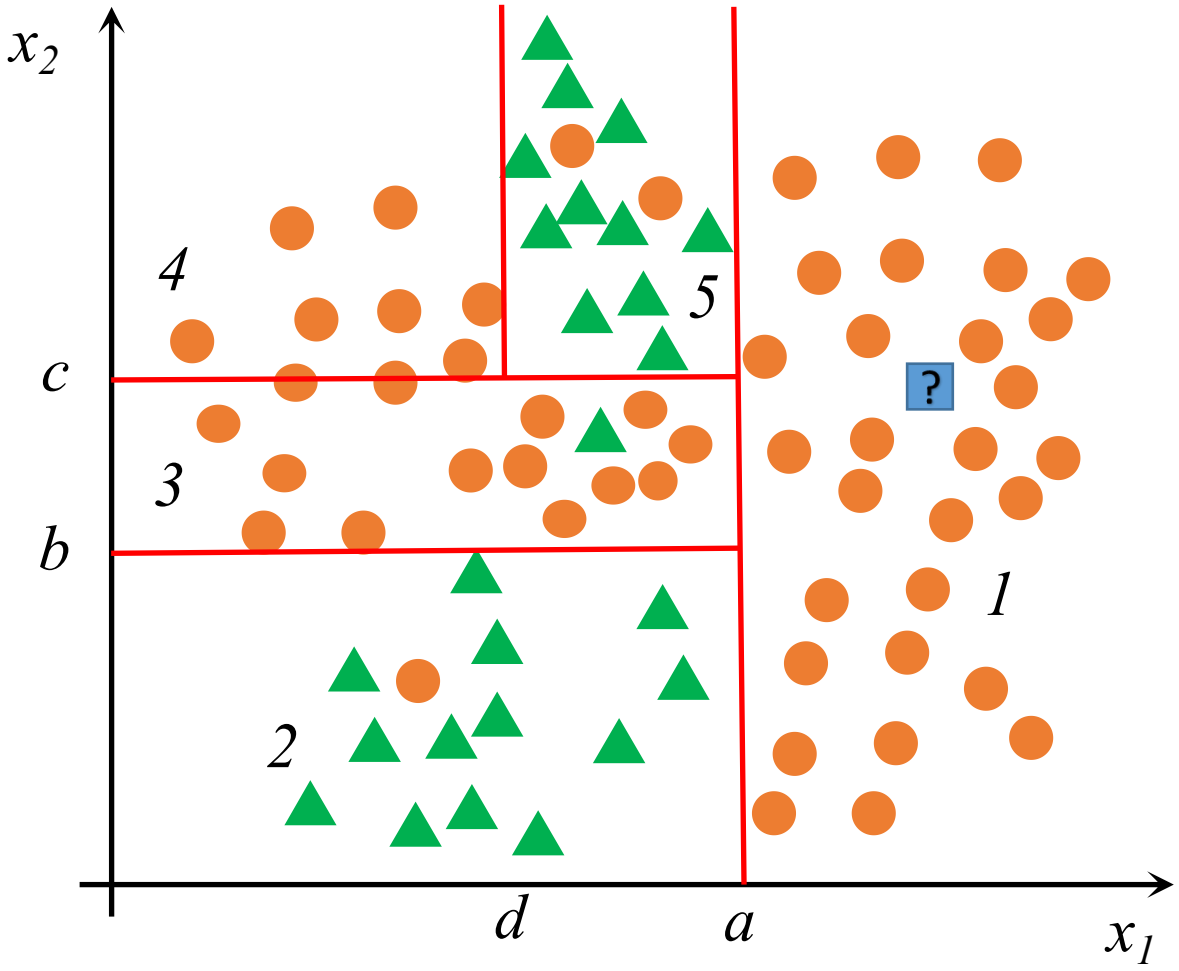
Деревья принятия решений



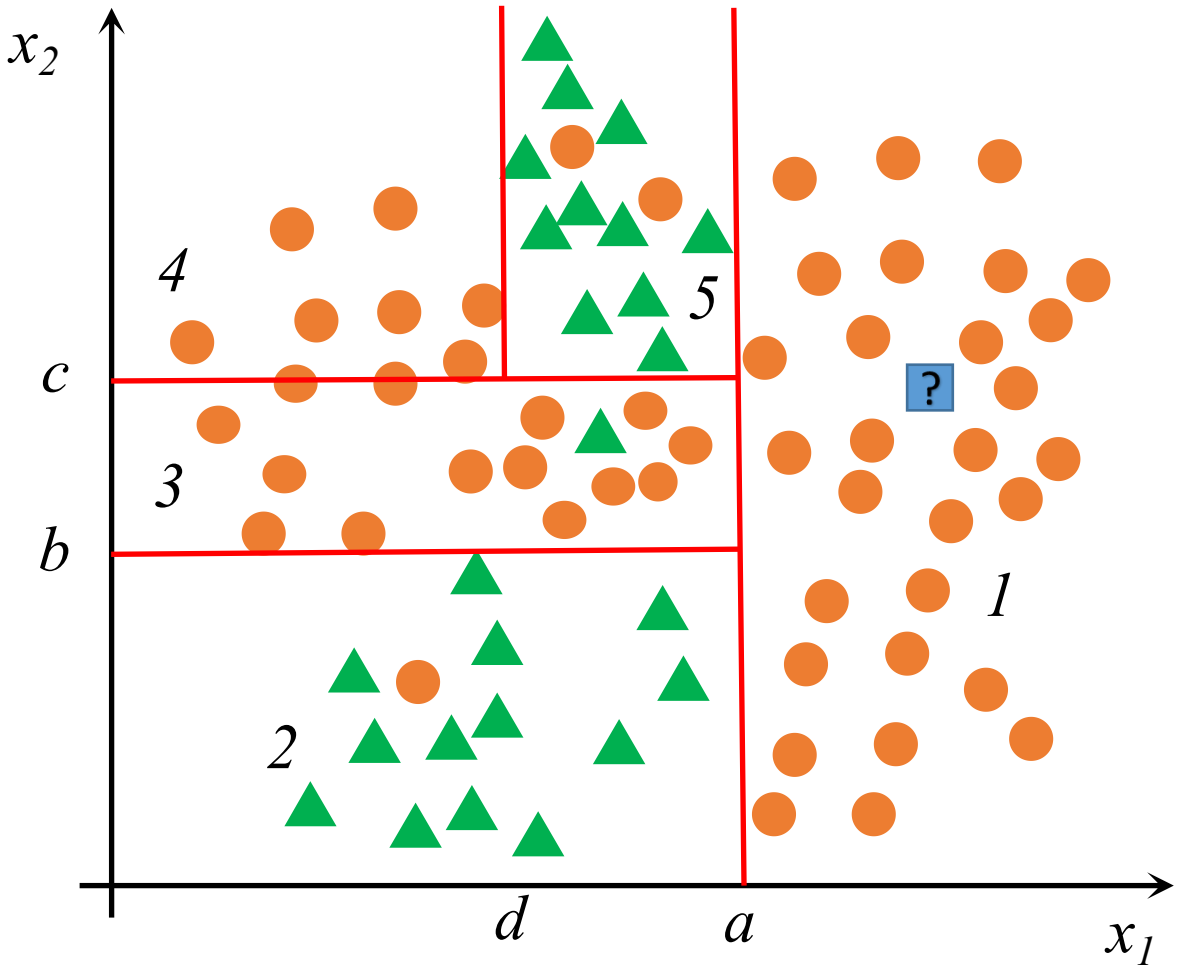
Деревья принятия решений



Деревья принятия решений

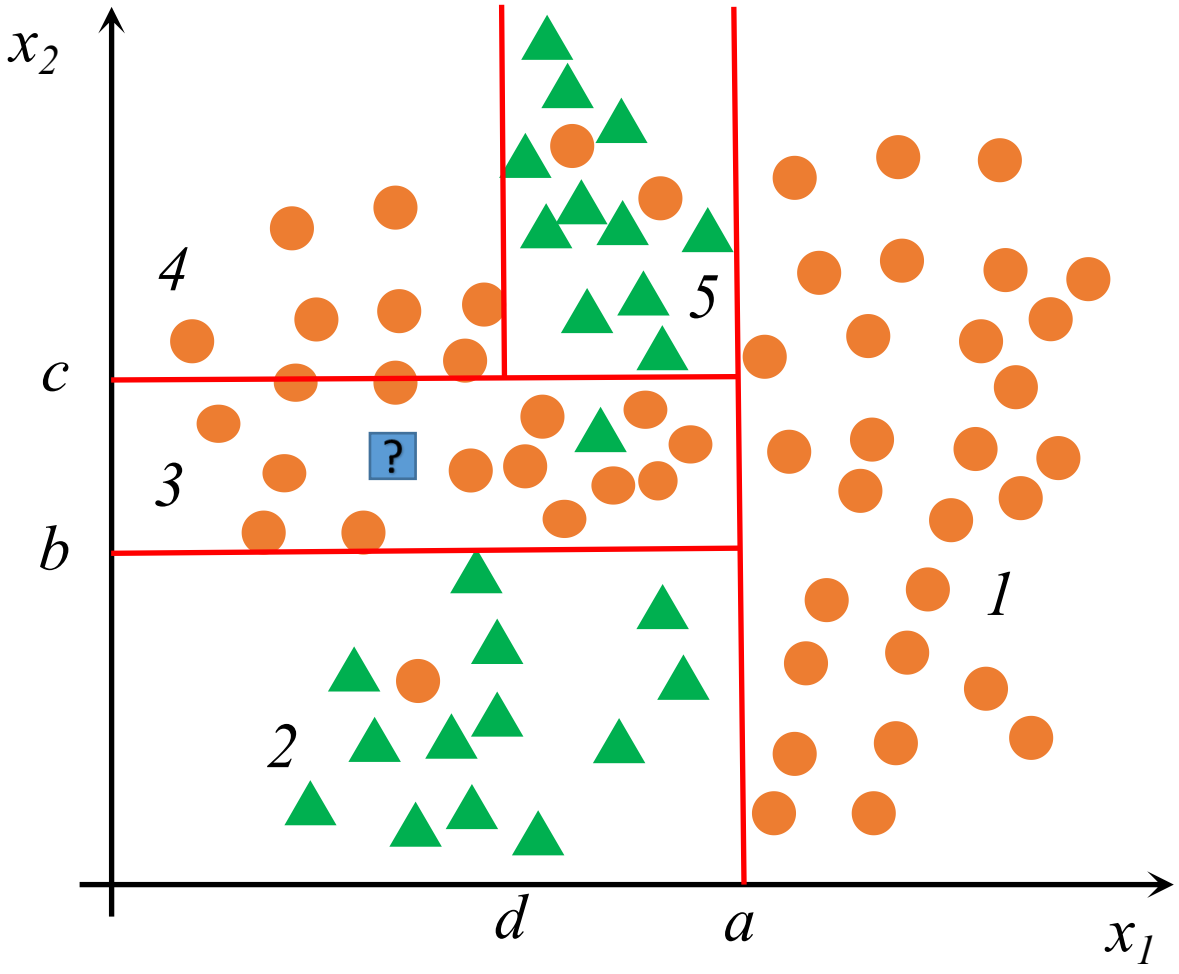


Деревья принятия решений

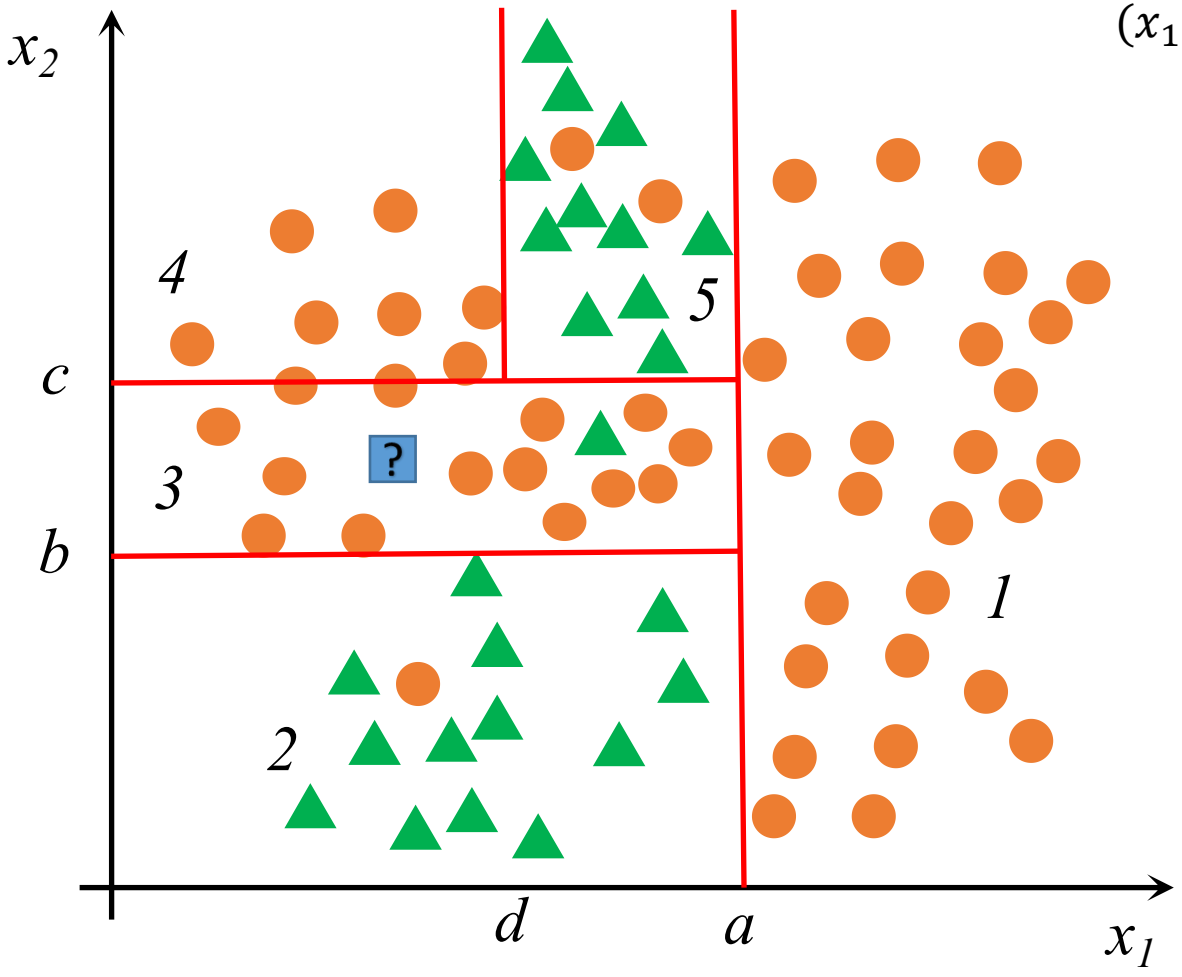


$x_1 > a, \Rightarrow$ ●

Деревья принятия решений



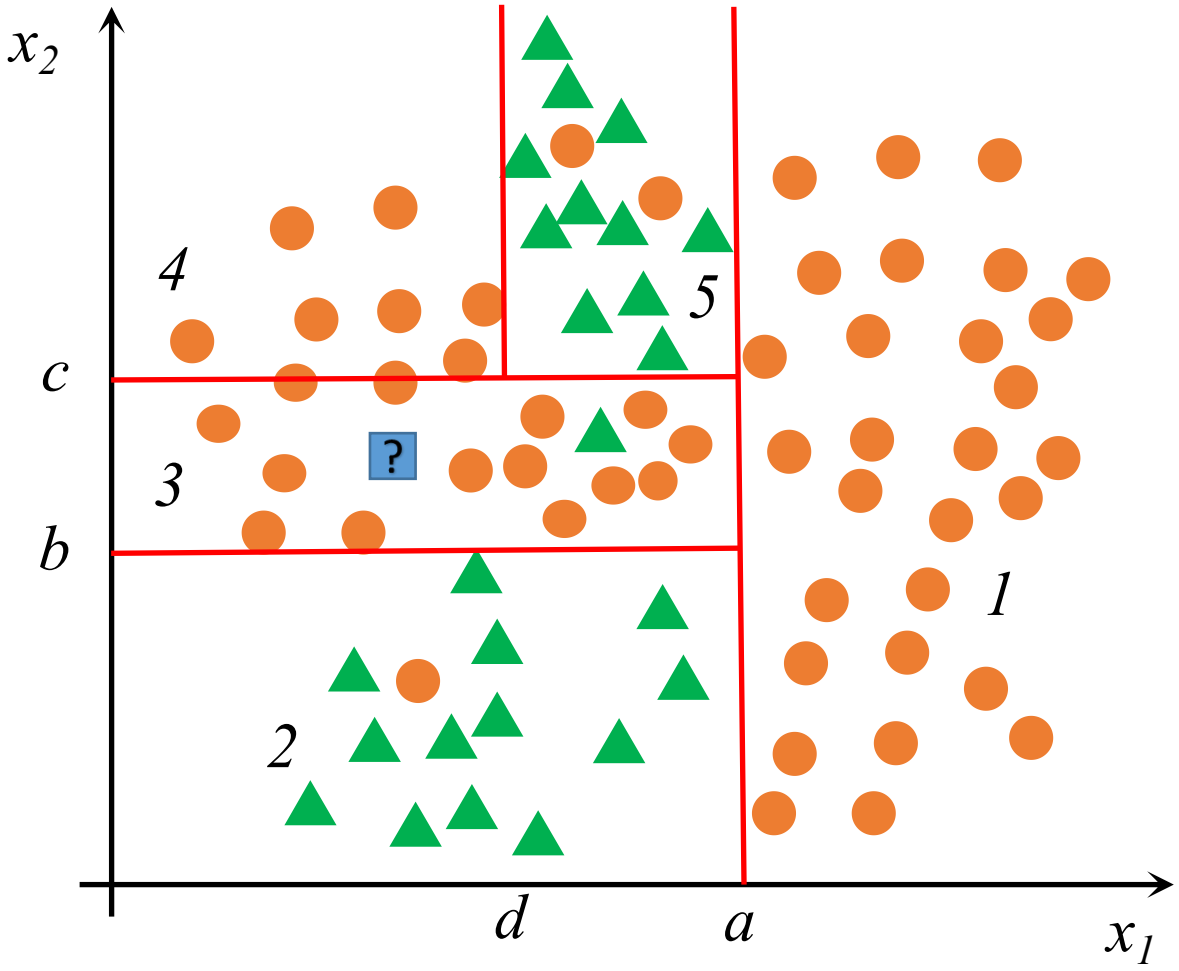
Деревья принятия решений



$(x_1 < a) \& (x_2 > b) \& (x_2 < c), \Rightarrow$ ●

Деревья принятия решений

$x_1 < a$

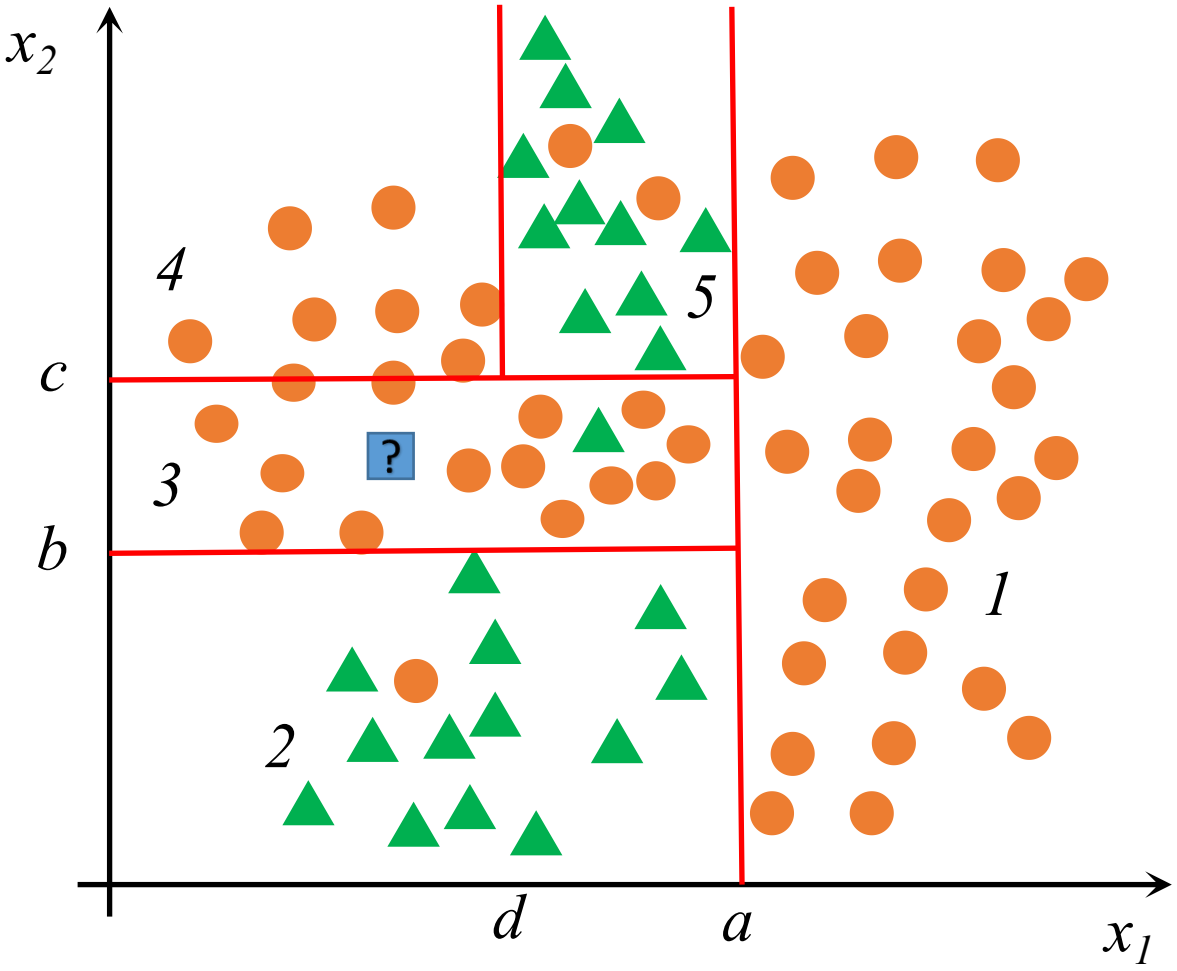


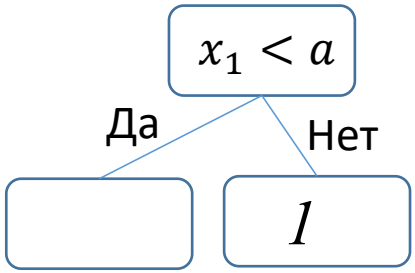
Деревья принятия решений (договоренности)

узел (node)

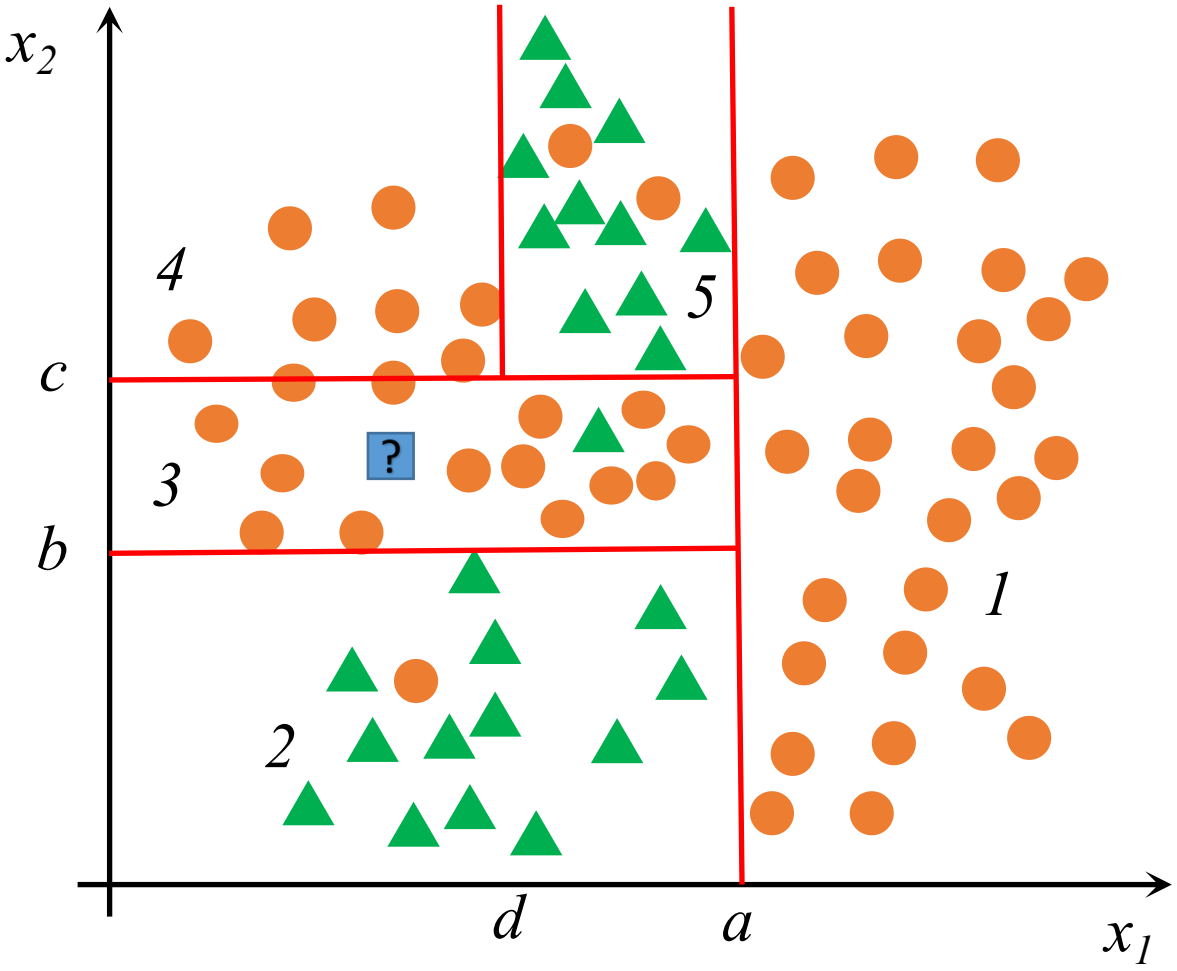
$x_1 < a$

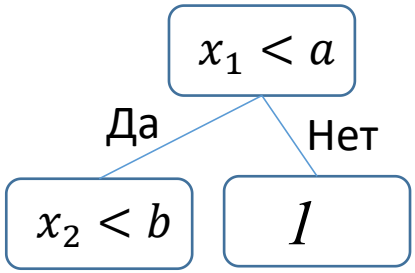
Деревья принятия решений



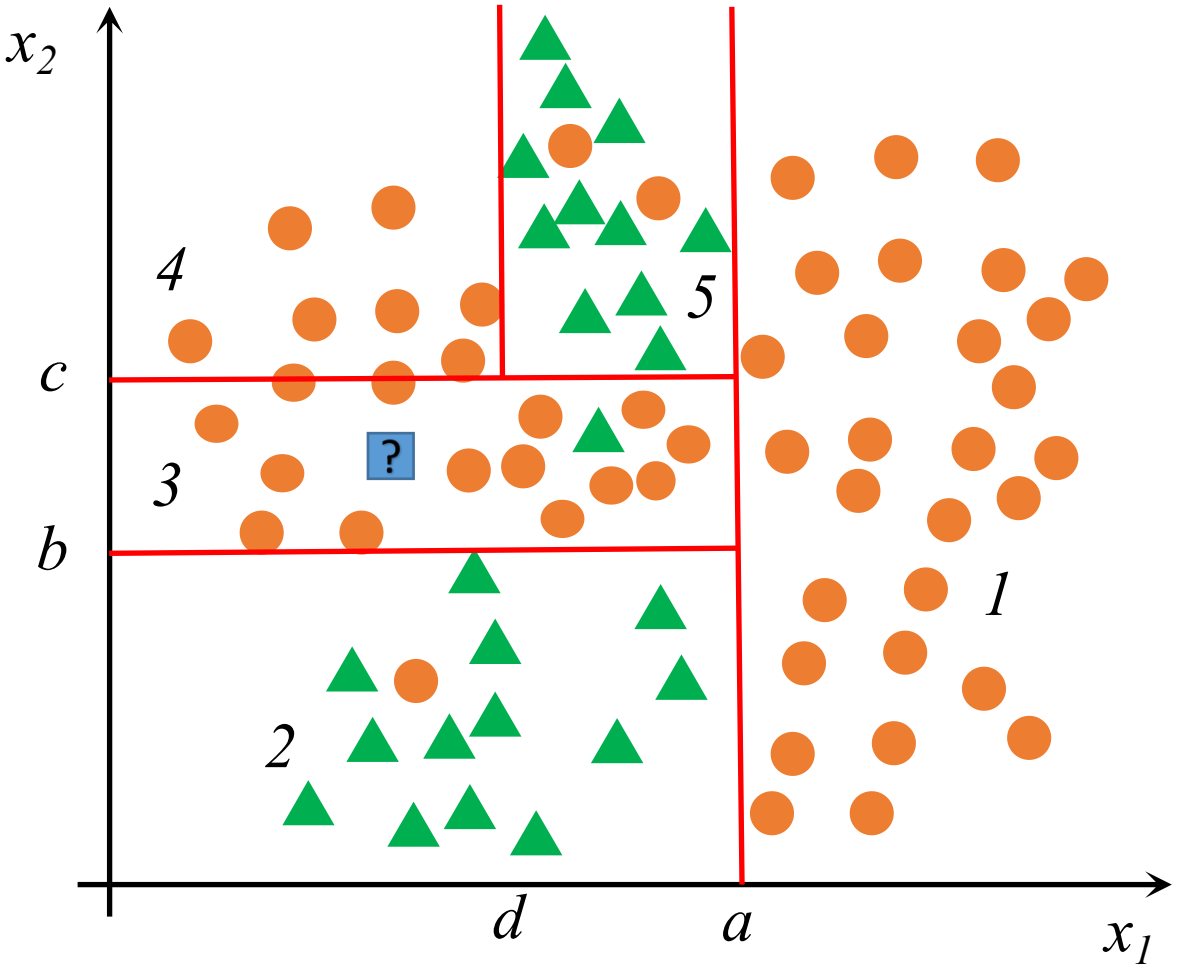


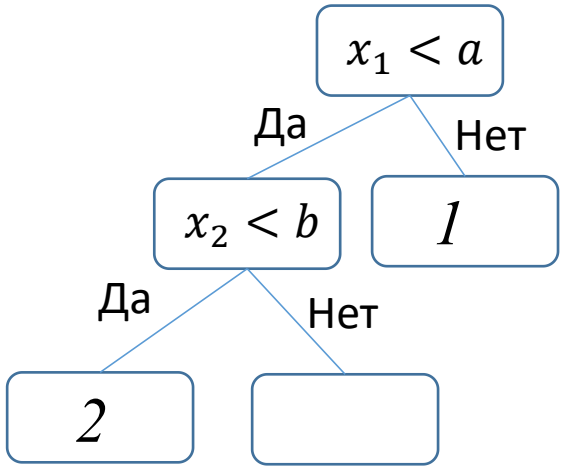
Деревья принятия решений



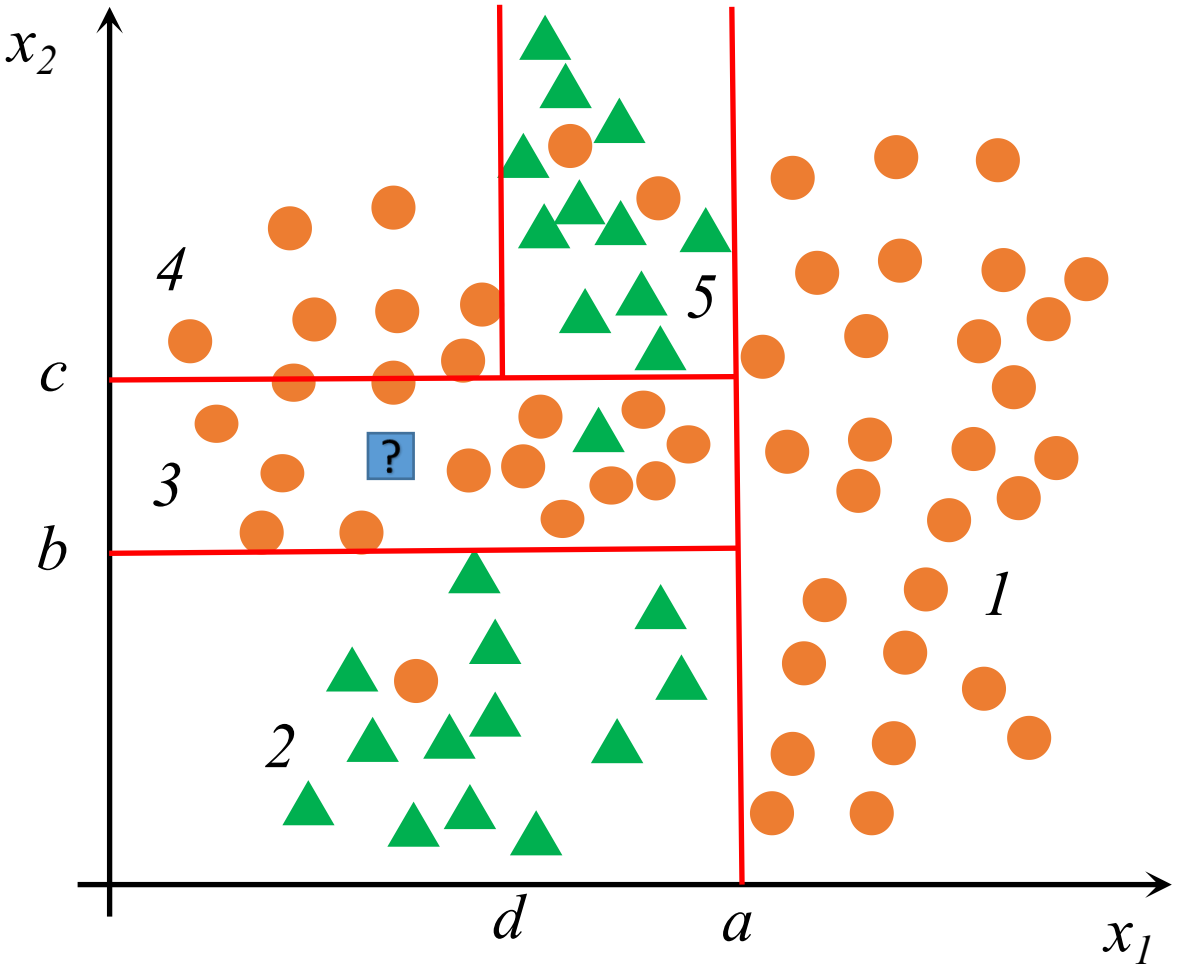


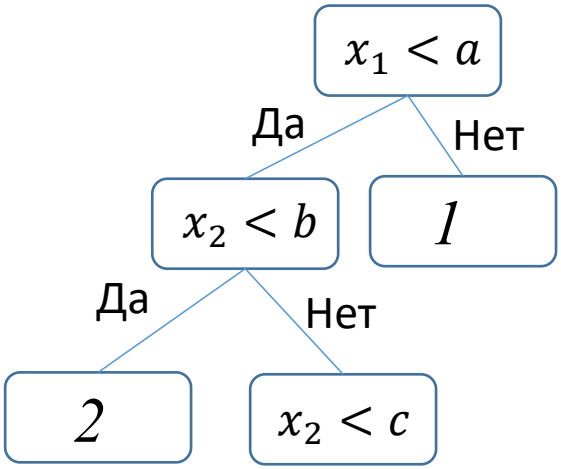
Деревья принятия решений



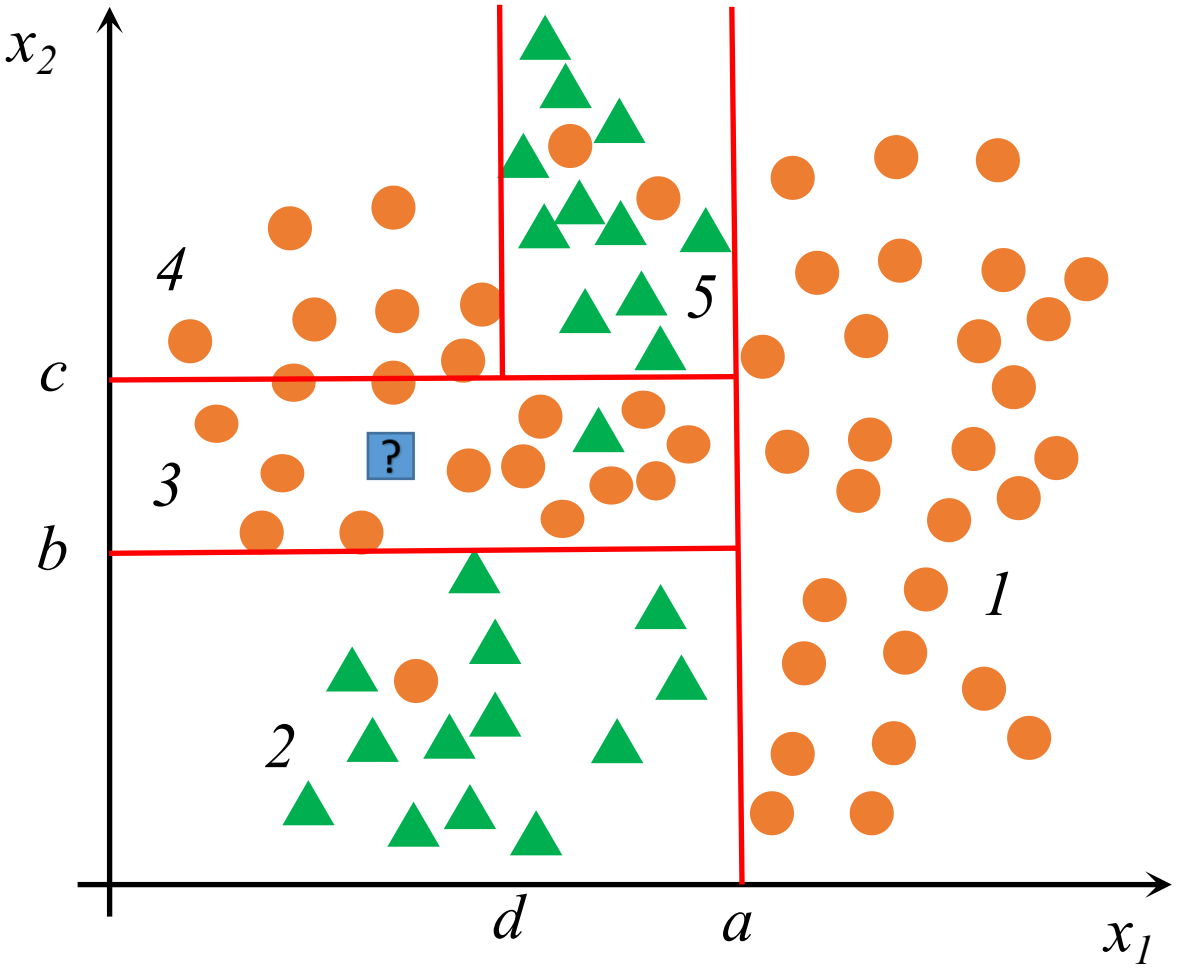


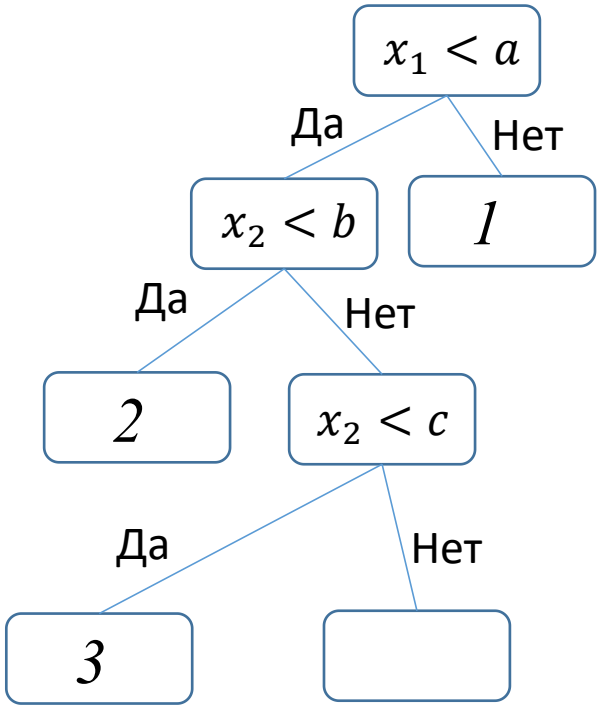
Деревья принятия решений



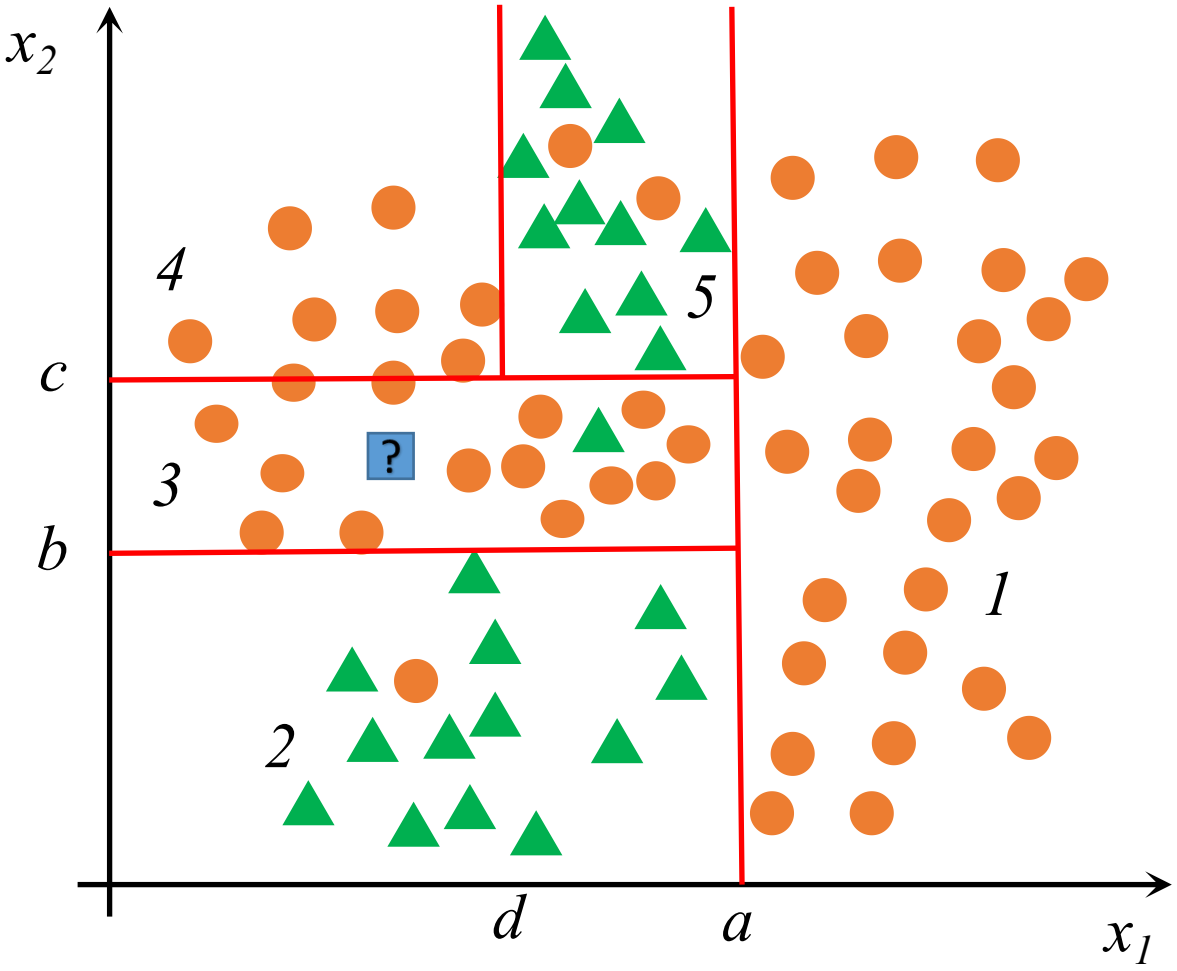


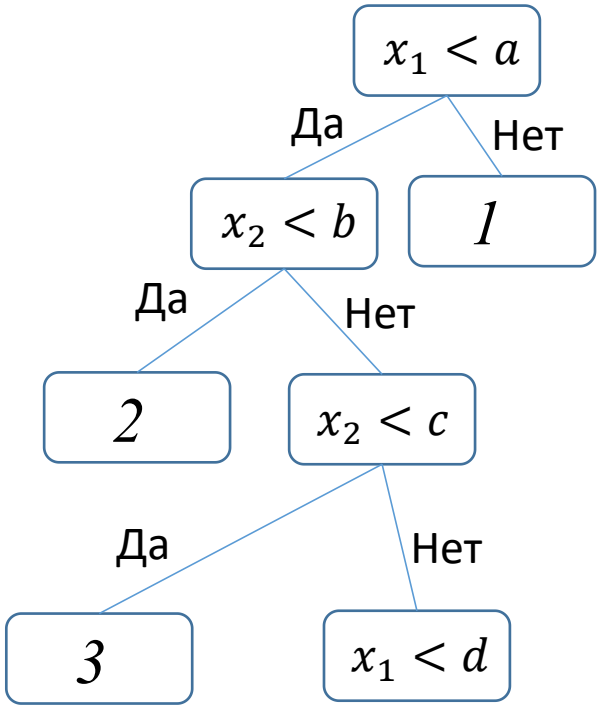
Деревья принятия решений



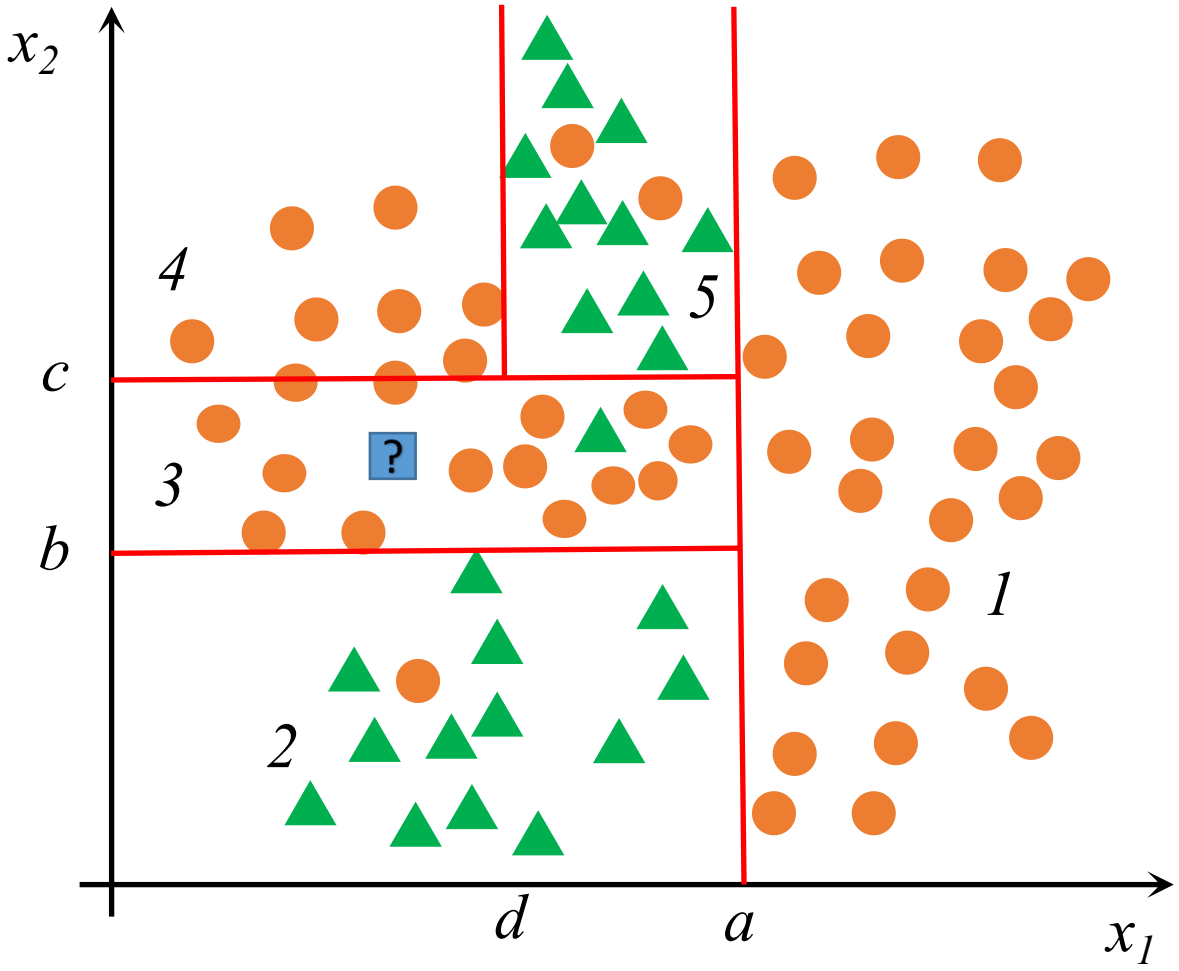


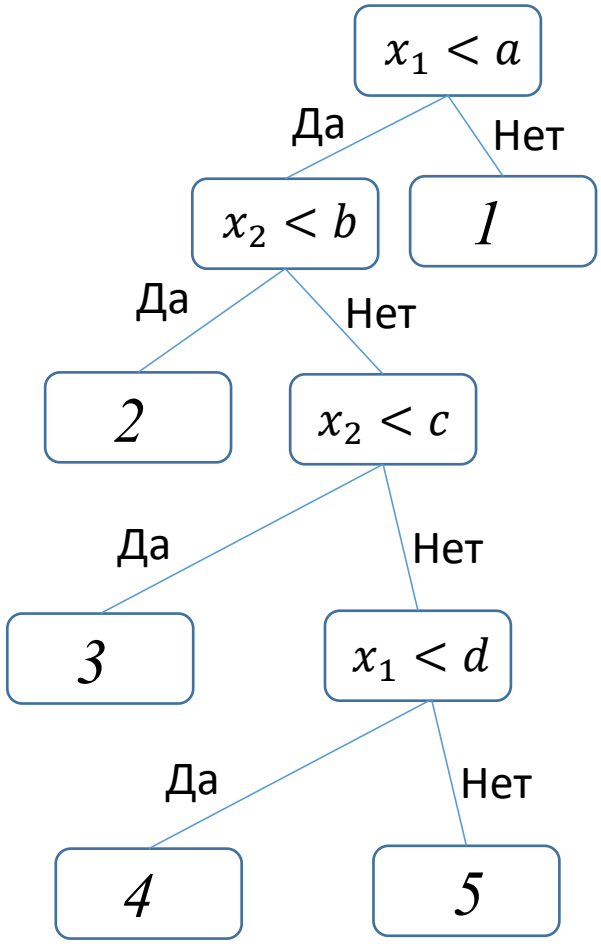
Деревья принятия решений





Деревья принятия решений





Как строится дерево решений

В примере с кредитным скорингом мы видели, что решение о выдаче кредита принималось на основе возраста, наличия недвижимости, дохода и других. Но какой признак выбрать первым?

Как строится дерево решений

В примере с кредитным скорингом мы видели, что решение о выдаче кредита принималось на основе возраста, наличия недвижимости, дохода и других. Но какой признак выбрать первым?

Есть игры, которые предполагают задавание вопросов и ответы типа «да-нет». Какой вопрос отгадывающий задаст первым делом? Конечно, такой, который сильнее всего уменьшит количество оставшихся вариантов. К примеру, вопрос «это млекопитающее?» намного лучше разделяет объекты, чем вопрос «это лошадь?».

Как строится дерево решений

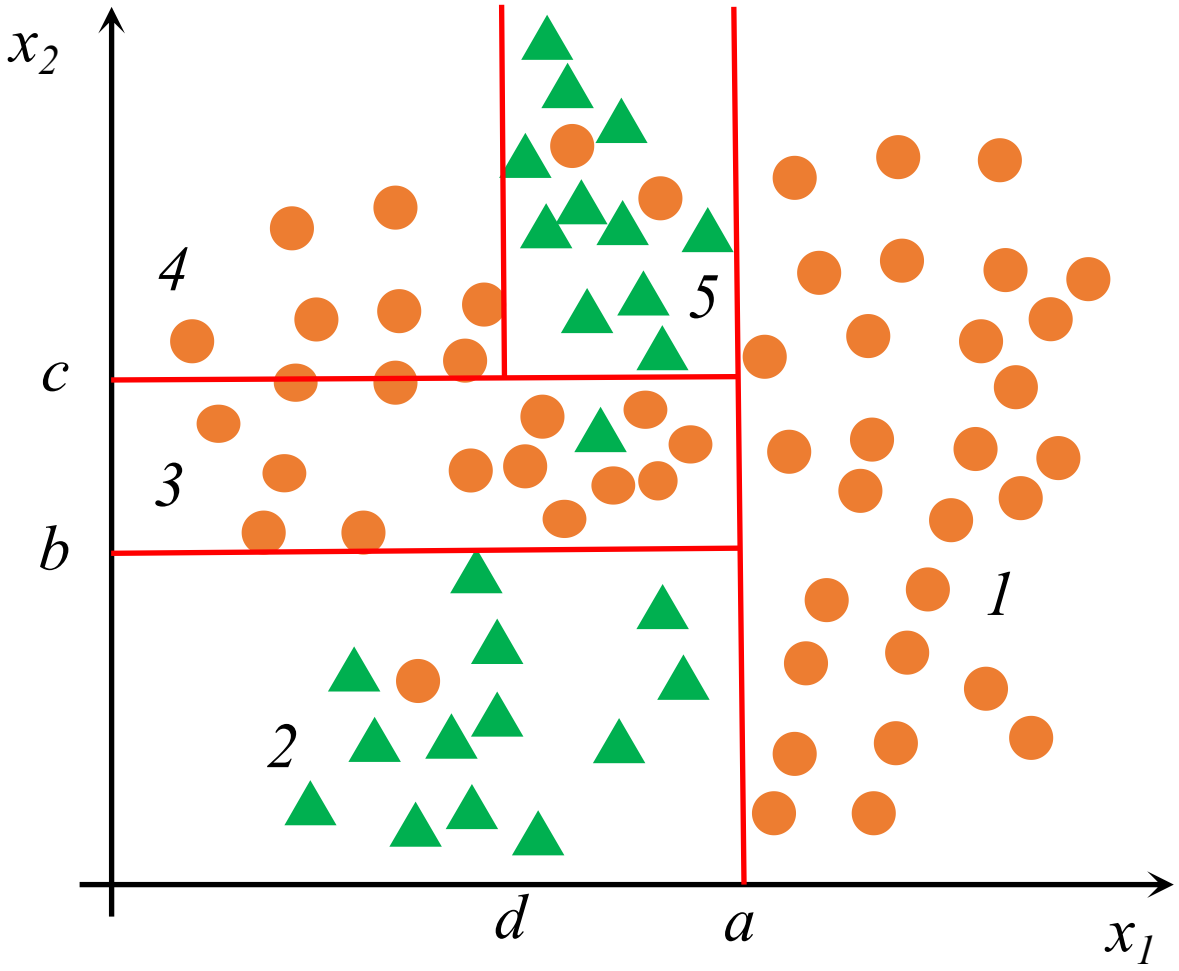
В примере с кредитным скорингом мы видели, что решение о выдаче кредита принималось на основе возраста, наличия недвижимости, дохода и других. Но какой признак выбрать первым?

Есть игры, которые предполагают задавание вопросов и ответы типа «да-нет». Какой вопрос отгадывающий задаст первым делом? Конечно, такой, который сильнее всего уменьшит количество оставшихся вариантов. К примеру, вопрос «это млекопитающее?» намного лучше разделяет объекты, чем вопрос «это лошадь?».

Это интуитивно соответствует понятию прироста информации, основанного на энтропии.

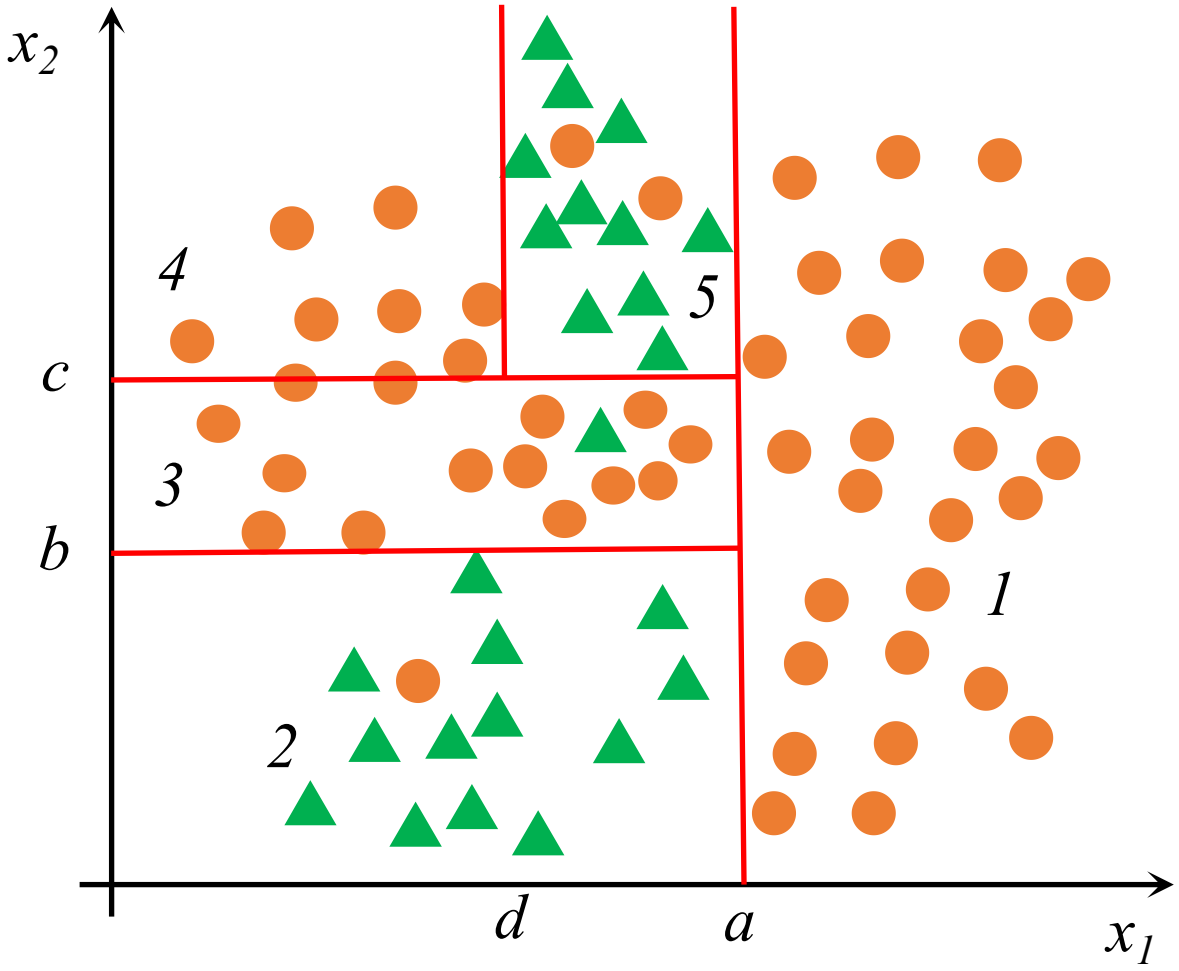
Деревья принятия решений

1 и 4 – «чистые» множества



Деревья принятия решений

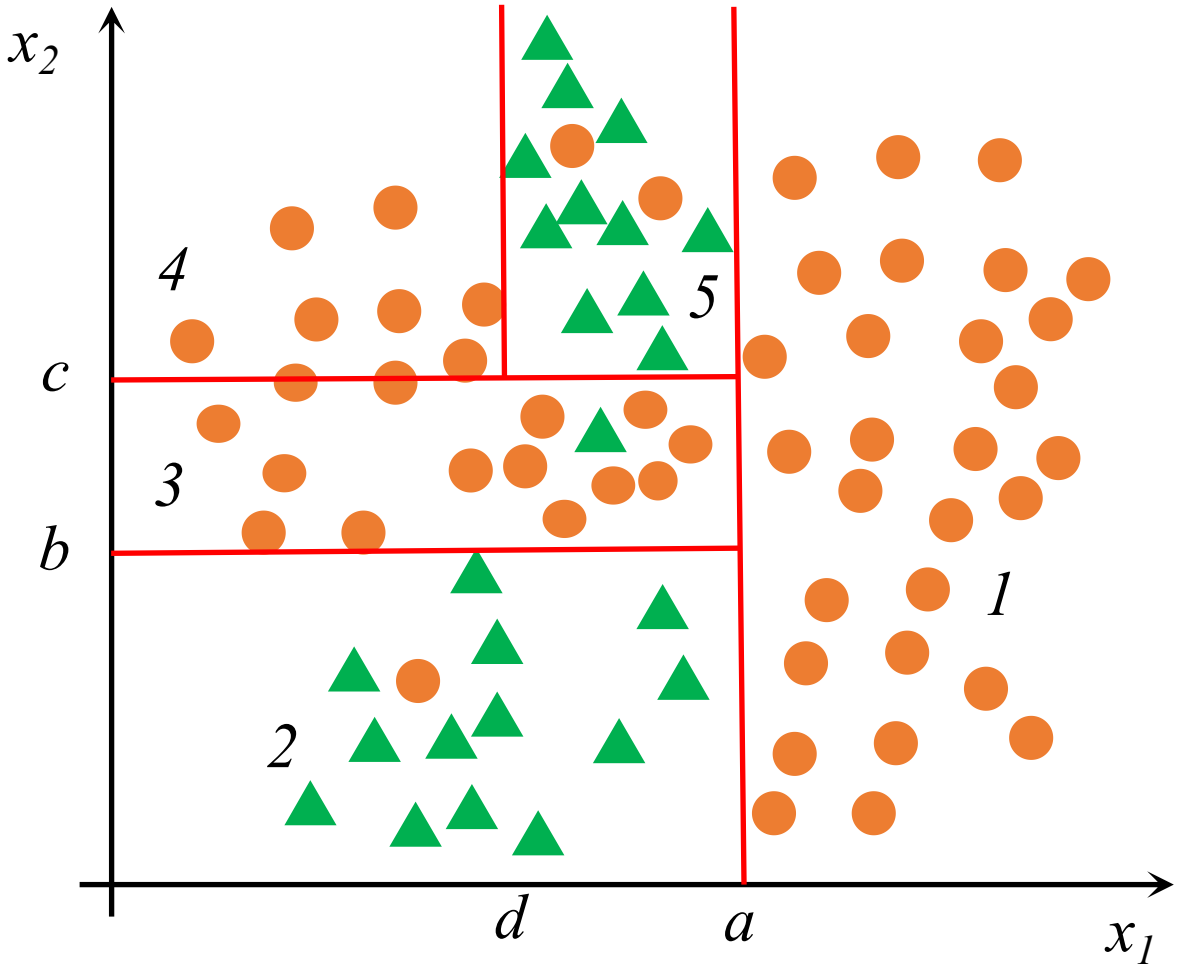
1 и 4 – «чистые» множества



Идея: проводить расщепление так, чтобы получающиеся множества содержали как можно меньше примесей.

Деревья принятия решений

1 и 4 – «чистые» множества



Идея: проводить расщепление так, чтобы получающиеся множества содержали как можно меньше примесей.

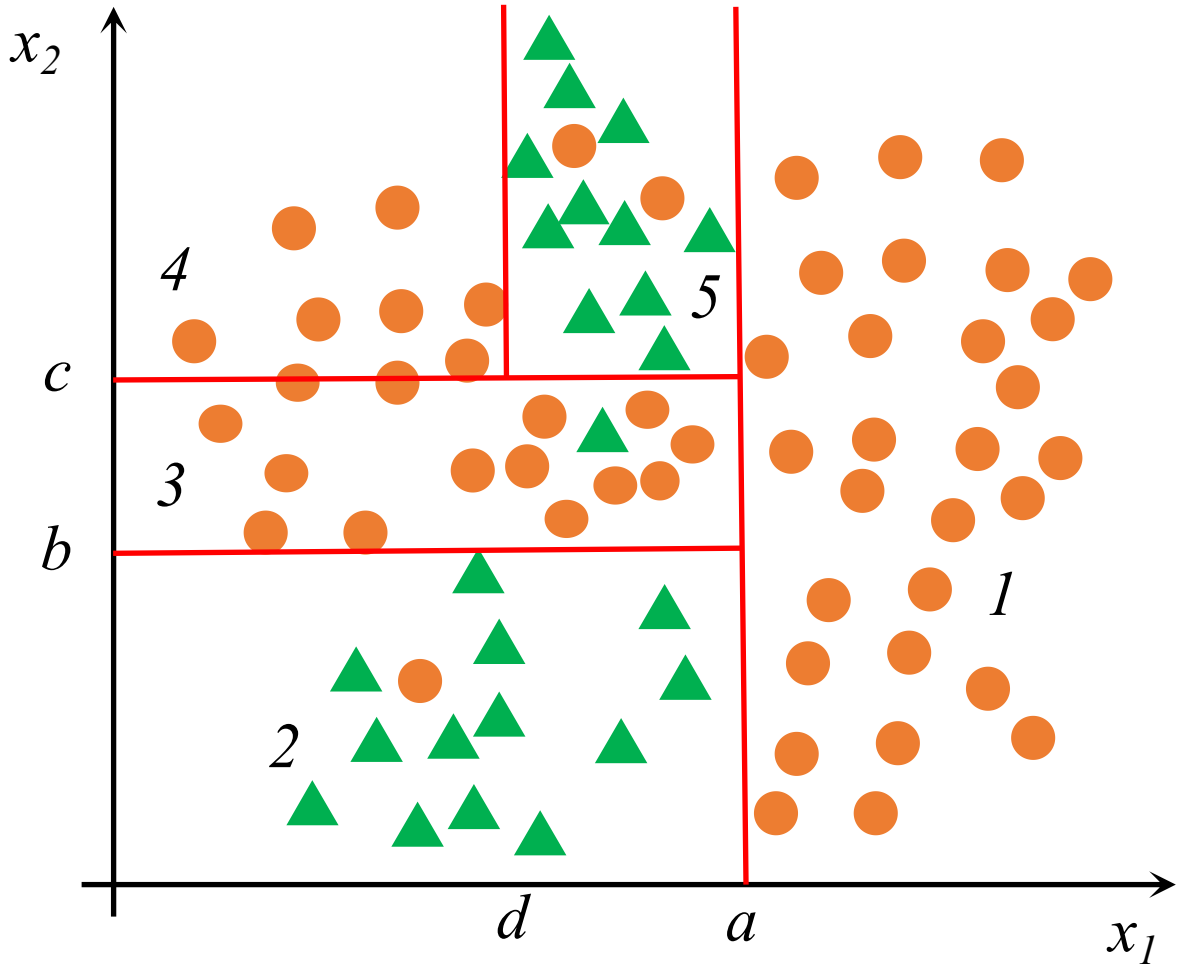
$p(\bullet) = 1$

или

$p(\bullet) = 0$

Деревья принятия решений

1 и 4 – «чистые» множества



Идея: проводить расщепление так, чтобы получающиеся множества содержали как можно меньше примесей.

$p(\bullet) = 1$

или

$p(\bullet) = 0$

Максимально «грязный» случай:

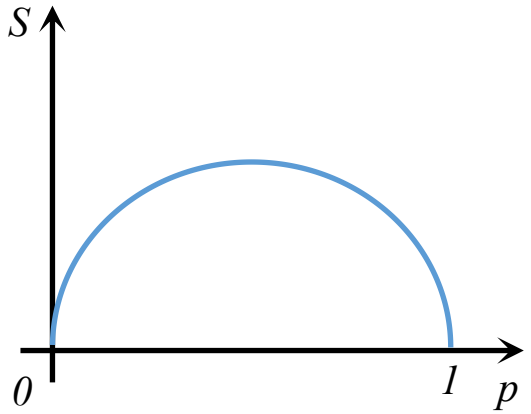
$p(\bullet) = 0{,}5$

Энтропия Шеннона

Энтропия Шеннона определяется для системы с N возможными состояниями (классами) следующим образом:

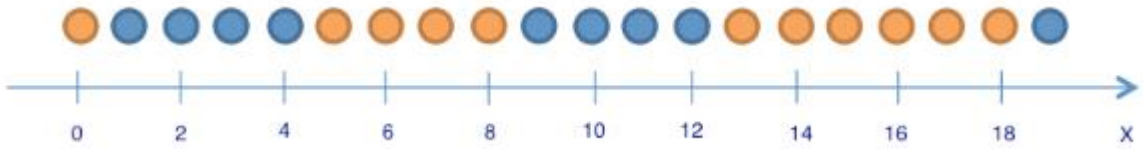
$$S = -\sum_{k=1}^{N} p_k \log_2 p_k$$

где p_k – вероятности нахождения системы в k-ом состоянии. Энтропия характеризует степень хаоса в системе. Чем выше энтропия, тем менее упорядочена система и наоборот.



Энтропия Шеннона

Пример. Будем предсказывать цвет шарика по его координате.

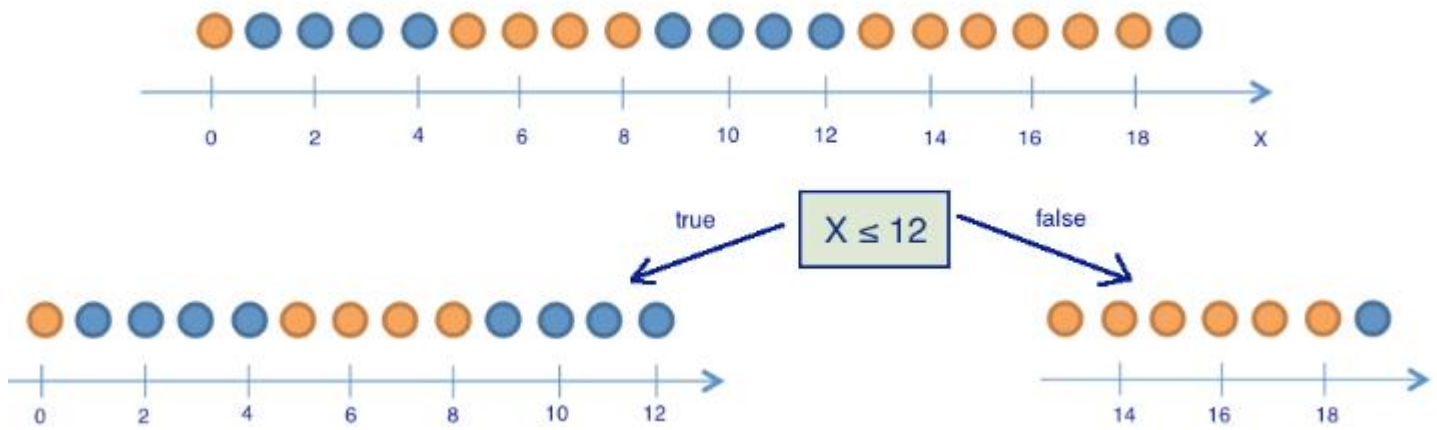


Здесь 9 синих шариков и 11 желтых. Если мы наудачу вытащили шарик, то он с вероятностью p_1=9/20 будет синим и с вероятностью p_2=11/20 – желтым. Значит, энтропия

$$S_0 = -\sum_{k=1}^{2} p_k \log_2 p_k = -\frac{9}{20}\log_2\frac{9}{20} - \frac{11}{20}\log_2\frac{11}{20} \approx 1$$

Само это значение пока ни о чем нам не говорит. Теперь посмотрим, как изменится энтропия, если разбить шарики на две группы – с координатой меньше либо равной 12 и больше 12.

Энтропия Шеннона



В левой группе оказалось 13 шаров, из которых 8 синих и 5 желтых. Энтропия этой группы равна

$$S_1 = -\frac{5}{13}\log_2\frac{5}{13} - \frac{8}{13}\log_2\frac{8}{13} \approx 0{,}96$$

В правой группе оказалось 7 шаров, из которых 1 синий и 6 желтых. Энтропия правой группы равна

$$S_2 = -\frac{1}{7}\log_2\frac{1}{7} - \frac{6}{7}\log_2\frac{6}{7} \approx 0{,}60$$

Как видим, энтропия уменьшилась в обеих группах по сравнению с начальным состоянием, хоть в левой и не сильно.

Энтропия Шеннона

Поскольку энтропия характеризует степень хаоса (или неопределенности) в системе, уменьшение энтропии называют приростом информации. Формально прирост информации (*information gain*, IG) при разбиении выборки по признаку Q (в нашем примере это признак "$x \leq 12$") определяется как

$$IG(Q) = S_0 - \sum_{i=1}^{K} \frac{N_i}{N} S_i$$

где K– число групп после разбиения, N_i – число элементов выборки, у которых признак Q имеет i-ое значение. В нашем случае после разделения получилось две группы (K=2) – одна из 13 элементов (N_1=13), вторая – из 7 (N_2=7). Прирост информации получился

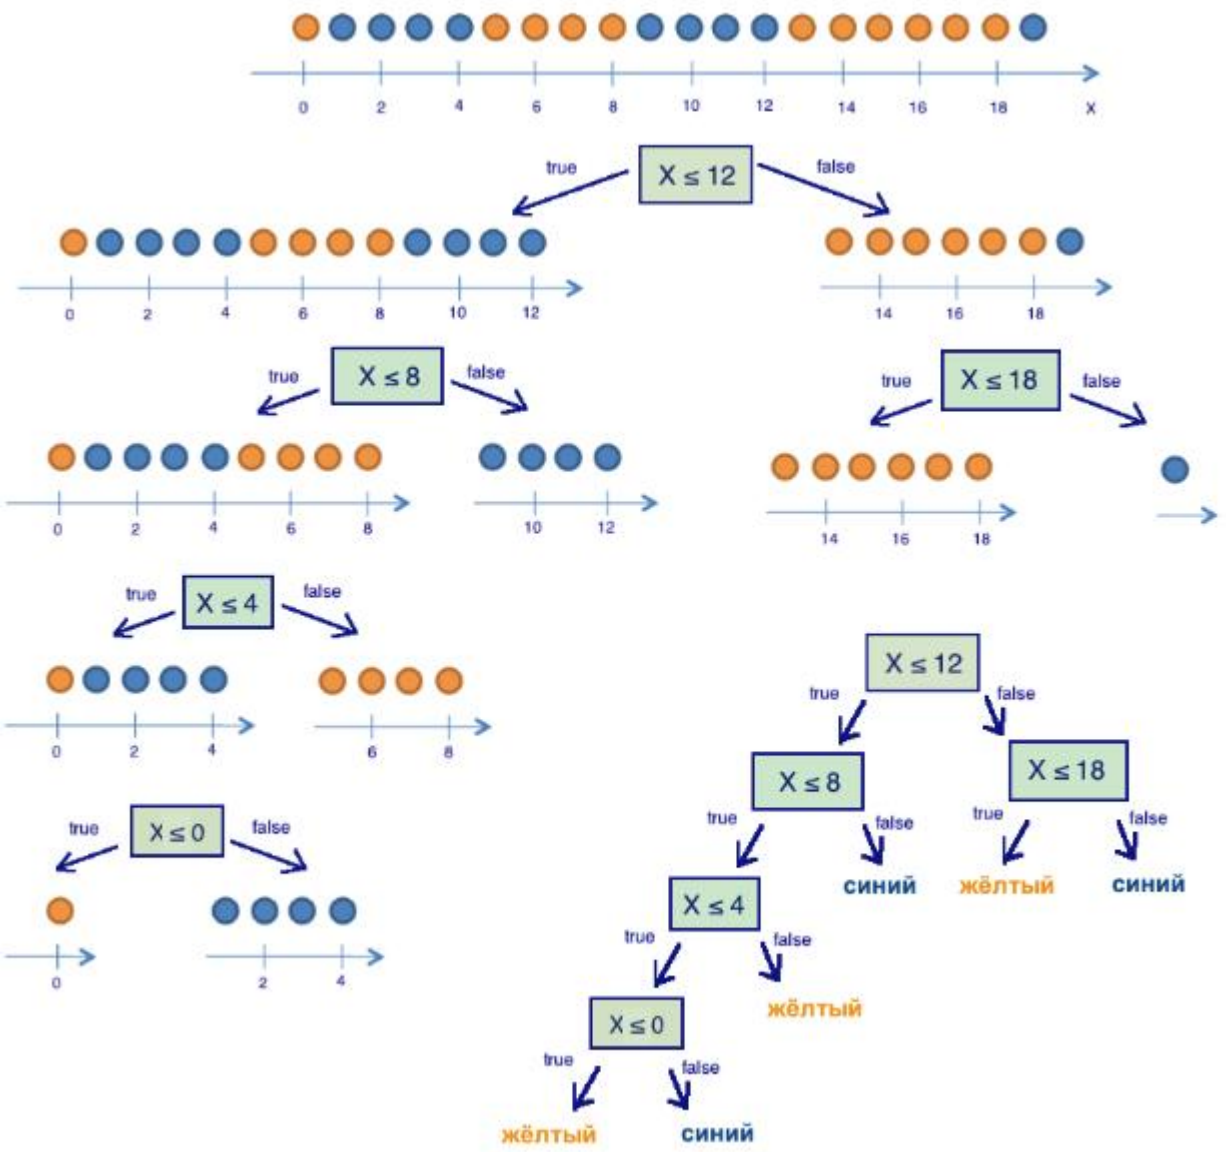
$$IG(x \leq 12) = S_0 - \frac{13}{20} S_1 - \frac{7}{20} S_2 \approx 0{,}16$$

Энтропия Шеннона

Получается, разделив шарики на две группы по признаку "координата меньше либо равна 12", мы уже получили более упорядоченную систему, чем в начале. Продолжим деление шариков на группы до тех пор, пока в каждой группе шарики не будут одного цвета.

Очевидно, энтропия группы с шариками одного цвета равна 0 ($\log_2 1 = 0$), что соответствует представлению, что группа шариков одного цвета – упорядоченная.

Энтропия Шеннона



Очевидно, энтропия группы с шариками одного цвета равна 0, т.к. $\log_2 1 = 0$, что соответствует представлению, что группа шариков одного цвета – упорядоченная.

Энтропия Шеннона

В итоге мы построили дерево решений, предсказывающее цвет шарика по его координате. Отметим, что такое дерево решений может плохо работать для новых объектов (определения цвета новых шариков), поскольку оно идеально подстроилось под обучающую выборку (изначальные 20 шариков). Для классификации новых шариков лучше подойдет дерево с меньшим числом "вопросов", или разделений, пусть даже оно и не идеально разбивает по цветам обучающую выборку.

Неопределенность Джини (Gini impurity)

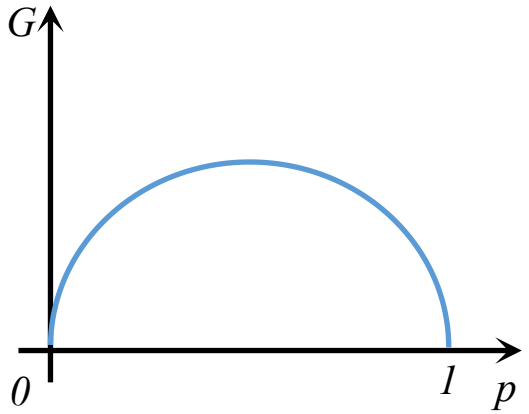
$$G = 1 - \sum_{k=1}^{N} p_k^2 = \sum_{k=1}^{N} p_k \, (1 - p_k \,)$$

Максимизацию этого критерия можно интерпретировать как максимизацию числа пар объектов одного класса, оказавшихся в одном поддереве.

Неопределенность Джини (Gini impurity)

$$G = 1 - \sum_{k=1}^{N} p_k^2 = \sum_{k=1}^{N} p_k (1 - p_k)$$

Максимизацию этого критерия можно интерпретировать как максимизацию числа пар объектов одного класса, оказавшихся в одном поддереве.



Деревья принятия решений

Зададимся некоторым разделением узла на 2 потомка. Тогда увеличение чистоты узлов измеряется как

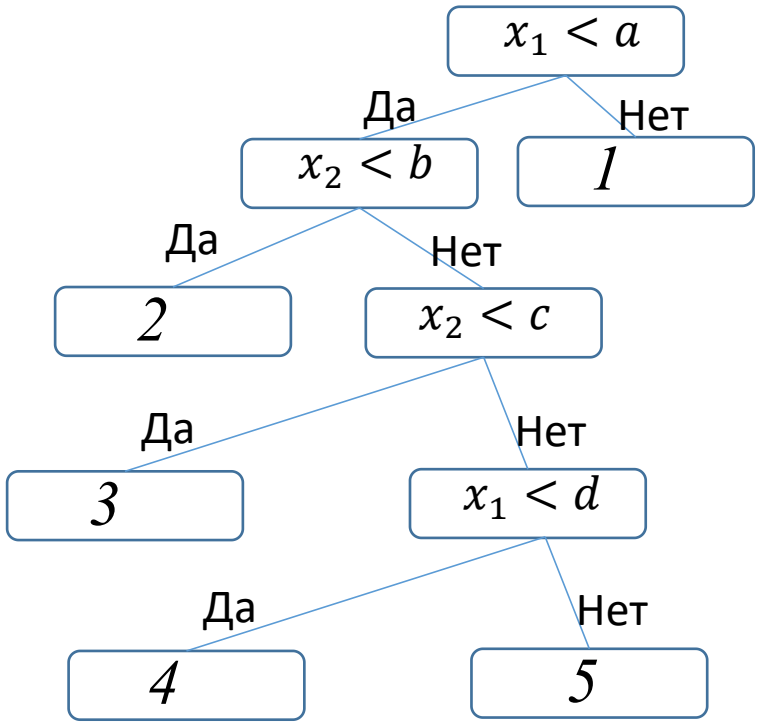
$$\Delta H = H_{\text{родителя}} - \left(\frac{n_{\text{лев}}}{n_{\text{родителя}}} H_{\text{лев}} + \frac{n_{\text{прав}}}{n_{\text{родителя}}} H_{\text{прав}} \right)$$

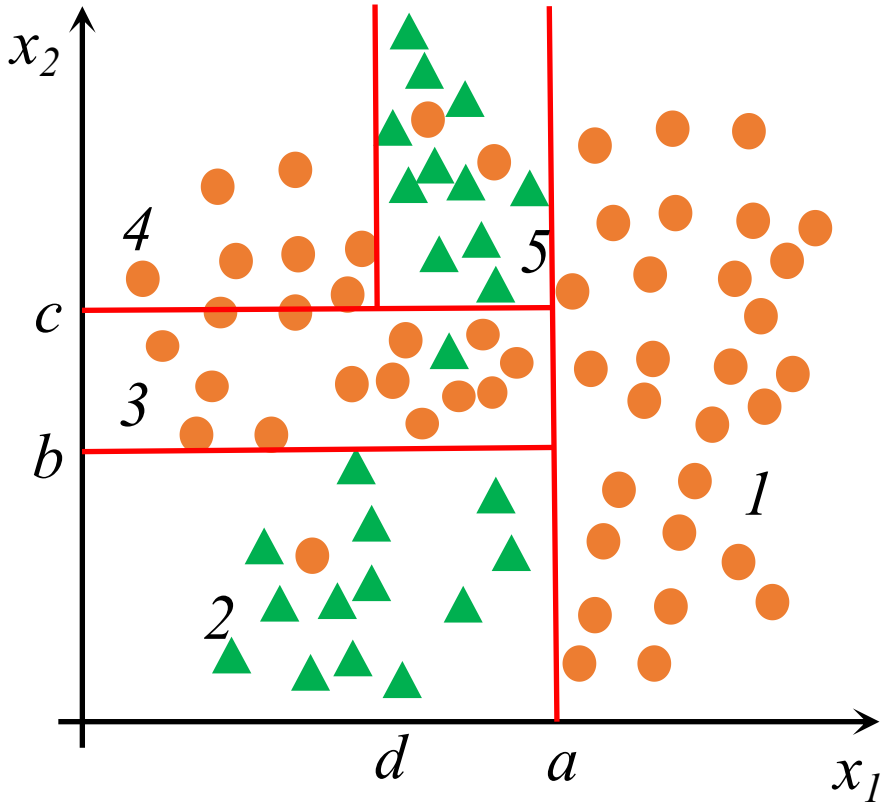
где H – энтропия или неопределенность Джини.

Деревья принятия решений

Правила останова:

1. Если улучшение слишком мало $\Delta H < \varepsilon$.

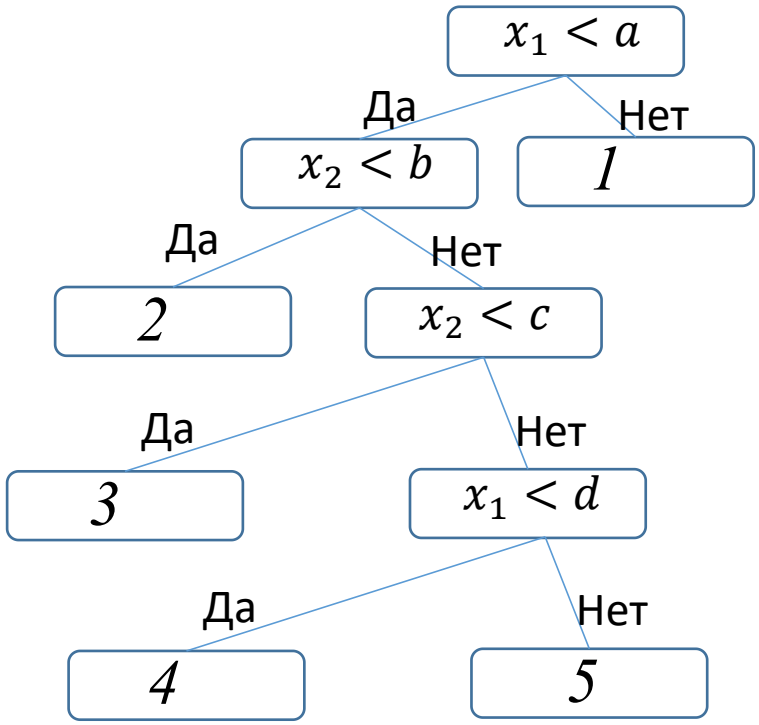


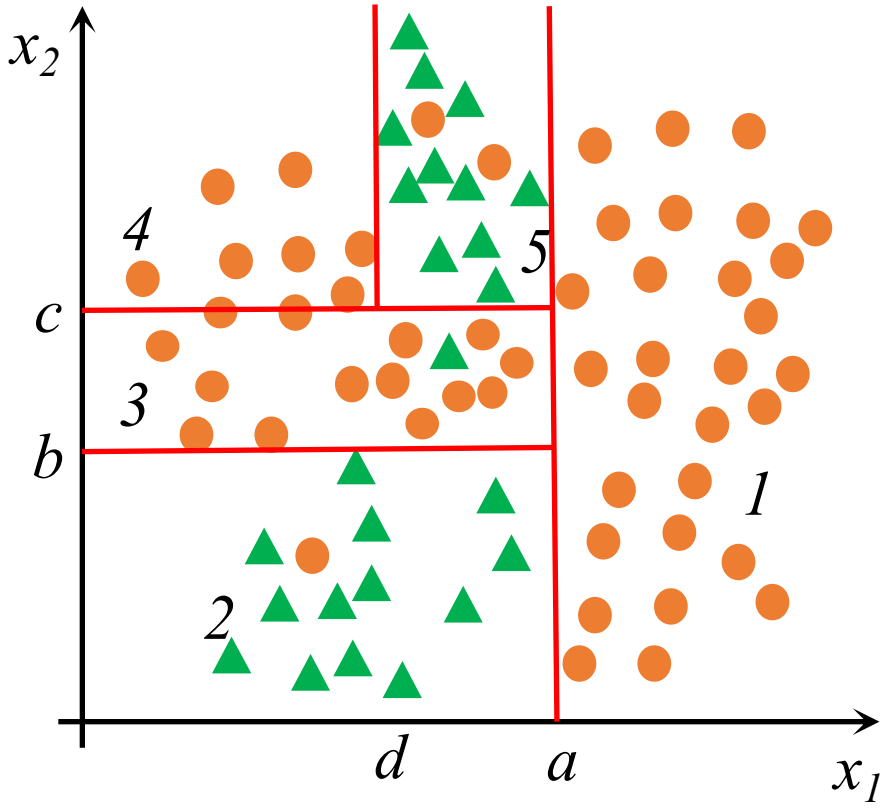


Деревья принятия решений

Правила останова:

1. Если улучшение слишком мало $\Delta H < \varepsilon$.
2. Если число слоев (или узлов) превысило заданное значение.





Что можно настроить, чтобы избежать переобучения

Деревья Решений склонны к переобучению при большом количестве параметров. Поэтому в случае большого числа параметров и относительно небольшой размерности выборки будет ну наверняка переобучение.

Можно предусмотреть использование методов снижения размерности, чтобы у вашего дерева было больше шансов найти отличительные признаки.

Что можно настроить, чтобы избежать переобучения

Деревья Решений склонны к переобучению при большом количестве параметров. Поэтому в случае большого числа параметров и относительно небольшой размерности выборки будет ну наверняка переобучение.

Можно предусмотреть использование методов снижения размерности, чтобы у вашего дерева было больше шансов найти отличительные признаки.

Перед обучением сбалансируйте набор данных, чтобы дерево не смещалось в сторону доминирующих классов.

Балансировка классов может быть выполнена путем выборки равного количества подвыборок для каждого класса или путем нормирования весов для каждого класса.

Что можно настроить, чтобы избежать переобучения

Деревья Решений склонны к переобучению при большом количестве параметров. Поэтому в случае большого числа параметров и относительно небольшой размерности выборки будет ну наверняка переобучение.

Можно предусмотреть использование методов снижения размерности, чтобы у вашего дерева было больше шансов найти отличительные признаки.

Перед обучением сбалансируйте набор данных, чтобы дерево не смещалось в сторону доминирующих классов.

Балансировка классов может быть выполнена путем выборки равного количества подвыборок для каждого класса или путем нормирования весов для каждого класса.

Используйте `max_depth` (максимальное количество разбиений решений в дереве), чтобы контролировать размер дерева для предотвращения переобучения

Ансамбли моделей

В статистике хорошо известно интуитивное соображение, согласно которому усреднение результатов наблюдений может дать более устойчивую и надежную оценку, поскольку ослабляется влияние случайных флуктуаций в отдельном измерении.

Ансамбли моделей

В статистике хорошо известно интуитивное соображение, согласно которому усреднение результатов наблюдений может дать более устойчивую и надежную оценку, поскольку ослабляется влияние случайных флуктуаций в отдельном измерении.

На аналогичной идее было основано развитие алгоритмов комбинирования моделей, в результате чего построение их ансамблей оказалось одним из самых мощных методов машинного обучения, нередко превосходящим по качеству предсказаний другие методы.

Ансамбли моделей

В 1906 году известный британский ученый Френсис Гальтон попал на сельскую ярмарку, на которой в качестве развлечения посетителям предлагалось на глаз оценить вес выставленного на всеобщее обозрение быка и написать эту цифру на специальном билете. За правильные ответы организаторы шоу обещали призы. В результате в голосовании приняли участие около 800 человек — как заядлых фермеров, так и людей, далеких от скотоводческих дел. Собрав после этой ярмарки все билеты для анализа, Гальтон высчитал среднее арифметическое значение для всей выборки — 1197 фунтов. Реальный же вес быка оказался 1198 фунтов. Каким-то непостижимым образом разношерстная публика дала ответ, максимально приближенный к реальному показателю.



Ансамбли моделей

Одним из решений, обеспечивающих необходимое разнообразие моделей, является их повторное обучение на выборках, случайно выбранных из генеральной совокупности, либо иных подмножествах данных, сконструированных из уже имеющихся.

Ансамбли моделей

Одним из решений, обеспечивающих необходимое разнообразие моделей, является их повторное обучение на выборках, случайно выбранных из генеральной совокупности, либо иных подмножествах данных, сконструированных из уже имеющихся.

Для получения устойчивого прогноза частные предсказания этих моделей тем или иным образом комбинируют, например, с помощью простого усреднения или голосования (возможно, взвешенного).

Случайный лес (Random Forest)

Random Forest — это ансамблевый алгоритм машинного обучения, который объединяет предсказания множества независимых решающих деревьев для получения более точного и устойчивого результата. Основная идея заключается в том, что хотя одно дерево может легко переобучиться и давать высокую ошибку, объединение множества разнообразных деревьев («лес») компенсирует ошибки отдельных моделей за счет усреднения ответов.

Случайный лес (Random Forest)

Алгоритм строит ансамбль на основе двух главных принципов рандомизации, которые обеспечивают разнообразие моделей:

1) Бэггинг (**B**ootstrap **Agg**regat**ing**): Для обучения каждого дерева используется не вся выборка целиком, а её случайная подвыборка с возвращением (bootstrap). Это означает, что некоторые объекты могут попасть в обучение несколько раз, а некоторые — ни разу, что делает каждое дерево уникальным по обучающим данным.

Случайный лес (Random Forest)

Алгоритм строит ансамбль на основе двух главных принципов рандомизации, которые обеспечивают разнообразие моделей:

1) Бэггинг (**B**ootstrap **Agg**regat**ing**): Для обучения каждого дерева используется не вся выборка целиком, а её случайная подвыборка с возвращением (bootstrap). Это означает, что некоторые объекты могут попасть в обучение несколько раз, а некоторые — ни разу, что делает каждое дерево уникальным по обучающим данным.

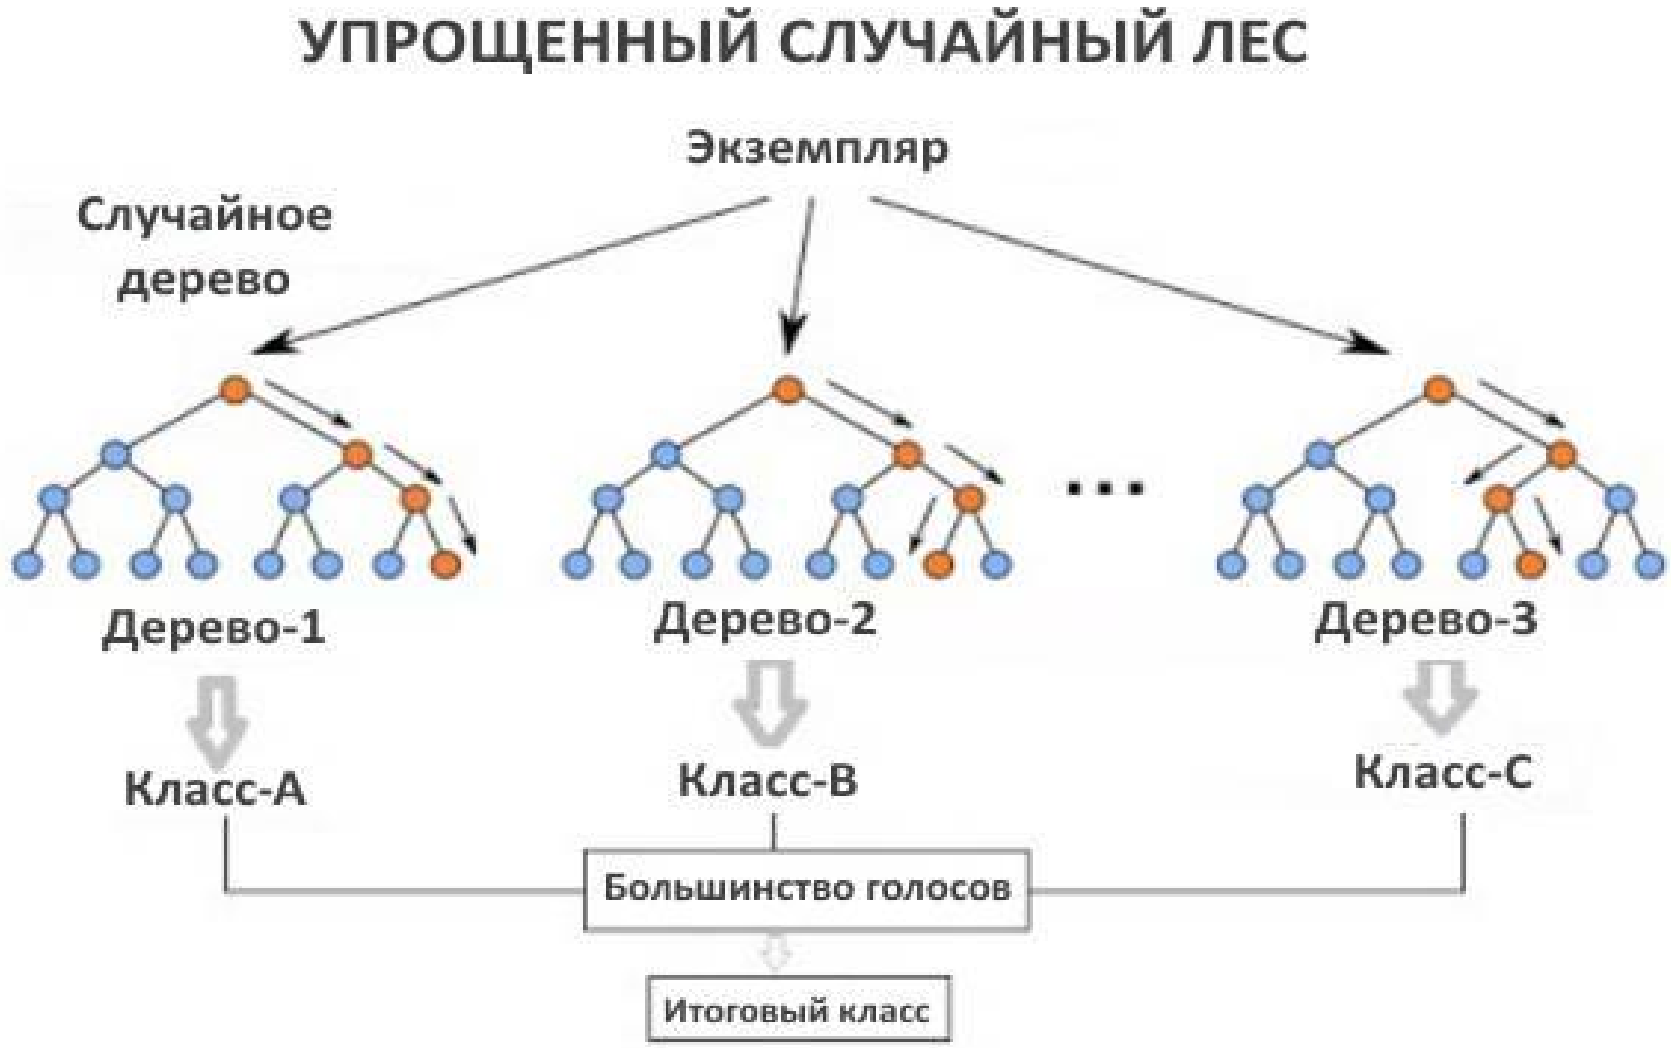
2) Метод случайных подпространств: При построении каждого узла дерева алгоритм выбирает для разделения не все доступные признаки, а лишь случайное их подмножество. Это заставляет деревья искать неочевидные закономерности и снижает корреляцию между ними.

Случайный лес (Random Forest)

Итоговый прогноз формируется путем агрегации результатов всех деревьев в ансамбле:

- Для классификации: используется голосование большинством (Majority Voting). Объект относится к классу, за который проголосовало наибольшее число деревьев.
- Для регрессии: вычисляется среднее арифметическое всех предсказаний отдельных деревьев.

Случайный лес (Random Forest)



Бустинг

Другим методом улучшения предсказаний является бустинг (boosting), идея которого заключается в итеративном процессе последовательного построения частных моделей.

Бустинг

Другим методом улучшения предсказаний является бустинг (boosting), идея которого заключается в итеративном процессе последовательного построения частных моделей.

Бустинг — это ансамблевый метод машинного обучения, который последовательно создает композицию из множества простых моделей (так называемых «слабых» алгоритмов) для построения одной сильной и точной модели. Главная идея заключается в том, что каждая следующая модель в цепочке учится исправлять ошибки, допущенные предыдущими моделями.

Бустинг

Другим методом улучшения предсказаний является бустинг (boosting), идея которого заключается в итеративном процессе последовательного построения частных моделей.

Бустинг — это ансамблевый метод машинного обучения, который последовательно создает композицию из множества простых моделей (так называемых «слабых» алгоритмов) для построения одной сильной и точной модели. Главная идея заключается в том, что каждая следующая модель в цепочке учится исправлять ошибки, допущенные предыдущими моделями.

