ЛАБОРАТОРНАЯ РАБОТА

Логистическая регрессия: прогнозирование оттока клиентов банка

Формат сдачи: Jupyter Notebook (Google Colab)

Цель работы

Освоить применение логистической регрессии для решения задачи бинарной классификации: научиться проводить разведочный анализ данных, выполнять предобработку, обучать модель, получать предсказанные вероятности с помощью predict_proba, оценивать качество модели метриками accuracy, precision, recall, F1 и ROC-AUC, а также интерпретировать результаты в контексте бизнес-задачи.

Датасет

Файл: Churn_Modelling.csv.

Объём: 10 000 записей, 12 столбцов.

Целевая переменная: Exited (0 - клиент остался, 1 - клиент ушёл). Дисбаланс классов умеренный: ~80% / 20%.

Список признаков:

Признак	**Описание**
RowNumber	числовой - номер строки
CustomerId	числовой - ID клиента
CreditScore	числовой - кредитный рейтинг
Gender	бинарный - пол (Female / Male)
Age	числовой - возраст
Tenure	числовой - стаж клиента в банке, лет
Balance	числовой - баланс на счёте
NumOfProducts	числовой - число продуктов банка у клиента
HasCrCard	бинарный 0/1 - наличие кредитной карты
IsActiveMember	бинарный 0/1 - активность клиента
EstimatedSalary	числовой - предполагаемая зарплата

Задания к работе

1. Первичный анализ данных (EDA)

Задание 1. Проведите разведочный аналих данных и проверьте наличие пропусков (isna().sum()).

Задание 2. Постройте распределение целевой переменной Exited с помощью countplot. Оцените баланс классов, выведите доли в процентах. Является ли дисбаланс критическим?

Задание 3. Постройте корреляционную матрицу для числовых признаков. Какие признаки сильнее всего коррелируют с Exited?

Задание 4. Постройте boxplot для признаков Age, Balance, CreditScore в разрезе классов Exited. Какие закономерности вы видите?

2. Предобработка данных

Задание 5. Закодируйте бинарный признак Gender значениями 0 и 1.

Задание 6. Стандартизируйте признаки с помощью StandardScaler.

Задание 7. Разделите данные на обучающую и тестовую выборки в пропорции 80/20. Убедитесь, что баланс классов сохранился в обеих выборках.

3. Обучение модели логистической регрессии

Задание 8. Обучите LogisticRegression с параметрами по умолчанию (без подбора гиперпараметров) и выведите коэффициенты модели в виде таблицы, отсортированной по убыванию абсолютного значения. Какие признаки увеличивают вероятность оттока, а какие - уменьшают?

4. Предсказание вероятностей с помощью predict_proba

Ключевая особенность логистической регрессии: модель выдаёт не класс, а вероятность принадлежности к положительному классу. Именно вероятности позволяют строить ROC-кривую, выбирать порог классификации под конкретную задачу и ранжировать клиентов по степени риска.

Задание 9. Получите вероятности оттока для тестовой выборки с помощью model.predict_proba(). Метод возвращает массив из двух столбцов - [P(класс 0), P(класс 1)]. Возьмите второй столбец (вероятность класса «Ушёл»). Выведите размер массива вероятностей, минимум, максимум и среднее значение.

Задание 10. Покажите связь между predict() и predict_proba(). Постройте таблицу для первых 20 клиентов тестовой выборки: истинный класс| предсказанная вероятность| класс, выдаваемый predict().

Задание 11. Постройте на одной координатной плоскости гистограмму распределения предсказанных вероятностей отдельно для клиентов, которые остались (y_test == 0), и для тех, кто ушёл (y_test == 1). Отметьте вертикальной линией порог 0.5. Как вы думаете, почему у

большинства ушедших клиентов вероятность оттока оказалась ниже 0.5? Удачен ли порог принятия решения о принадлежности к классу = 0.5 для решаемой задачи?

5. Оценка качества модели

Задание 12. Постройте матрицу ошибок (confusion_matrix) и визуализируйте её с помощью heatmap. Вычислите TP, TN, FP, FN.

Задание 13. Рассчитайте метрики accuracy, precision, recall, F1 и выведите classification_report.

Задание 14. Оцените, какую accuracy дала бы «наивная» модель, которая всегда предсказывает самый частый класс (Exited = 0). Для этого:

- Создайте массив предсказаний, состоящий из одних нулей (длина как у y_test).
- Вычислите для него accuracy, precision и recall по классу «Ушёл».
- Сравните с метриками обученной модели.

Случайно ли значение accuracy обученной модели лишь немного превышает baseline?

6. ROC-кривая и AUC-ROC

Задание 15. Постройте ROC-кривую и вычислите AUC-ROC. Как интерпретировать полученное значение? Хорошая ли это модель по шкале AUC?

7. Интерпретация и выводы

Задание 16. Ответьте на вопросы:

- Какие признаки сильнее всего увеличивают вероятность оттока?
- Какие признаки её уменьшают?
- Почему accuracy в данной задаче не является надёжной метрикой?
- Какая метрика наиболее важна в задаче прогнозирования оттока клиентов? Обоснуйте ответ.
- Почему при пороге по умолчанию (0.5) recall по классу «Ушёл» такой низкий? Сошлитесь в ответе на построенную ранее гистограмму.

Задание 17. На основе коэффициентов модели сформулируйте несколько бизнес-рекомендаций для банка.

8. Отбор признаков

В модели несколько признаков. Некоторые из них могут вносить малый вклад в предсказание. Проверим, что произойдёт, если последовательно удалять признаки с наименьшими по модулю коэффициентами.

Задание 18. Удалите три признака с наименьшими по модулю коэффициентами и обучите модель заново на оставшихся признаках. Сравните метрики с исходной моделью.

Задание 19. Ответьте на вопросы:

- Оправдано ли удаление этих трёх признаков с точки зрения качества модели?

- Какие преимущества даёт модель с меньшим числом признаков (упрощение, скорость, интерпретируемость)?
- Есть ли риски при удалении признаков, если обучающая выборка маленькая?

9. Влияние масштабирования

Мы стандартизировали признаки с помощью StandardScaler. Посмотрим, что произойдёт, если не масштабировать данные.

Задание 20. Обучите LogisticRegression на исходных (немасштабированных) данных и сравните метрики (accuracy, precision, recall, F1, ROC-AUC) с масштабированной моделью. Сравните коэффициенты двух моделей - масштабированной и немасштабированной. Обратите внимание: качество могло почти не измениться, но коэффициенты выглядят совершенно по-разному. Какой вывод можно сделать об интерпретируемости коэффициентов логистической регрессии при разном масштабе признаков?

Задание 21. Ответьте на вопросы:

- Почему без масштабирования мы не можем сравнивать коэффициенты по абсолютной величине?
- Почему при этом качество модели может почти не страдать?
- Какой практический вывод: нужно ли всегда масштабировать данные перед логистической регрессией?

Требования к отчёту

Отчёт оформляется в виде Jupyter-блокнота (Google Colab). Блокнот должен содержать:

- Код с комментариями по каждому заданию.
- Все запрошенные визуализации с подписями осей и заголовками.
- Числовые результаты метрик (вывод на экран).
- Развёрнутые письменные ответы на вопросы.
- Итоговый вывод по работе (5–7 предложений): какую задачу решали, какая модель получилась, что показали метрики, какие рекомендации можно дать бизнесу, какие ограничения у модели.