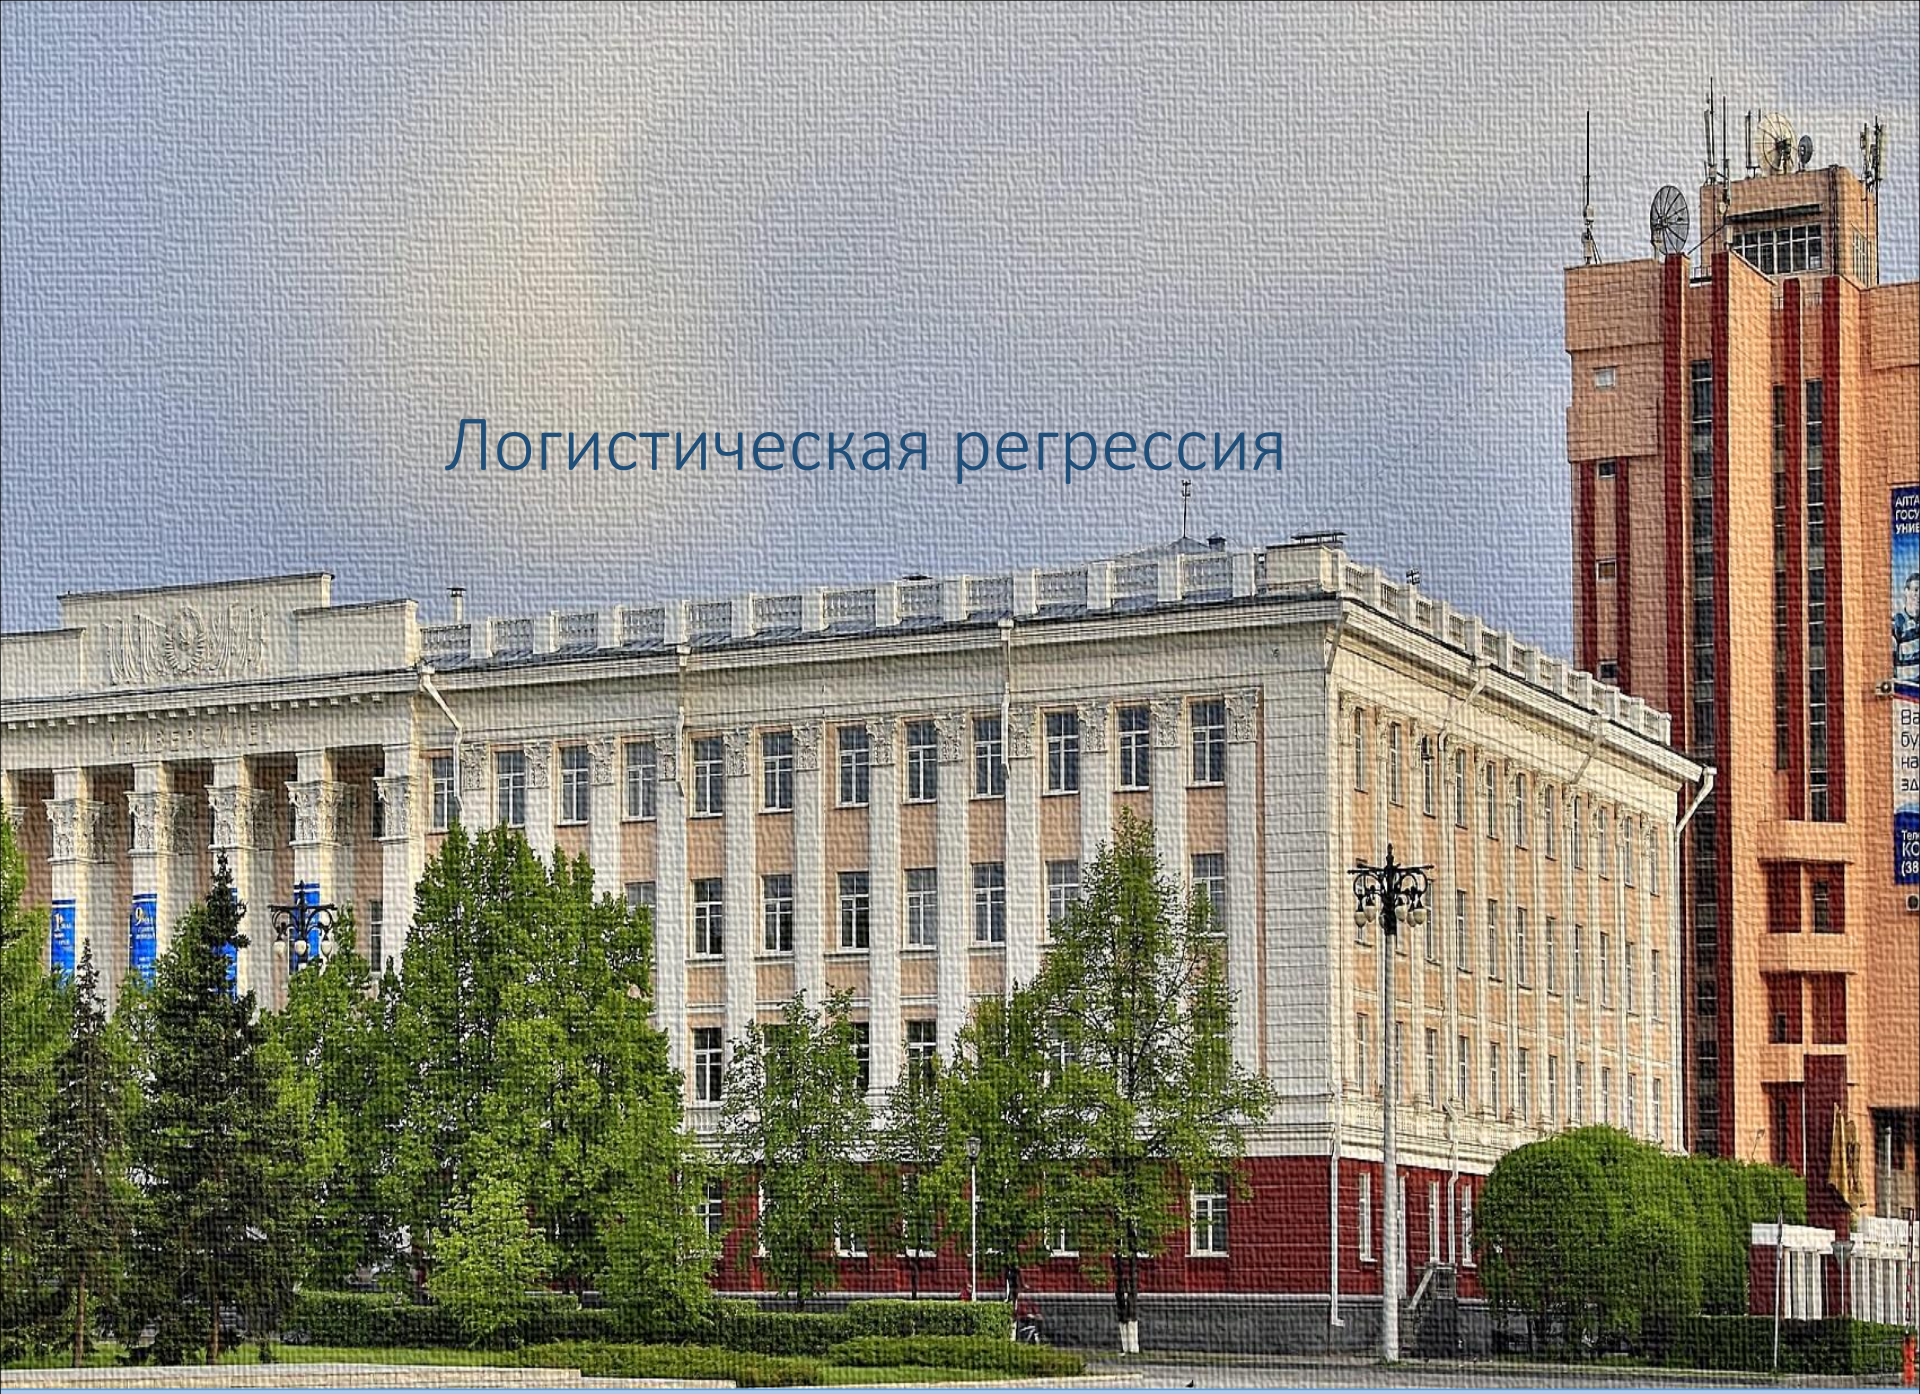
Логистическая регрессия



Козлов Денис Юрьевич, к.ф.-м.н, доцент АлтГУ, Барнаул

План

1. Задача бинарной классификации
2. Логистическая регрессия
3. Оценка качества построенных моделей логистической регрессии

Бинарная классификация

Задача бинарной классификации

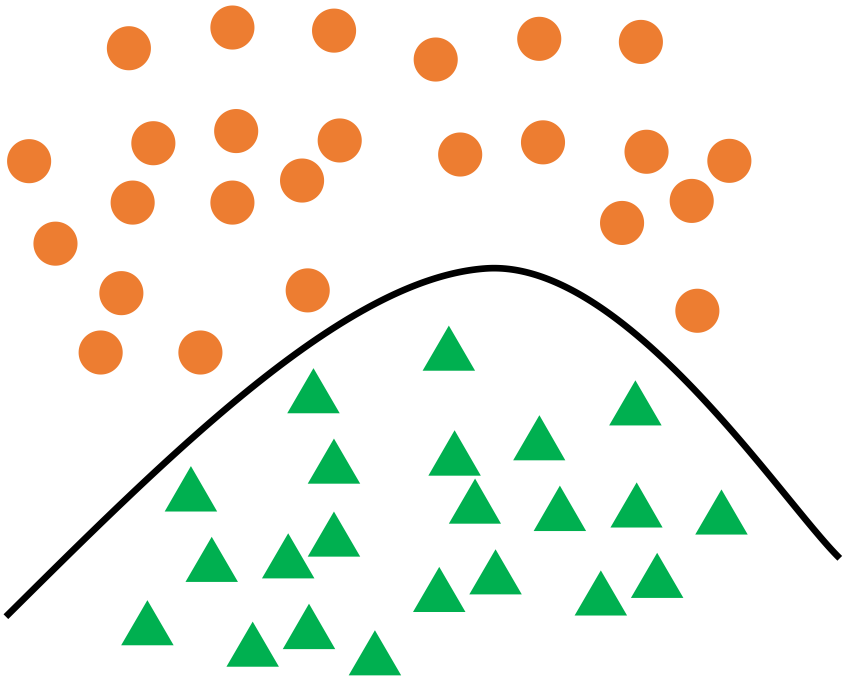
Есть два класса, требуется по известному набору признаков отнести объект к одному из этих классов:

1) болен или здоров пациент по значениям диагностических параметров;
2) вернет ли заемщик кредит;
3) закончит ли школьник школу с медалью и т.п.

Задача бинарной классификации

Есть два класса, требуется по известному набору признаков отнести объект к одному из этих классов:

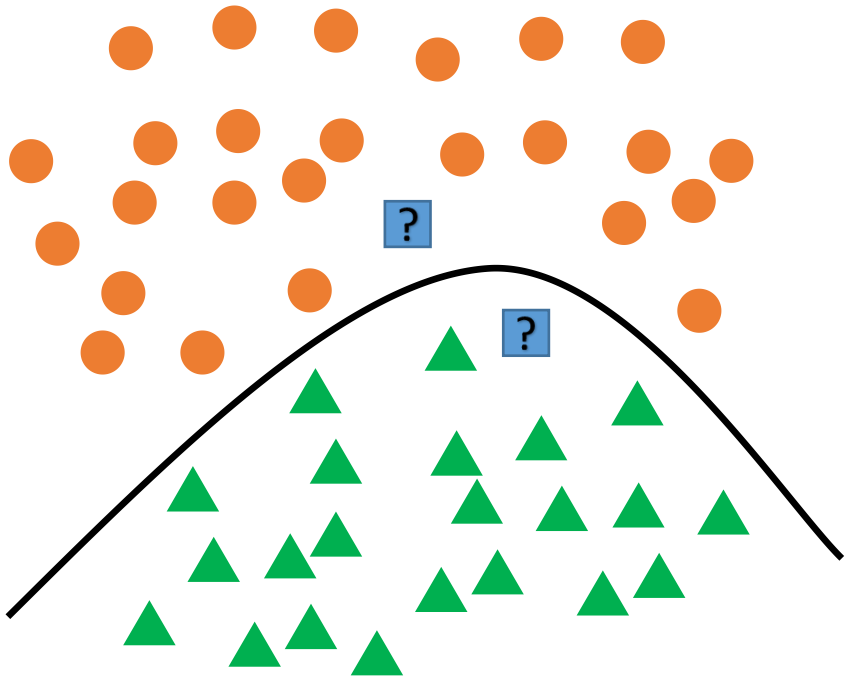
1) болен или здоров пациент по значениям диагностических параметров;
2) вернет ли заемщик кредит;
3) закончит ли школьник школу с медалью и т.п.



Задача бинарной классификации

Есть два класса, требуется по известному набору признаков отнести объект к одному из этих классов:

1) болен или здоров пациент по значениям диагностических параметров;
2) вернет ли заемщик кредит;
3) закончит ли школьник школу с медалью и т.п.



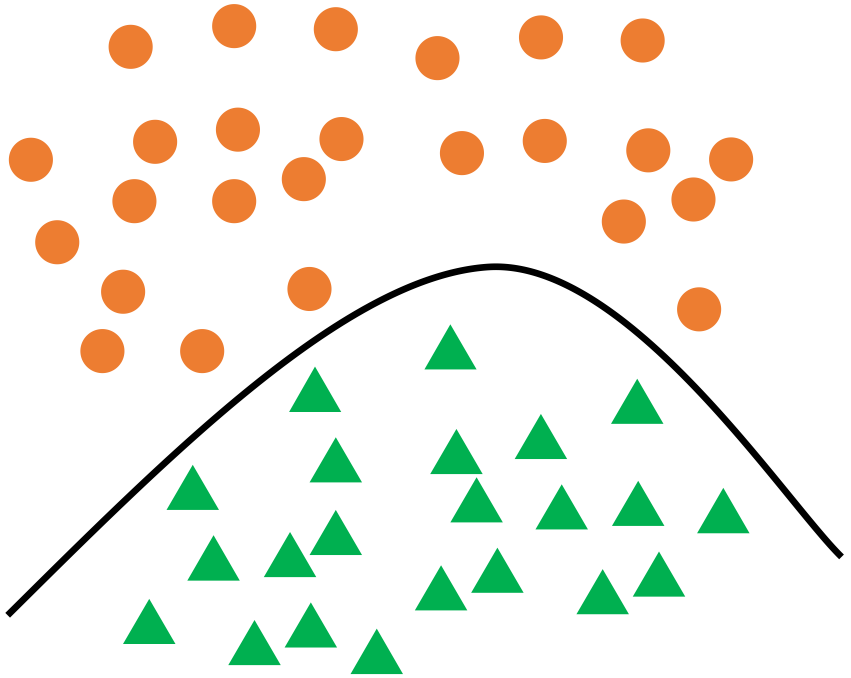
Логистическая регрессия

Логистическая регрессия

Логистическая регрессия – в некотором смысле, обобщенная линейная регрессия, применимая для категориальной (факторной, номинативной) выходной переменной. Входными переменными могут быть как количественные, так и категориальные переменные.

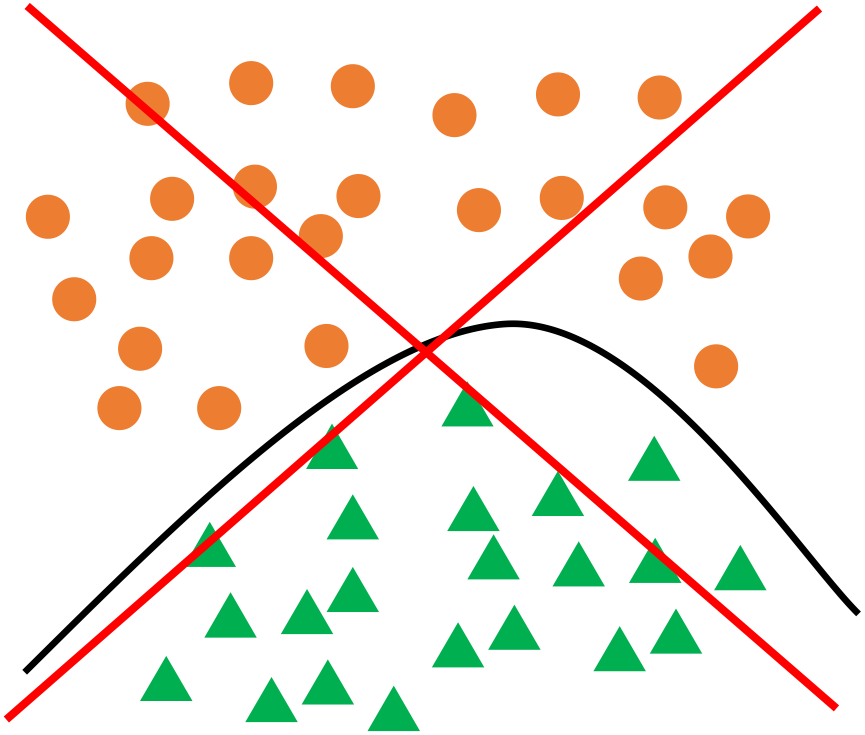
Логистическая регрессия

Логистическая регрессия – в некотором смысле, обобщенная линейная регрессия, применимая для категориальной (факторной, номинативной) выходной переменной. Входными переменными могут быть как количественные, так и категориальные переменные.



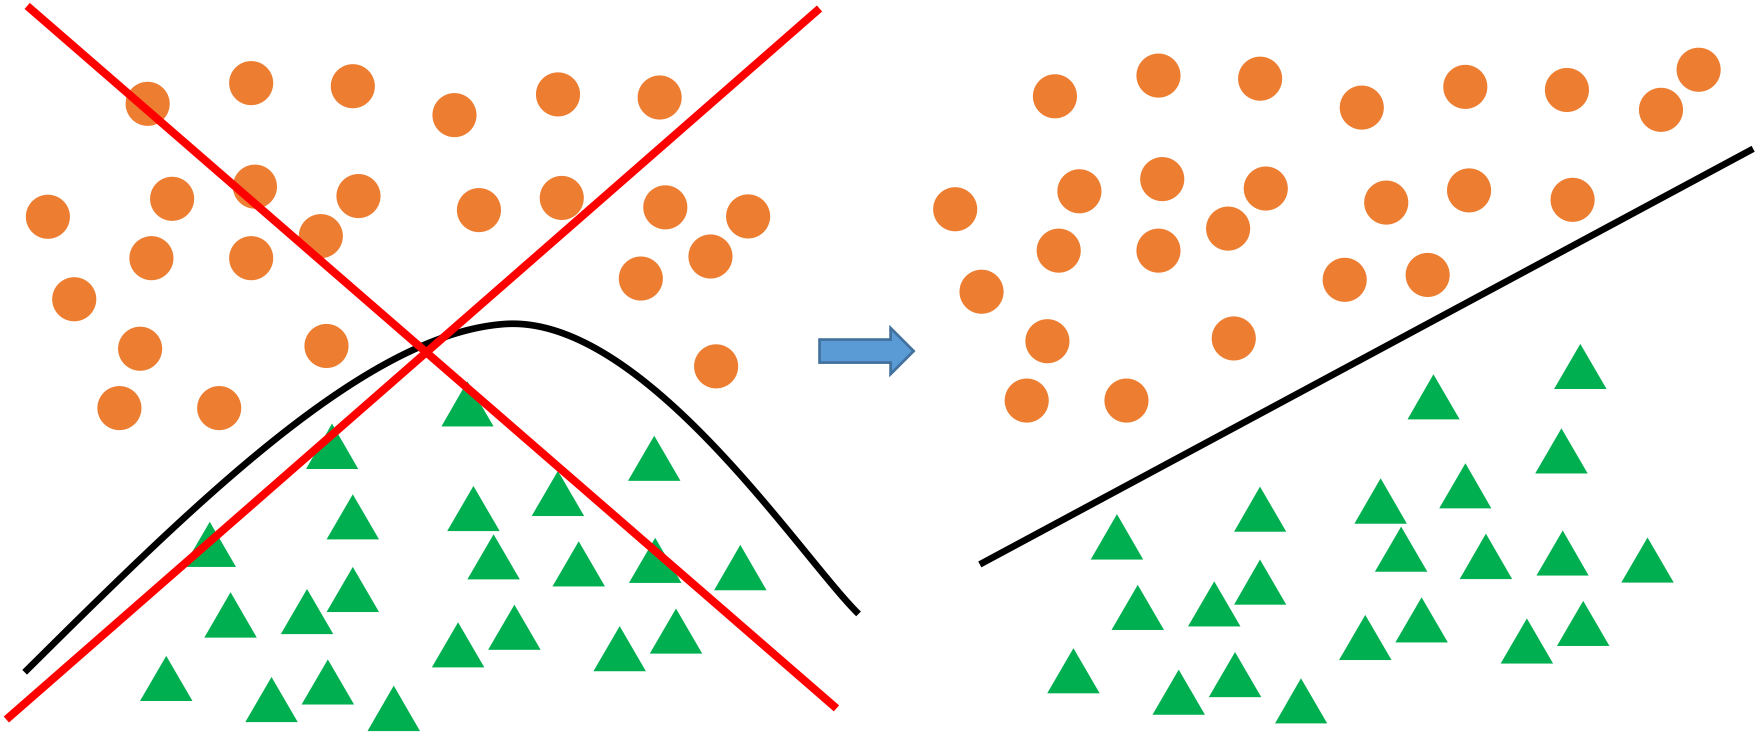
Логистическая регрессия

Логистическая регрессия – в некотором смысле, обобщенная линейная регрессия, применимая для категориальной (факторной, номинативной) выходной переменной. Входными переменными могут быть как количественные, так и категориальные переменные.



Логистическая регрессия

Логистическая регрессия – в некотором смысле, обобщенная линейная регрессия, применимая для категориальной (факторной, номинативной) выходной переменной. Входными переменными могут быть как количественные, так и категориальные переменные.



Логистическая регрессия

$$p(x_1, x_2, \dots, x_n) \stackrel{?}{=} a_0 + a_1 x_1 + a_2 x_2 + \cdots + a_n x_n$$

- вероятность.

$$o(x) = \frac{p(x)}{1 - p(x)}$$

- шансы.

Логистическая регрессия

Возраст, лет	Заболевание
25	0
29	0
30	0
31	0
32	0
41	0
41	0
42	0
44	1
49	1
50	0
59	1
60	0
62	0
68	1
72	0
79	1
80	0
81	1
84	1

Предположим (пример взят из книги *Паклин Н.Б., Орешков В.И. Бизнес-аналитика от данных к знаниям – СПб.: Питер, 2013.*), у нас имеется выборка, отражающая наличие некоторой болезни в зависимости от возраста человека:

- 0 – заболевание отсутствует;
- 1 – присутствует.

Логистическая регрессия

Подробней разберем понятие «шансы»на этом примере. Шансы – это отношение вероятностей того, что событие произошло $p(x)$, к вероятности того, что оно не произошло $1 - p(x)$.

Логистическая регрессия

Подробней разберем понятие «шансы»на этом примере. Шансы – это отношение вероятностей того, что событие произошло $p(x)$, к вероятности того, что оно не произошло $1 - p(x)$.

$$o(x) = \frac{p(x)}{1-p(x)}$$

- шансы.

Логистическая регрессия

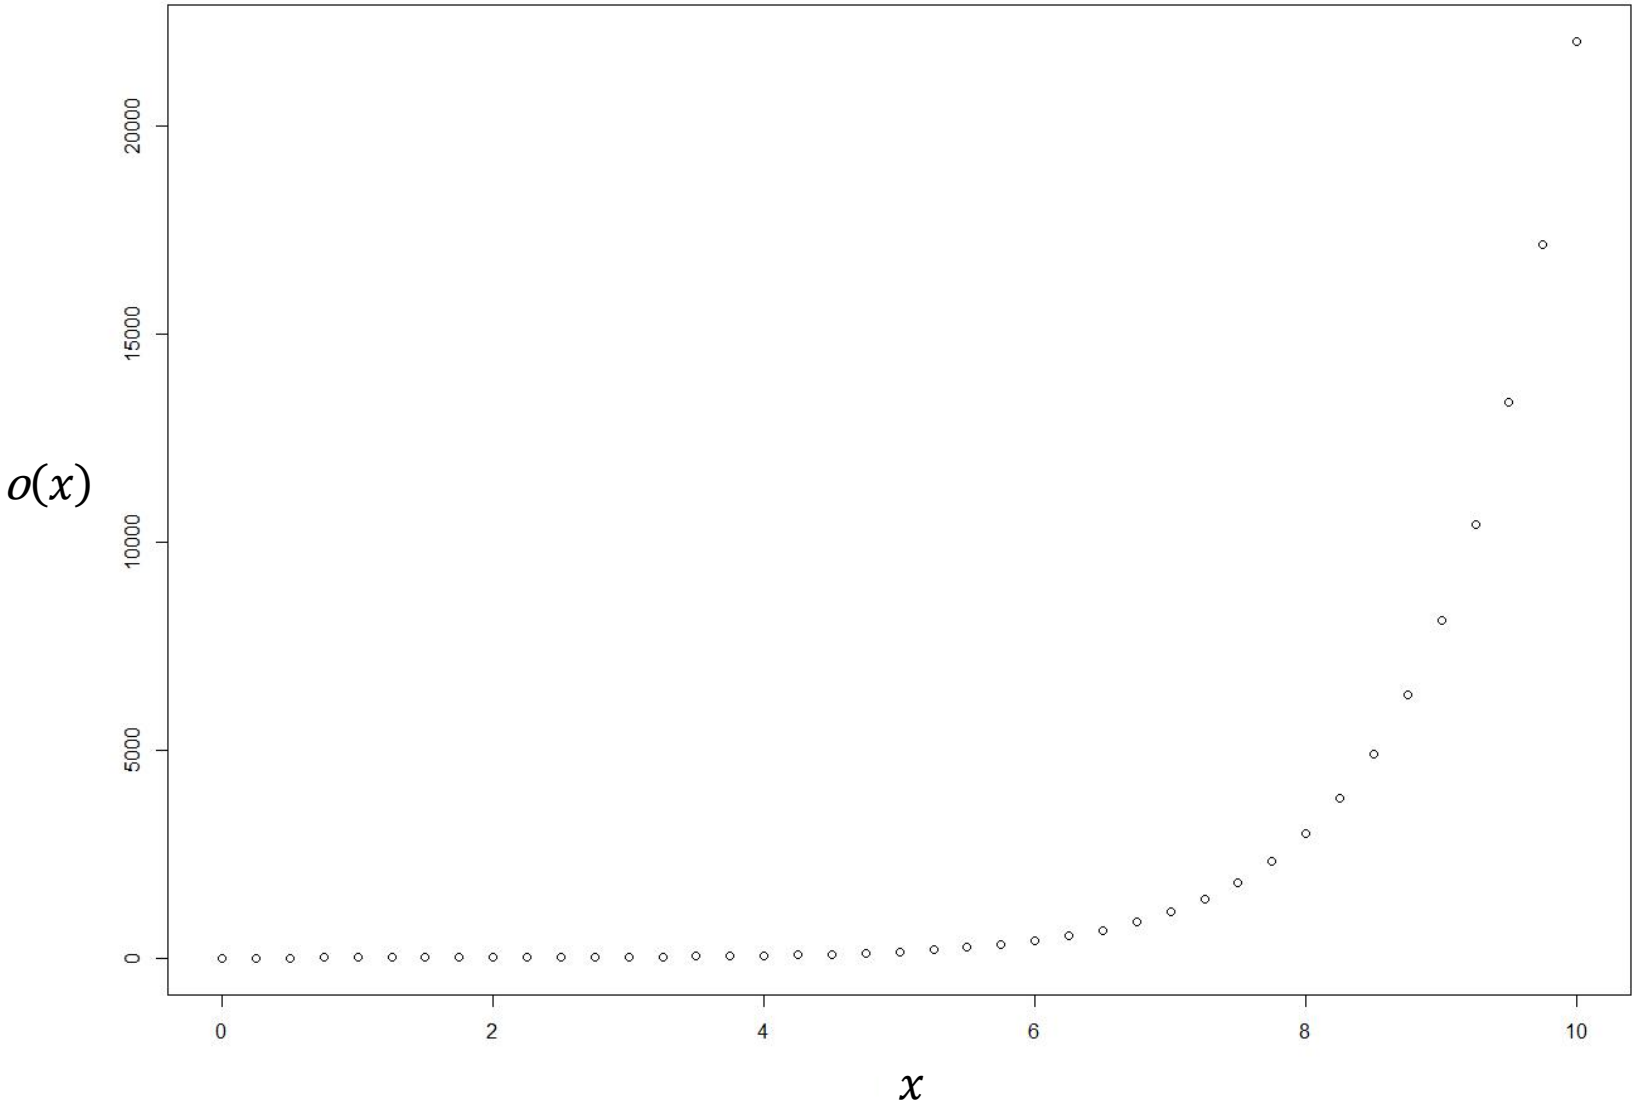
Подробней разберем понятие «шансы»на этом примере. Шансы – это отношение вероятностей того, что событие произошло $p(x)$, к вероятности того, что оно не произошло $1 - p(x)$.

$$o(x) = \frac{p(x)}{1-p(x)}$$

- шансы.

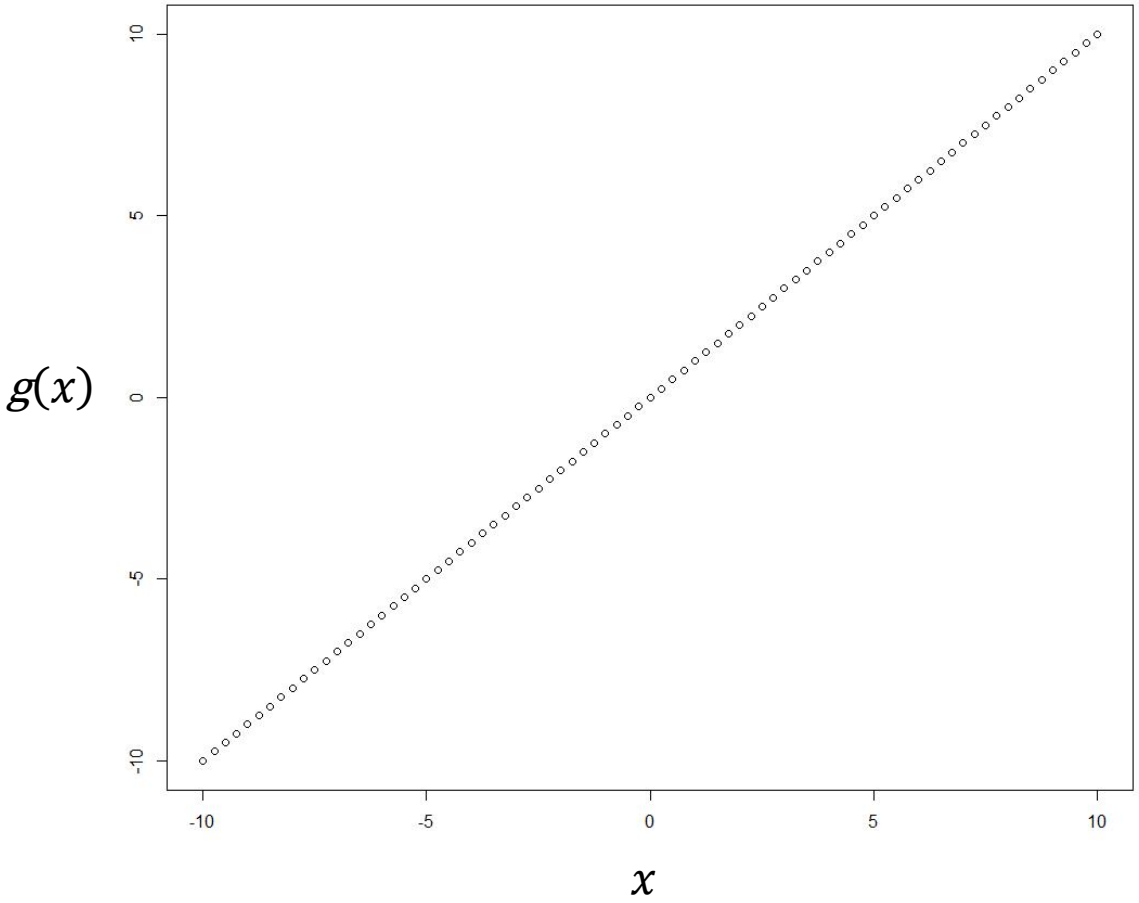
Допустим, вероятность заболевания какого-то человека – 0,2. Значит, шансы заболевания для него 0,25. А для какого-то другого человека вероятность заболевания – 0,6. Значит, шансы заболевания для него уже 1,5.

Логистическая регрессия



Логистическая регрессия

$$g(x) = \ln o(x) = \ln \frac{p(x)}{1-p(x)}$$ - логит-преобразование.



Логистическая регрессия

$$p(x_1, x_2, \ldots, x_n) \stackrel{?}{=} a_0 + a_1 x_1 + a_2 x_2 + \ldots + a_n x_n$$

Логистическая регрессия

$$p(x_1, x_2, \ldots, x_n) \stackrel{?}{=} a_0 + a_1 x_1 + a_2 x_2 + \ldots + a_n x_n$$

$$g(x) = \ln o(x) = \ln \frac{p(x)}{1-p(x)} = a_0 + a_1 x_1 + a_2 x_2 + \ldots + a_n x_n$$

Логистическая регрессия

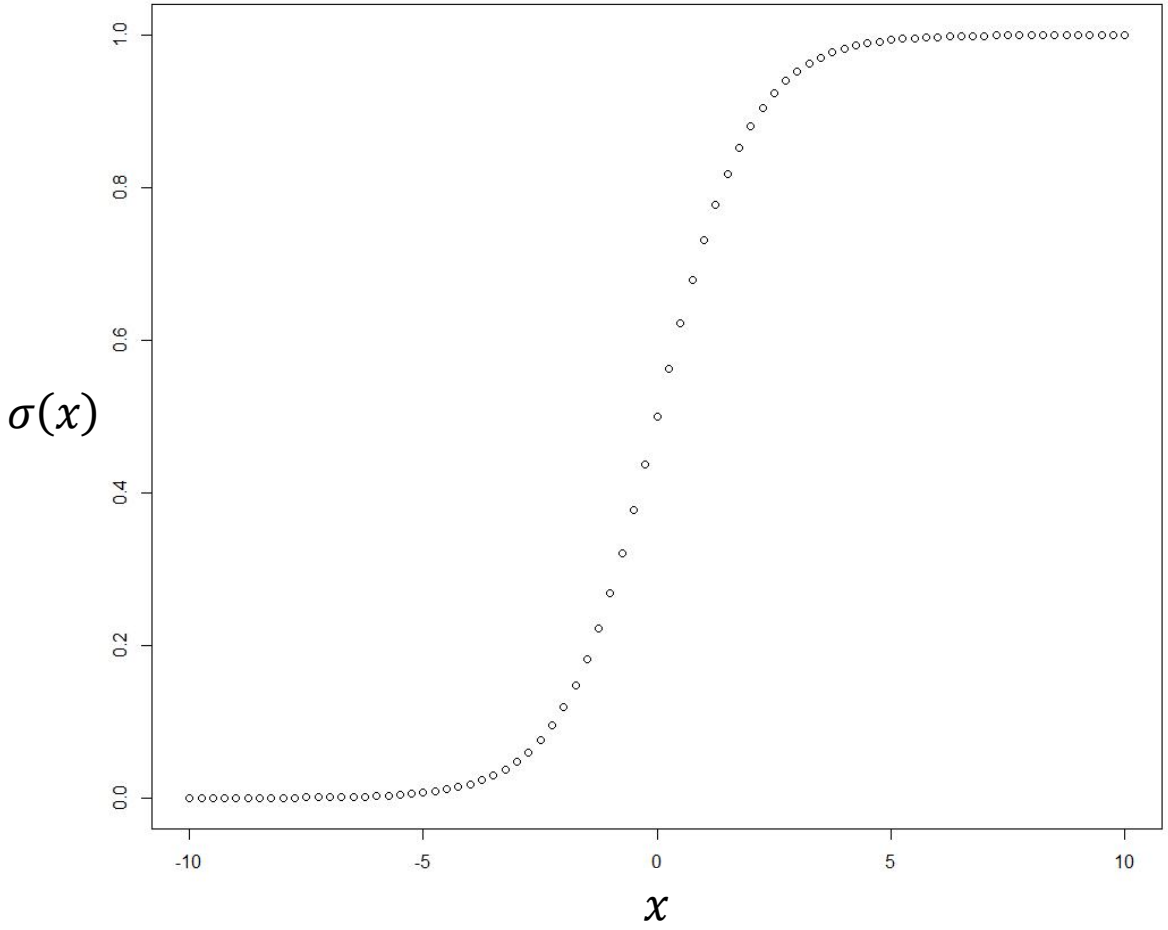
$$p(x_1, x_2, \ldots, x_n) \stackrel{?}{=} a_0 + a_1 x_1 + a_2 x_2 + \ldots + a_n x_n$$

$$g(x) = \ln o(x) = \ln \frac{p(x)}{1-p(x)} = a_0 + a_1 x_1 + a_2 x_2 + \ldots + a_n x_n$$

$$g(x) = \ln \frac{p(x)}{1-p(x)} \quad \Rightarrow \quad p(x) = \frac{e^{g(x)}}{1 + e^{g(x)}} = \frac{1}{1 + e^{-g(x)}}$$ - сигмоида.

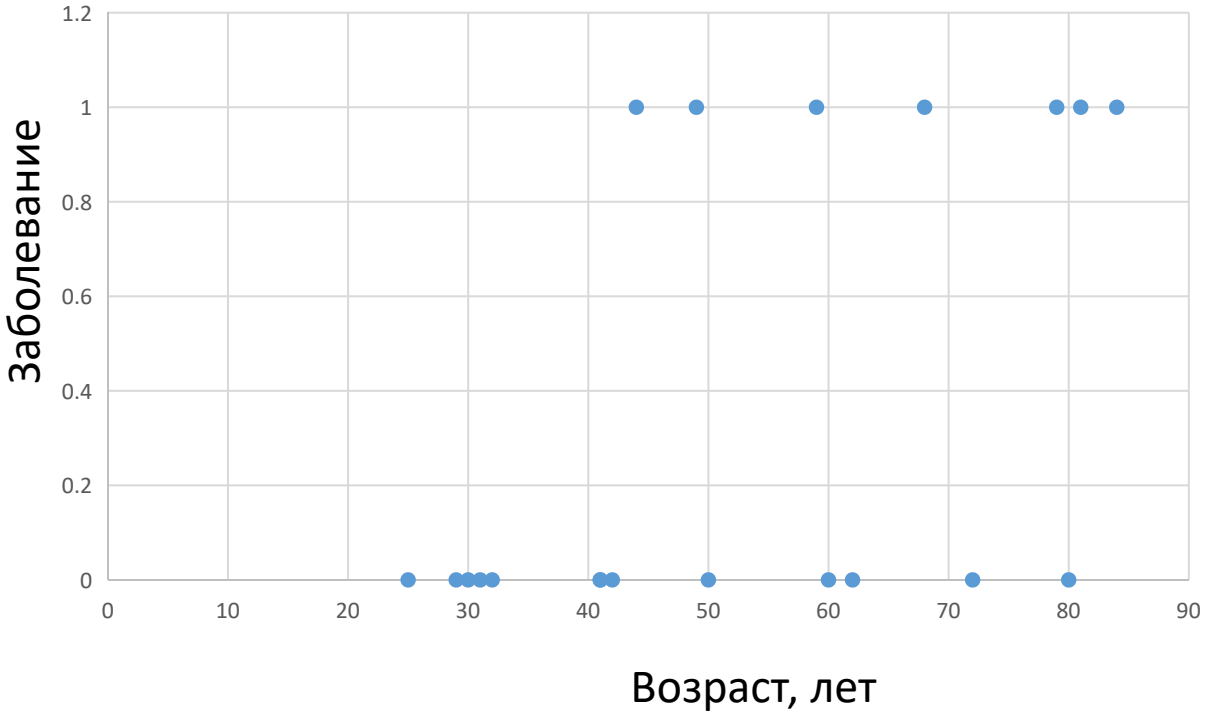
Логистическая регрессия

$$\sigma(x) = \frac{e^x}{1 + e^x} = \frac{1}{1 + e^{-x}}$$ - сигмоида.



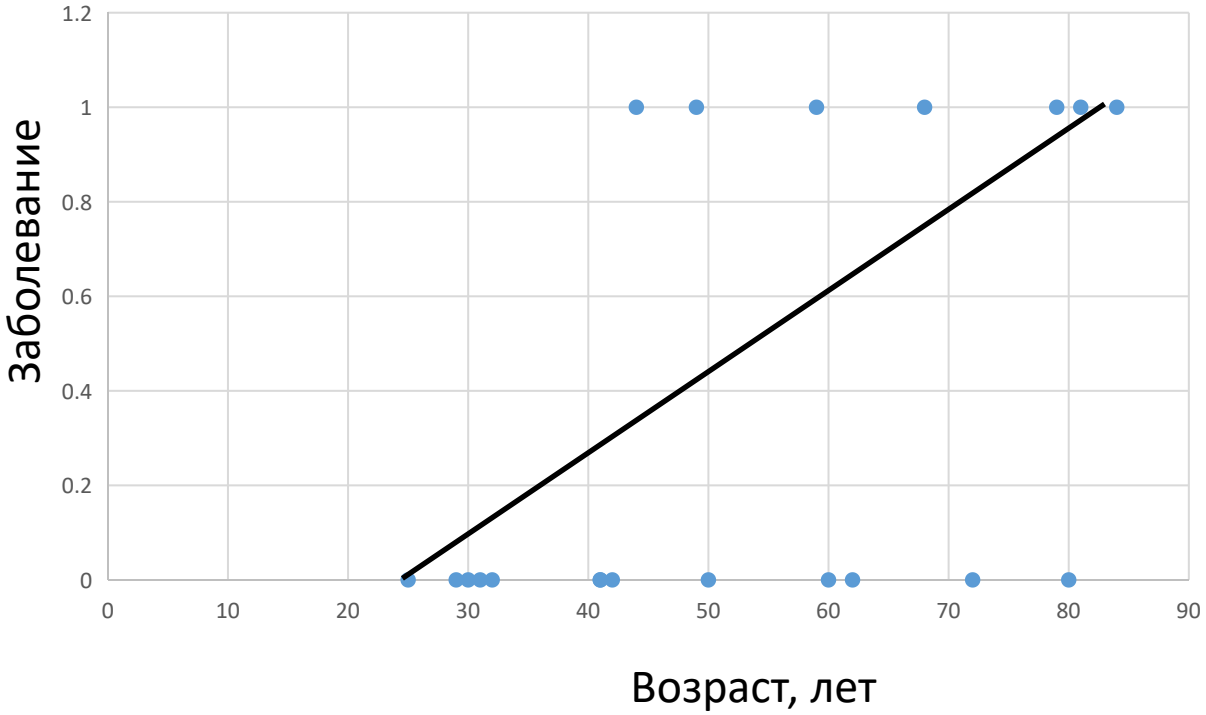
Логистическая регрессия

Возраст, лет	Заболевание
25	0
29	0
30	0
31	0
32	0
41	0
41	0
42	0
44	1
49	1
50	0
59	1
60	0
62	0
68	1
72	0
79	1
80	0
81	1
84	1



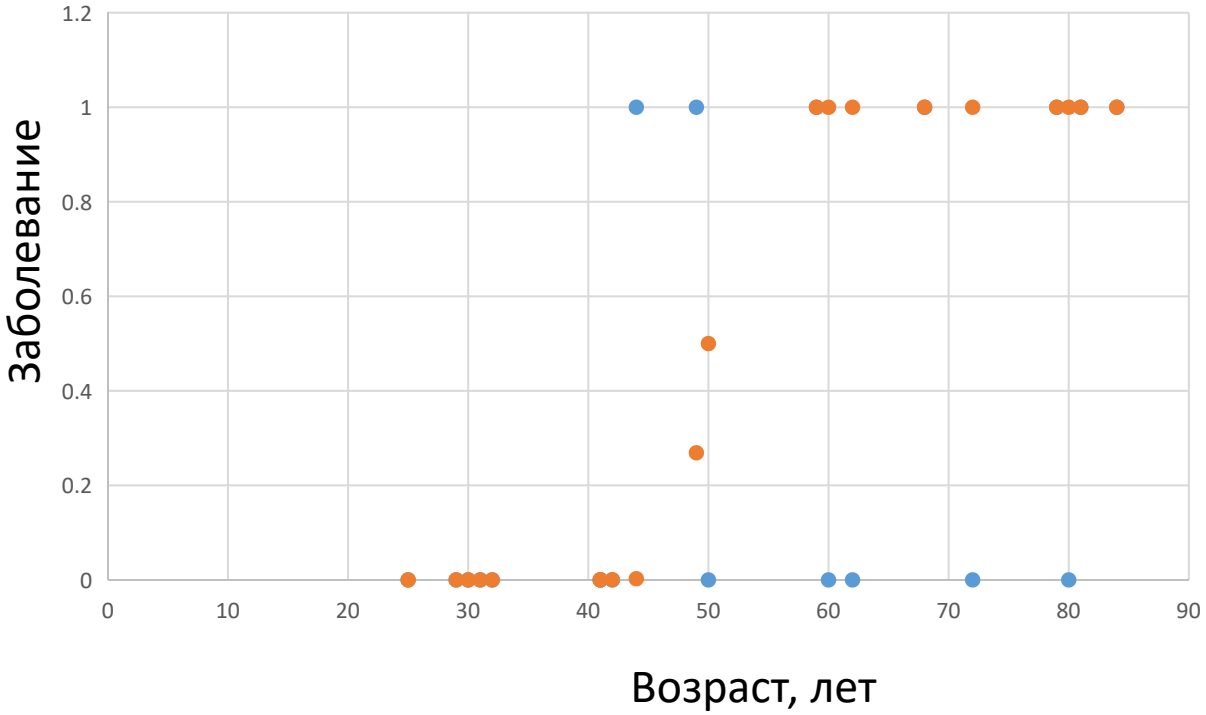
Логистическая регрессия

Возраст, лет	Заболевание
25	0
29	0
30	0
31	0
32	0
41	0
41	0
42	0
44	1
49	1
50	0
59	1
60	0
62	0
68	1
72	0
79	1
80	0
81	1
84	1



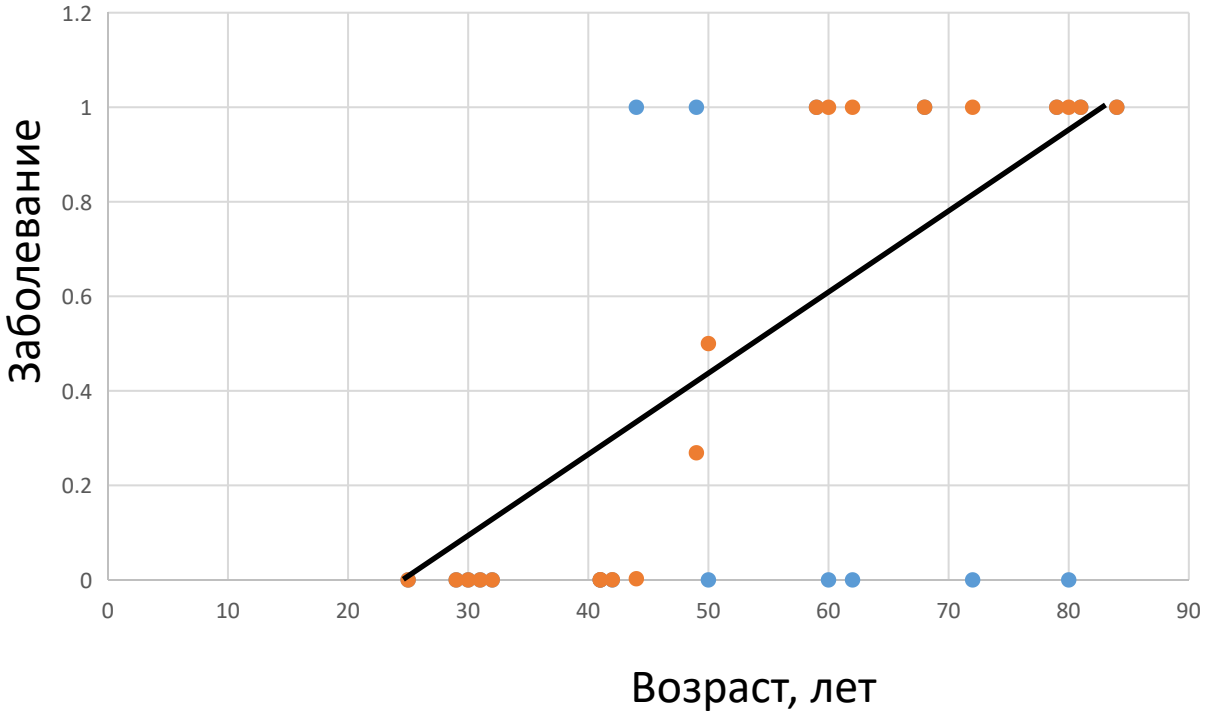
Логистическая регрессия

Возраст, лет	Заболевание
25	0
29	0
30	0
31	0
32	0
41	0
41	0
42	0
44	1
49	1
50	0
59	1
60	0
62	0
68	1
72	0
79	1
80	0
81	1
84	1



Логистическая регрессия

Возраст, лет	Заболевание
25	0
29	0
30	0
31	0
32	0
41	0
41	0
42	0
44	1
49	1
50	0
59	1
60	0
62	0
68	1
72	0
79	1
80	0
81	1
84	1



Пример использования логистической регрессии

Пример использования логистической регрессии

Рассмотрим следующий пример (см.приложенный к лекции colab-ноутбук), посвященный диагностике диабета у женщин (набор данных взят из UCI machine learning repository). Выборка содержит 768 записей со следующими полями:

1. Число случаев беременности;
2. Концентрация глюкозы;
3. Артериальное диастолическое давление, мм. рт. ст.;
4. Толщина кожной складки трехглавой мышцы, мм.;
5. 2-х часовой сывороточный инсулин;
6. Индекс массы тела;
7. Числовой параметр наследственности диабета;
8. Возраст, лет;
9. Зависимая переменная (1 – наличие заболевания, 0 – отсутствие).

Распределение зависимой переменной следующее: 500 случаев отсутствия заболевания, 268 – его наличие.

Оценка качества построенных моделей логистической регрессии

Оценка качества построенных моделей логистической регрессии

Существуют разные способы сравнения регрессионных моделей, например, дисперсионный анализ или ANOVA (от англ. ANalysis Of VAriance).

Метрики качества. Задача классификации

Метрики качества классификации. Пример

Банк выбрал 100 человек.

90 - отказались от услуг банка

10 - остались клиентами

Нужно обучить алгоритм, который предсказывает класс клиента:

0 - ушедший клиент, 1 - оставшийся

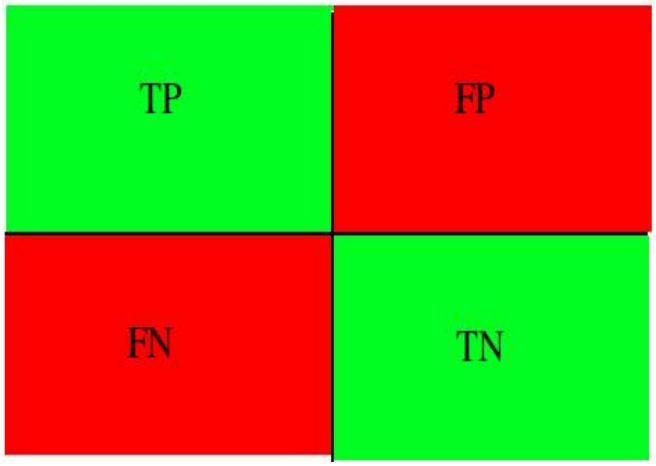
Метрики качества классификации

TP — это количество верно классифицированных меток положительного класса

TN — это количество верно классифицированных меток отрицательного класса

FP — это количество неверно классифицированных меток положительного класса

FN — это количество неверно классифицированных меток отрицательного класса



- confusion matrix (матрица ошибок)

Метрики качества классификации. Пример. Точность

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

TP — это количество верно классифицированных меток положительного класса

TN — это количество верно классифицированных меток отрицательного класса

FP — это количество неверно классифицированных меток положительного класса

FN — это количество неверно классифицированных меток отрицательного класса

Метрики качества классификации. Пример. Точность

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Accuracy — может быть интерпретируема как доля правильных ответов алгоритма, она интуитивно понятная, очевидная и почти неиспользуемая метрика. Эта метрика бесполезна в задачах с неравными классами.

Метрики качества классификации. Пример. Точность

Банк выбрал 100 человек.

90 - отказались от услуг банка

10 - остались клиентами

Нужно обучить алгоритм, который предсказывает класс клиента:

0 - ушедший клиент, 1 - оставшийся

Пусть алгоритм предсказал, что все 100 человек - ушедшие клиенты (класс 0)

Тогда:

TP = 0, TN = 90

FP = 0, FN = 10

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

accuracy = (90+0)/(0+90+0+10) = 0.9 = 90%

Метрики качества классификации. Пример. Точность №2

Несмотря на различные английские названия и разные формулы подсчета, русский перевод этой метрики также закрепился как «точность», что может вызвать недоумение, поэтому следует уточнять, о чем именно вы говорите. Эта точность показывает количество истинно положительных исходов из всего набора положительных меток и считается по следующей формуле

$$precision = \frac{TP}{TP + FP}$$

Метрики качества классификации. Пример. Точность №2

Банк выбрал 100 человек.

90 - отказались от услуг банка

10 - остались клиентами

Нужно обучить алгоритм, который предсказывает класс клиента:

0 - ушедший клиент, 1 - оставшийся

Алгоритм предсказал, что 94 человек - ушедшие клиенты (класс 0), 6 - оставшиеся (класс 1)

Тогда: TP = 6, TN = 90, FP = 4, FN = 4

precision = TP/(TP + FP) = (6)/(6 + 4) = 0.6 = 60%

$$precision = \frac{TP}{TP + FP}$$

Метрики качества классификации. Пример. Полнота

В русском языке для этого термина используется слово «полнота» или «чувствительность». Эта метрика определяет количество истинно положительных среди всех меток класса, которые были определены как «положительный» и вычисляется по следующей формуле

$$recall = \frac{TP}{TP + FN}$$

Метрики качества классификации. Пример. Полнота

Банк выбрал 100 человек.

90 - отказались от услуг банка

10 - остались клиентами

Нужно обучить алгоритм, который предсказывает класс клиента:

0 - ушедший клиент, 1 - оставшийся

Алгоритм предсказал, что 94 человек - ушедшие клиенты (класс 0), 6 - оставшиеся (класс 1)

Тогда: TP = 6, TN = 90, FP = 4, FN = 4

recall = TP/(TP + FN) = (6)/(6 + 4) = 0.6 = 60%

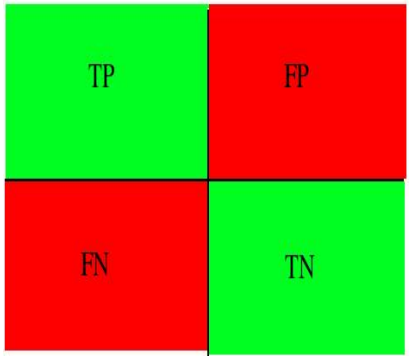
$$recall = \frac{TP}{TP + FN}$$

Метрики качества классификации. Точность. Полнота

Precision можно интерпретировать как долю объектов, названных классификатором положительными и при этом действительно являющимися положительными, а recall показывает, какую долю объектов положительного класса из всех объектов положительного класса нашел алгоритм.

$$precision = \frac{TP}{TP + FP}$$

$$recall = \frac{TP}{TP + FN}$$



Метрики качества классификации. F-мера (F1-Score)

F-мера — агрегированный критерий качества: среднее гармоническое precision и recall. F-мера достигает максимума при полноте и точности, равными единице, и близка к нулю, если один из аргументов близок к нулю.

$$F_1 = 2\frac{recall \cdot precision}{recall + precision} = \frac{TP}{TP + \frac{FP+FN}{2}}$$

$$F_1 = 2\ (0{,}6 * 0{,}6)/(0{,}6+0{,}6) = 0{,}6$$

Метрики качества классификации

Precision и recall не зависят, в отличие от accuracy, от соотношения классов и потому применимы в условиях несбалансированных выборок.

Эти параметры собраны в матрице ошибок, можно получить доступ к ним, например, с помощью `sklearn.metrics`.

Есть удобная функция `metrics.classification_report`, возвращающая recall, precision и F-меру для каждого из классов, а также количество экземпляров каждого класса.

Метрики качества классификации

Необходимо отметить, что в случае задач с несбалансированными классами, которые превалируют в реальной практике, часто приходится прибегать к техникам искусственной модификации датасета для выравнивания соотношения классов. https://imbalanced-learn.org/stable/index.html - здесь можно посмотреть некоторые методы и выбрать подходящий для вашей задачи

ROC-кривые

ROC-кривые

ROC-анализ изначально создавался для обработки радиолокационных сигналов (ROC расшифровывается как Receiver Operating Characteristic или рабочая характеристика приёмника), но затем нашел применение и в других областях.

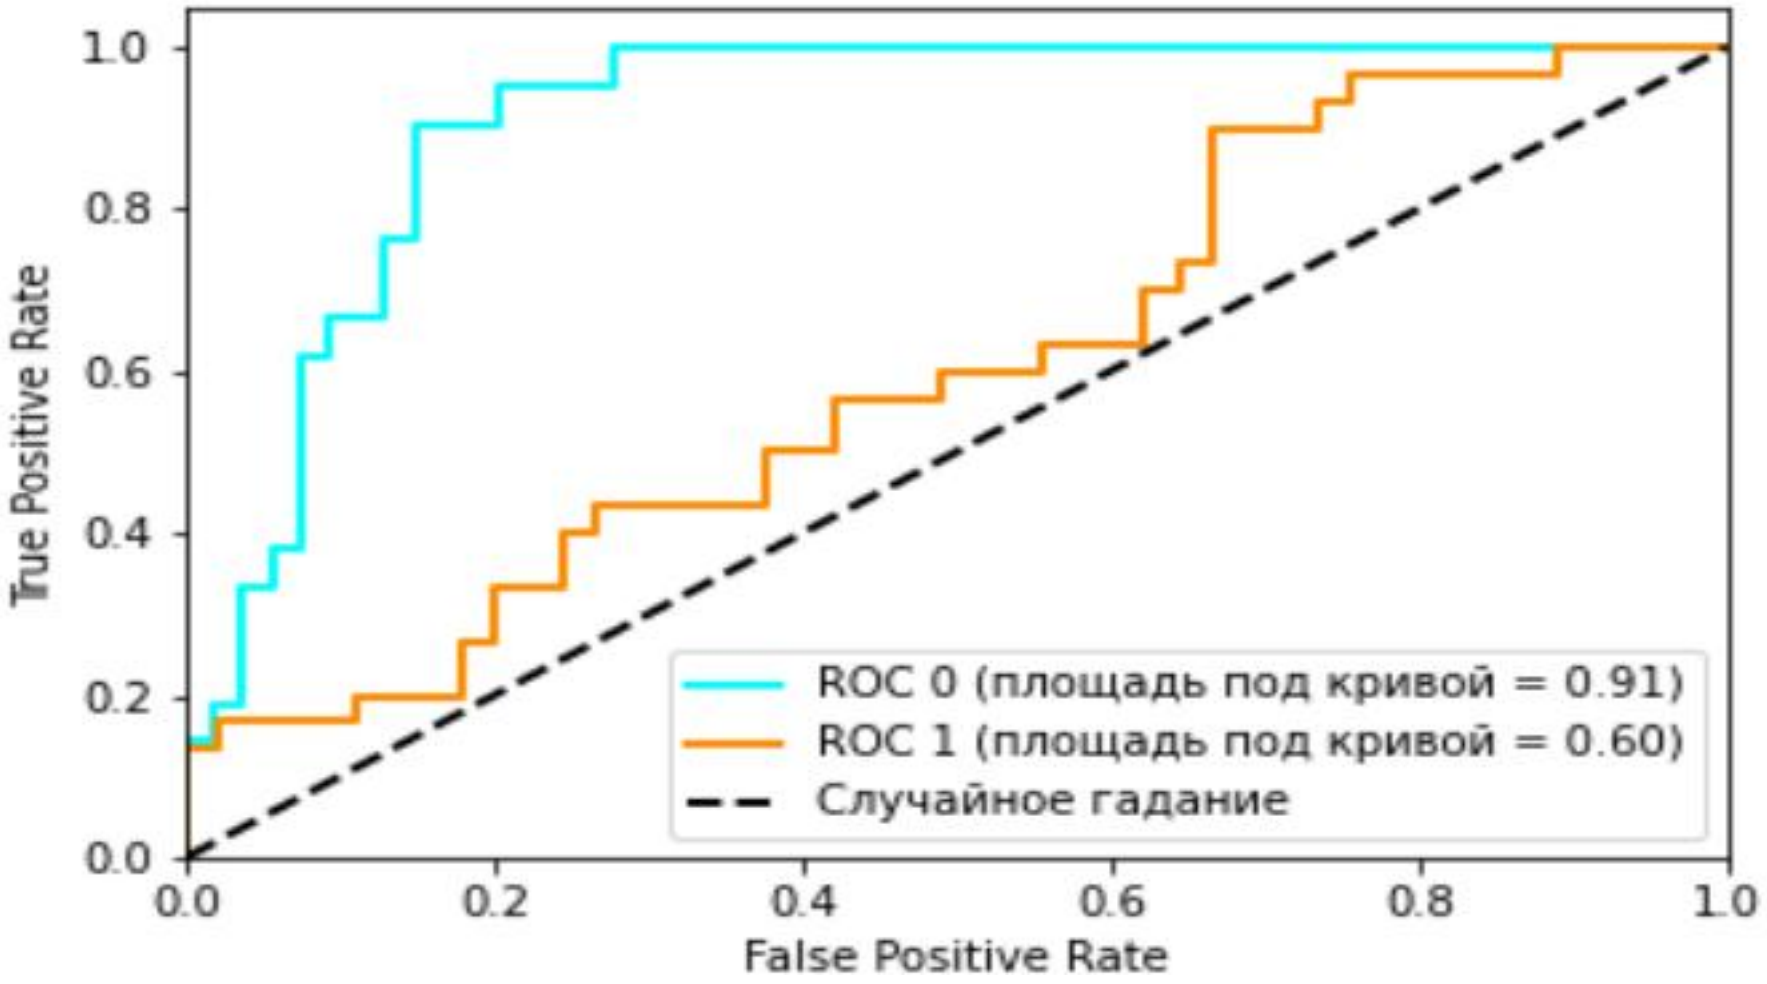
ROC-кривые

Одним из способов оценить модель в целом, не привязываясь к конкретному порогу, является AUC-ROC (или ROC AUC) — площадь (Area Under Curve) под кривой ошибок (Receiver Operating Characteristic curve). Данная кривая представляет из себя линию от (0,0) до (1,1) в координатах True Positive Rate (TPR) - по сути это полнота и False Positive Rate (FPR).

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{FP + TN}$$

ROC-кривые



$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{FP + TN}$$

ROC-кривые

Критерий AUC-ROC устойчив к несбалансированным классам (хоть бывают и особые случаи) и может быть интерпретирован как вероятность того, что случайно выбранный объект положительного класса будет проранжирован классификатором выше (будет иметь более высокую вероятность быть отнесенным к положительному классу), чем случайно выбранный объект негативного класса.

Кроссвалидация

Кроссвалидация (перекрестная проверка) — это метод оценки качества модели машинного обучения, при котором доступные данные многократно разбиваются на обучающую и тестовую выборки, чтобы получить более надежную и устойчивую метрику качества. Этот подход позволяет убедиться, что модель способна обобщать закономерности, а не просто запоминать конкретные примеры из обучающего набора.

Кроссвалидация

