МЕТОД ОПОРНЫХ ВЕКТОРОВ

Метод опорных векторов

- Метод опорных векторов, МОВ (Support Vector Machine, SVM)
- Первоначально предложен как метод классификации, опирающийся на теорию статистического обучения (1992, В. Вапник, А.Червоненкис)
- МОВ получил известность, продемонстрировав сравнимую с нейросетями точность решения задачи распознавания рукописных цифр
- В настоящее время МОВ – один из широко используемых методов машинного обучения при решении задач классификации и регрессии



Вапник Владимир Наумович



Червоненкис Алексей Яковлевич

План

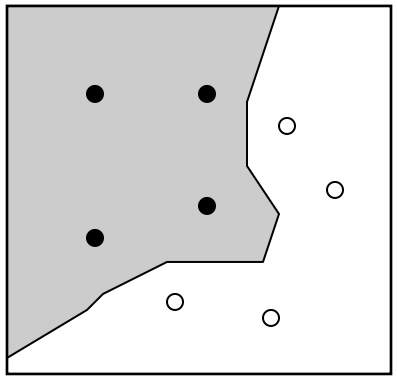
- Метод опорных векторов (МОВ)
  - Линейная классификация
  - Классификатор, максимизирующий отступ
  - Нелинейная классификация, ядровые преобразования
  - Примеры

Метод опорных векторов

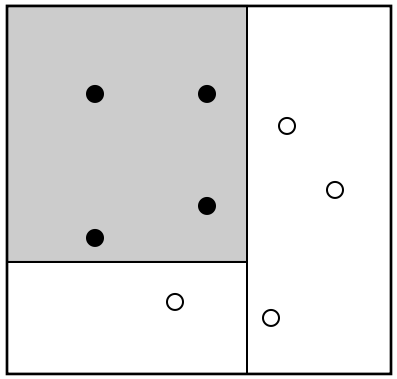
ЛИНЕЙНАЯ КЛАССИФИКАЦИЯ

Разделяющая функция

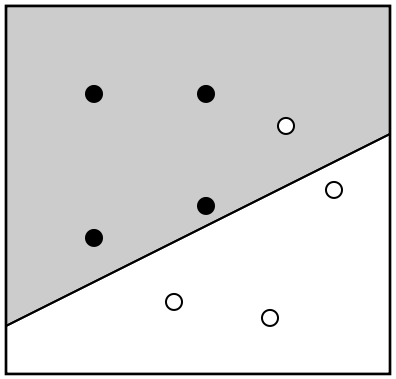
- Разделяющая функция может быть произвольной функцией от $\mathbf{x}$



По ближайшему соседу

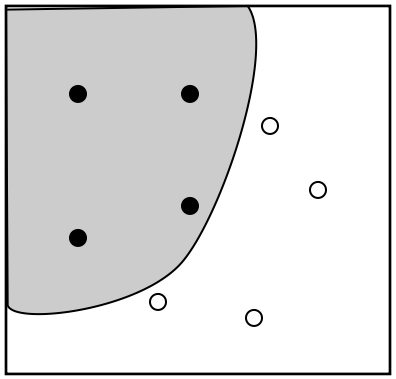


Деревья решений



Линейные функции

$$g(\mathbf{x}) = \mathbf{w}^T\mathbf{x} + b$$



Нелинейные функции

Линейная разделяющая функция

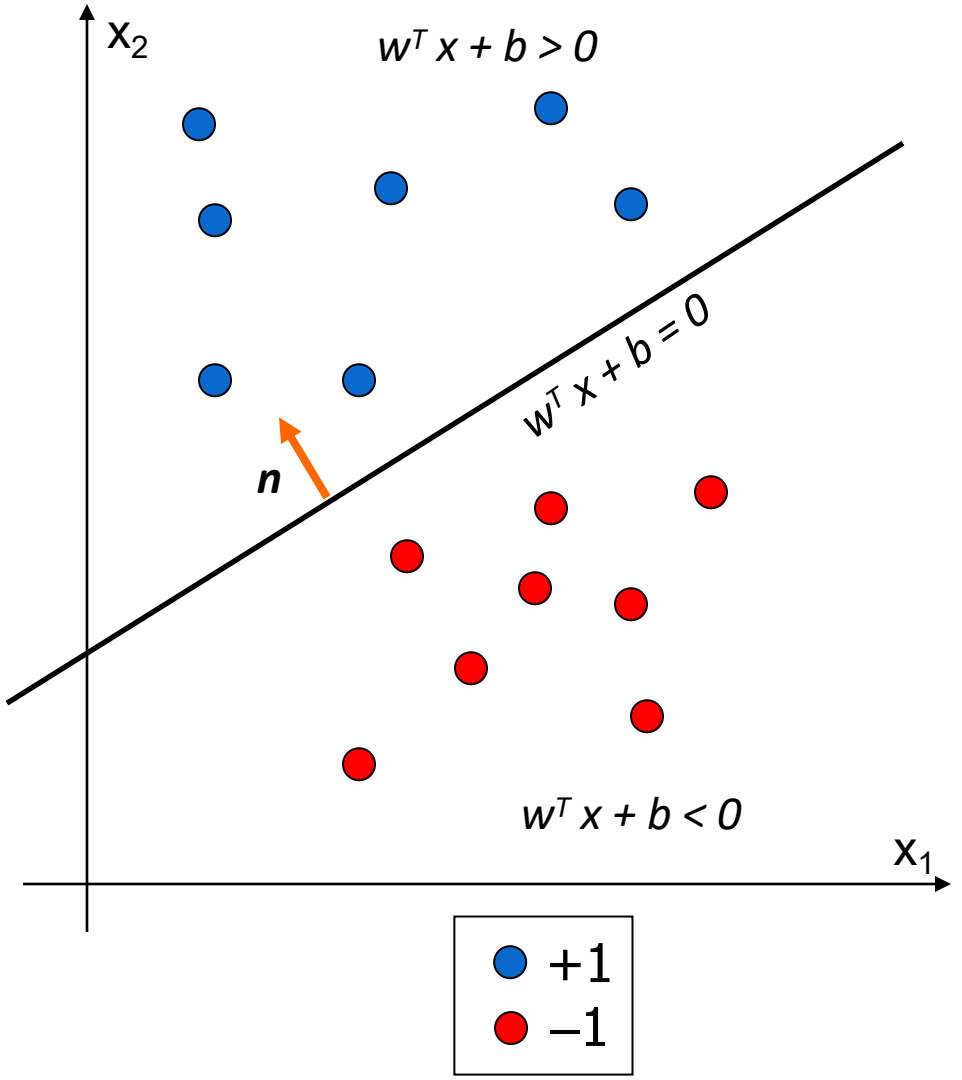
- $g(x)$ – линейная функция:

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

- Определяет гиперплоскость в признаковом пространстве

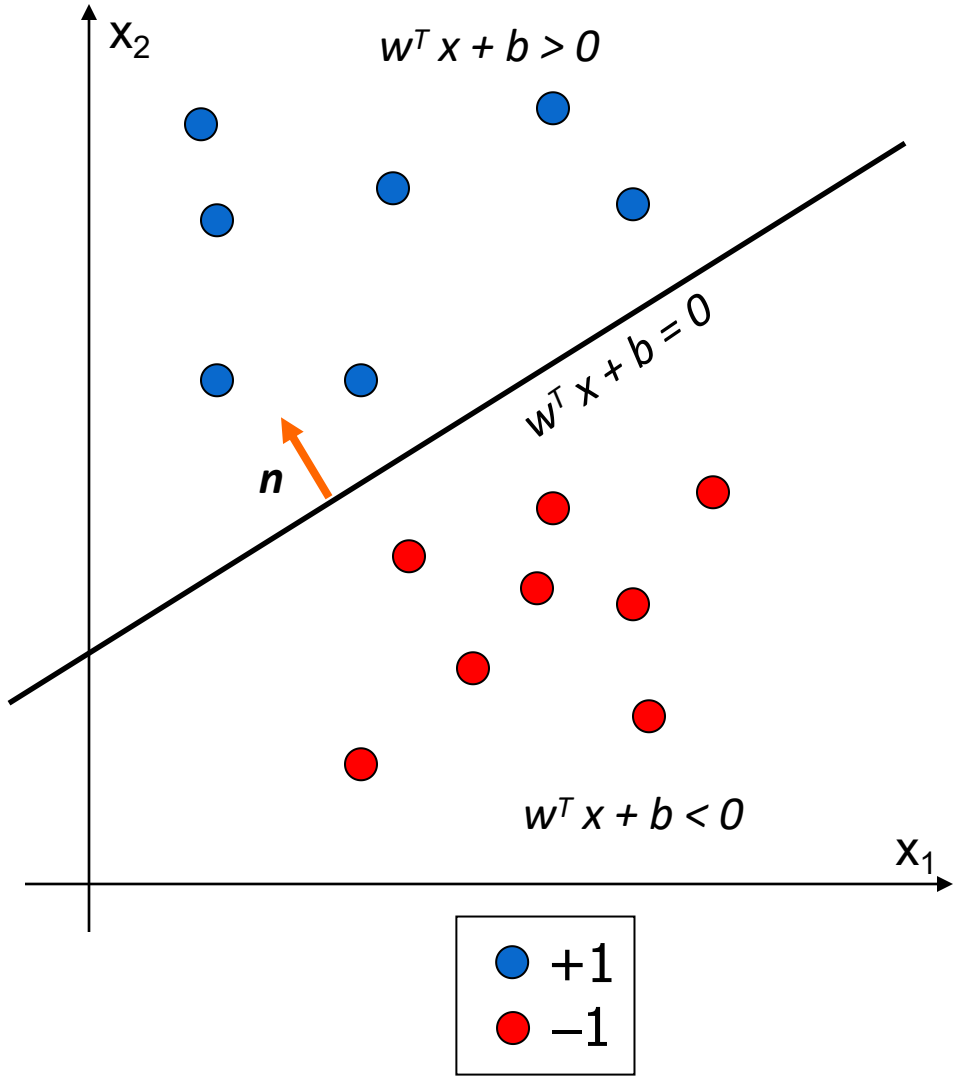
- Единичный вектор нормали гиперплоскости:

$$\mathbf{n} = \frac{\mathbf{w}}{\|\mathbf{w}\|}$$



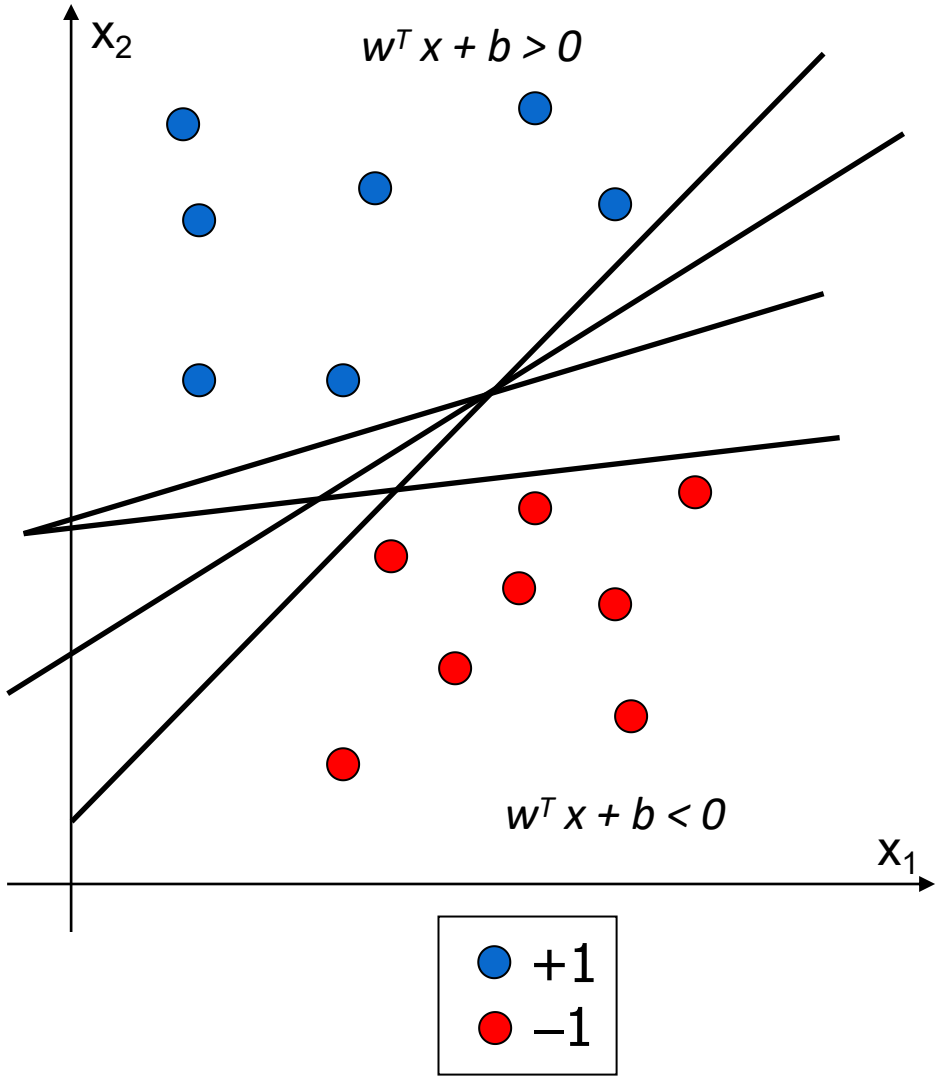
Линейная разделяющая функция

- Как построить линейную функцию, решающую задачу классификации?
- Ответов бесконечно много!



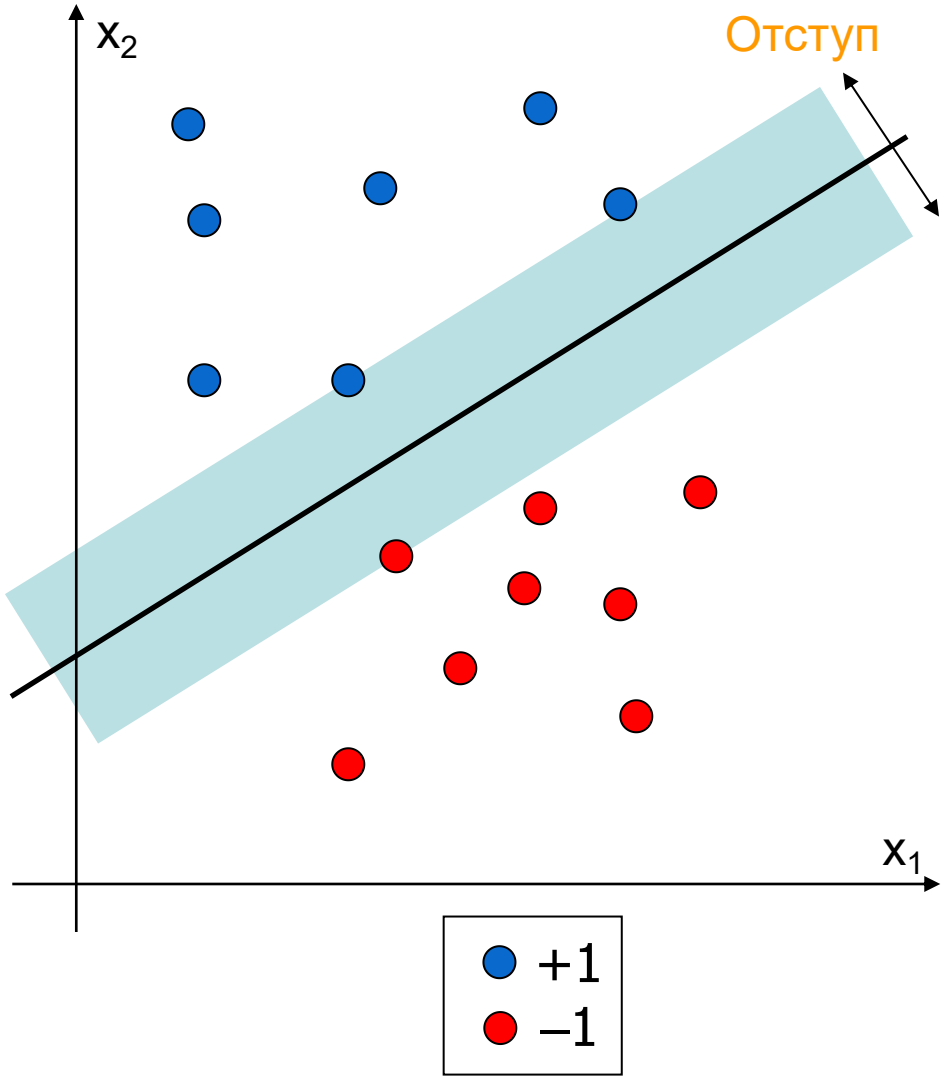
Линейная разделяющая функция

- Как построить линейную функцию, решающую задачу классификации?
- Ответов бесконечно много!
- Какой вариант является наилучшим?



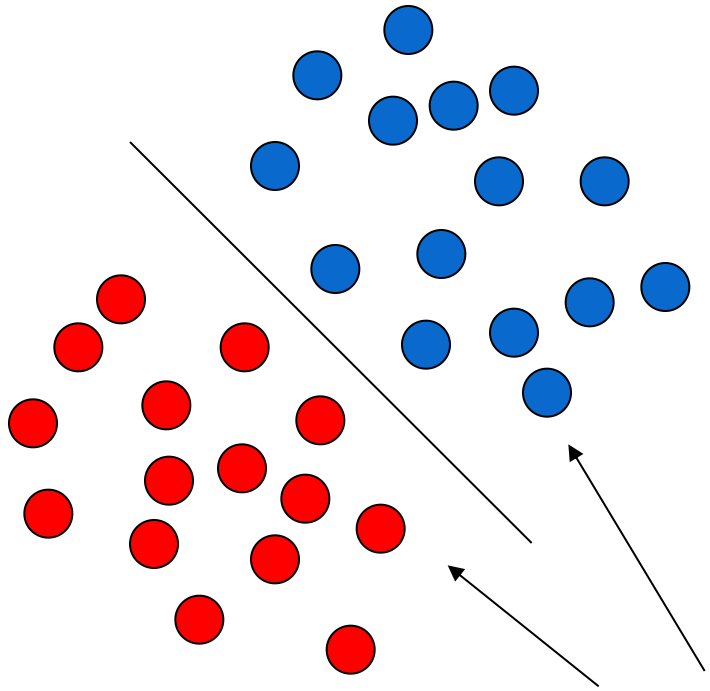
Линейный классификатор с наибольшим отступом

- Почему бы не брать ту, которая равно и максимально удалена от обоих классов?
- Почему она наилучшая?
  - Наиболее устойчива к выбросам и обладает наибольшей обобщающей способностью



Линейный классификатор с наибольшим отступом

- Изменится ли разделяющая функция?



Прецеденты, которые нельзя убрать
без изменения разделяющей функции

Линейный классификатор с наибольшим отступом

- Задан набор данных:

$\{(\mathbf{x}_i, y_i)\}, \; i = 1, 2, \mathrm{L} \;\; , n$, где

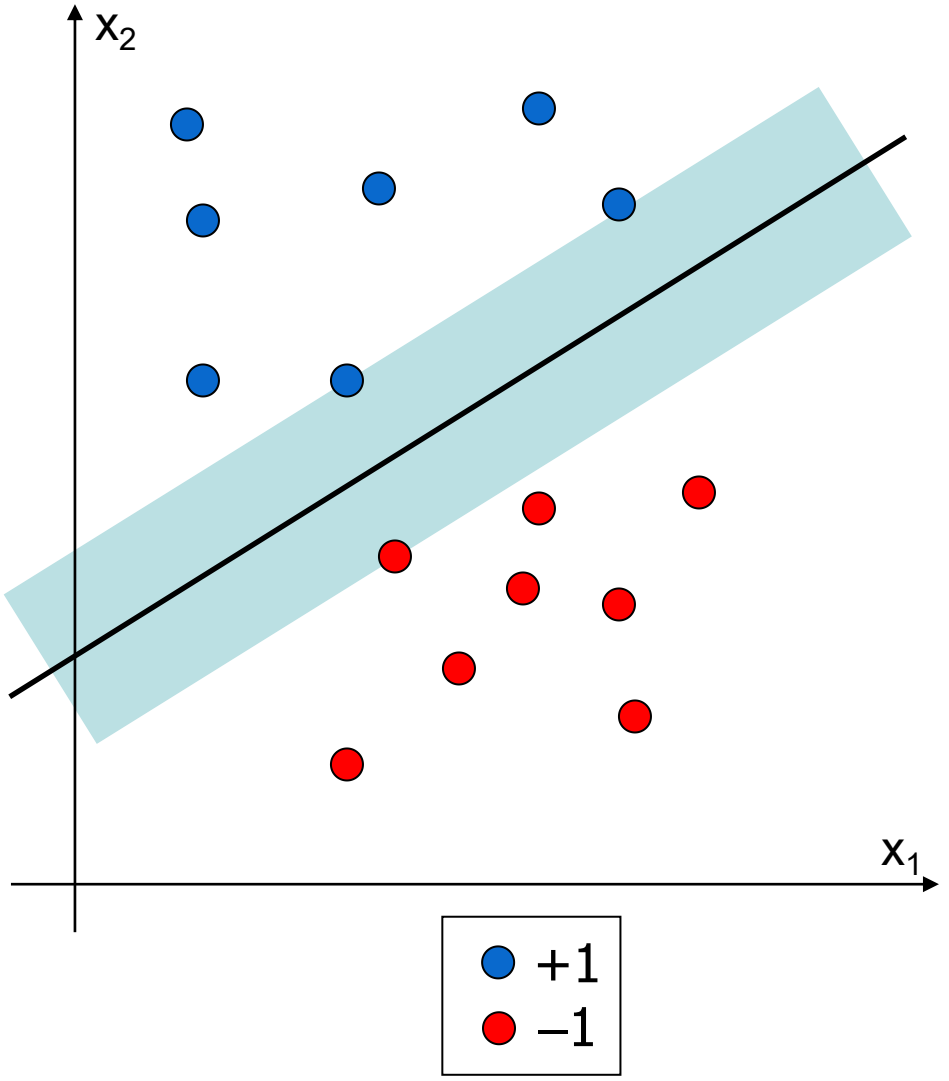
для $y_i = +1, \;\; \mathbf{w}^T \mathbf{x}_i + b > 0$

для $y_i = -1, \;\; \mathbf{w}^T \mathbf{x}_i + b < 0$

- Несложные преобразования ***w*** и ***b*** позволяют перейти к виду

для $y_i = +1, \;\; \mathbf{w}^T \mathbf{x}_i + b \geq 1$

для $y_i = -1, \;\; \mathbf{w}^T \mathbf{x}_i + b \leq -1$



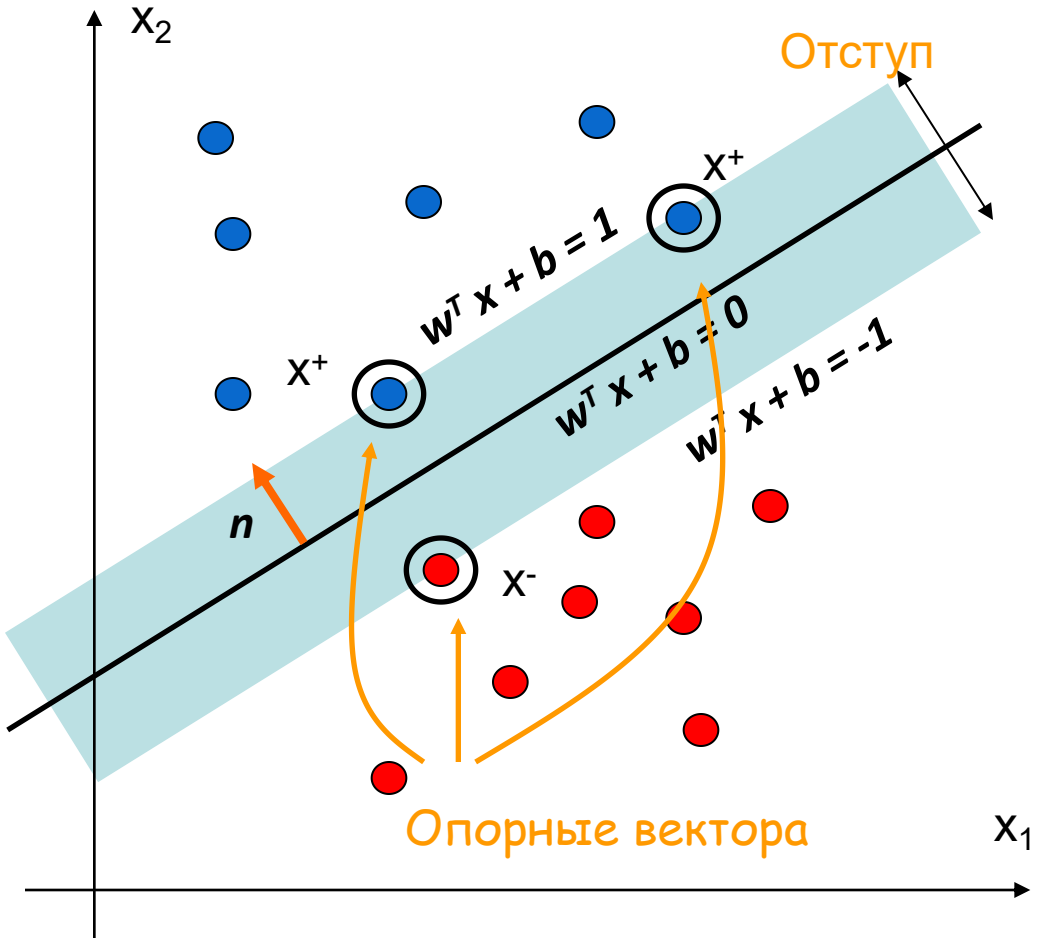
Линейный классификатор с наибольшим отступом

- Известно, что

$$\mathbf{w}^T \mathbf{x}^+ + b = 1$$
$$\mathbf{w}^T \mathbf{x}^- + b = -1$$

- Величина отступа:

$$M = (\mathbf{x}^+ - \mathbf{x}^-)\ \mathbf{n}$$
$$= (\mathbf{x}^+ - \mathbf{x}^-)\ \frac{\mathbf{w}}{\|\mathbf{w}\|} = \frac{2}{\|\mathbf{w}\|}$$



Линейный классификатор с наибольшим отступом

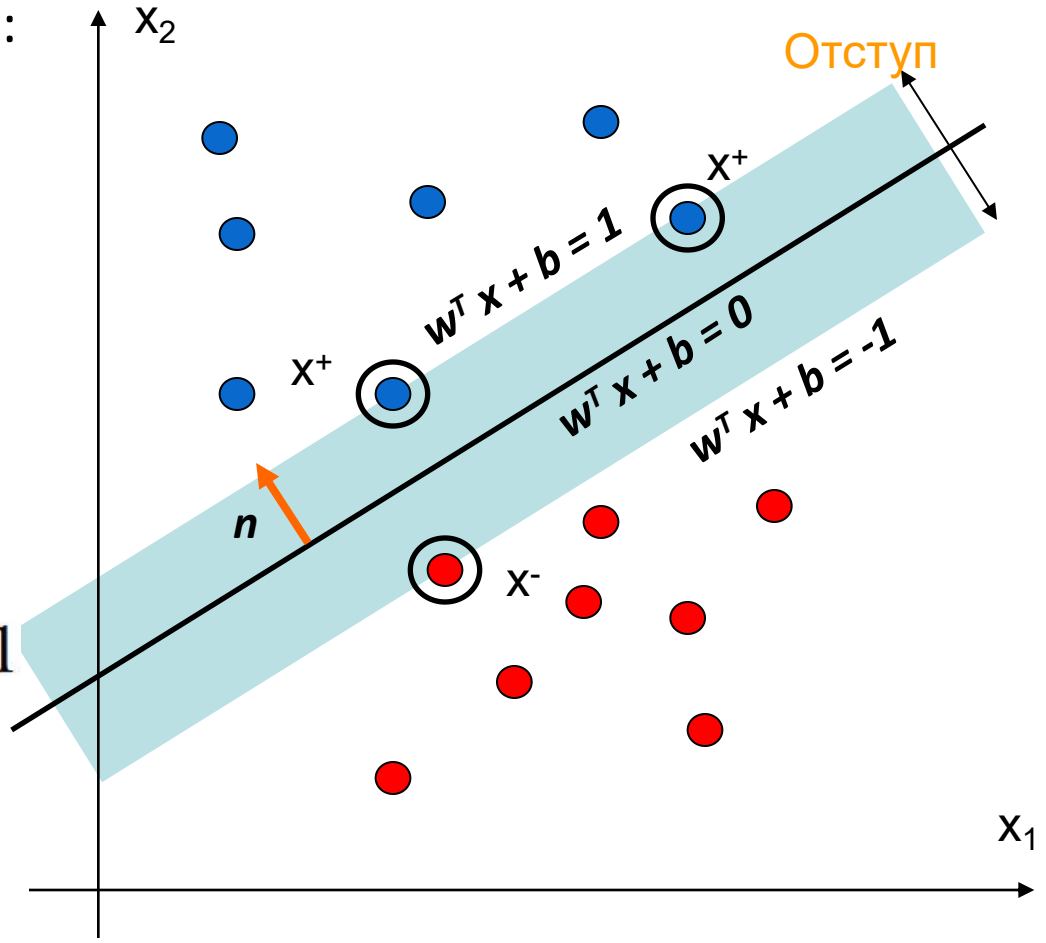
- Формальная постановка задачи:

$$\frac{2}{\|\mathbf{w}\|} \to \max_{\mathbf{w},\ b}$$

при ограничениях

для $y_i = +1, \quad \mathbf{w}^T \mathbf{x}_i + b \geq 1$

для $y_i = -1, \quad \mathbf{w}^T \mathbf{x}_i + b \leq -1$



Линейный классификатор с наибольшим отступом

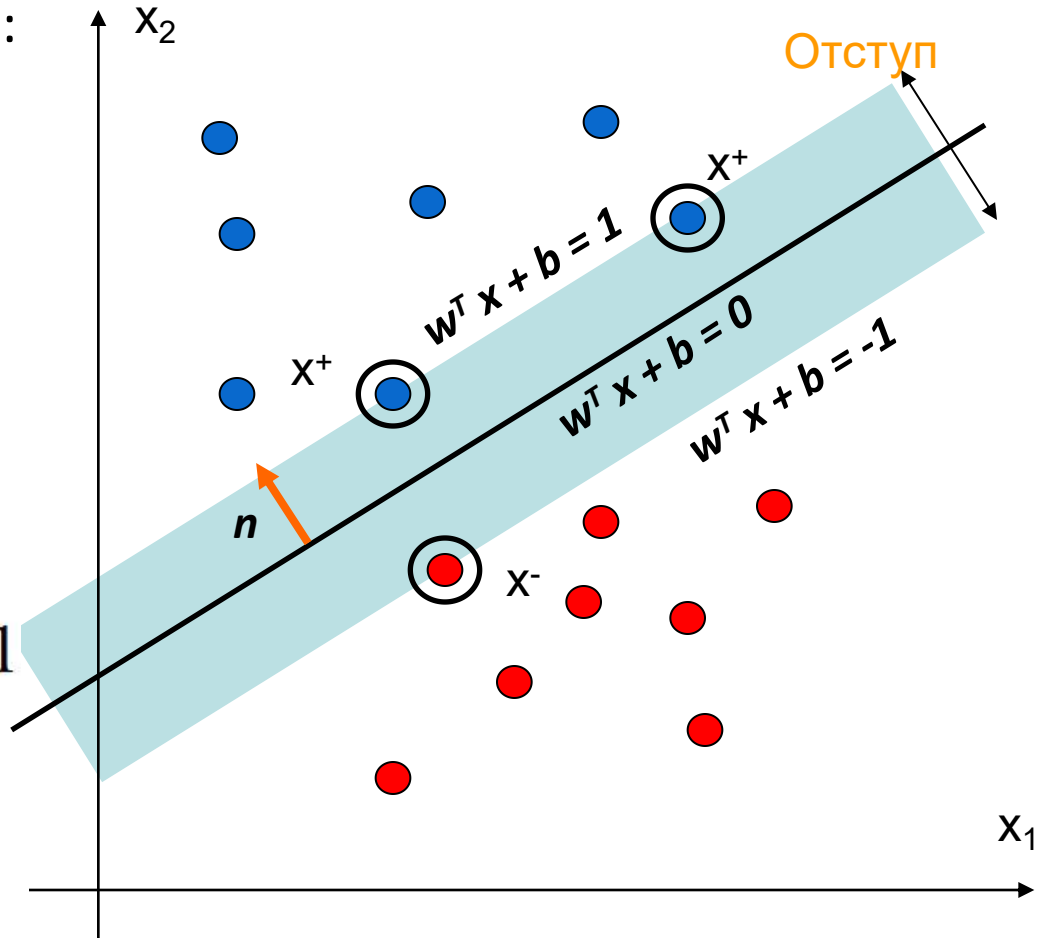
- Формальная постановка задачи:

$$\frac{1}{2}\|\mathbf{w}\|^2 \to \min_{\mathbf{w},\ b}$$

при ограничениях

для $y_i = +1, \quad \mathbf{w}^T\mathbf{x}_i + b \geq 1$

для $y_i = -1, \quad \mathbf{w}^T\mathbf{x}_i + b \leq -1$



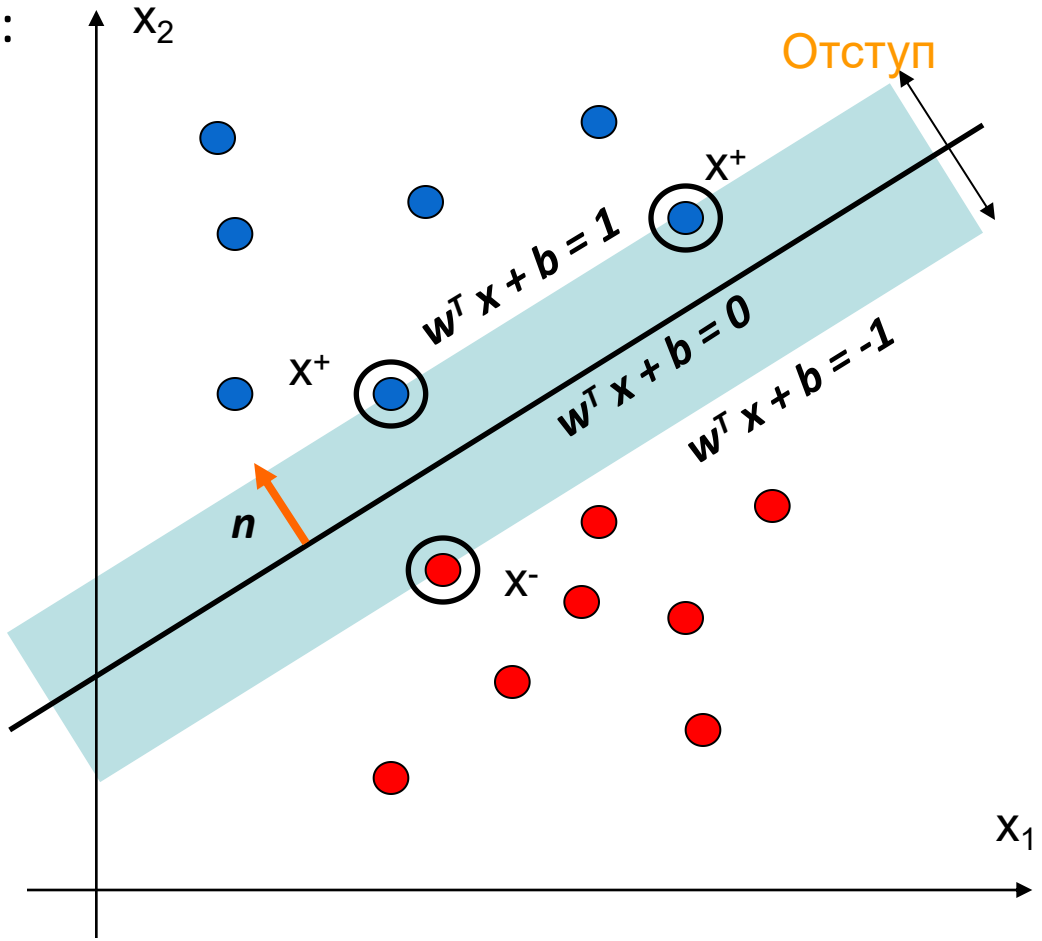
Линейный классификатор с наибольшим отступом

- Формальная постановка задачи:

$$\frac{1}{2}\|\mathbf{w}\|^2 \to \min_{\mathbf{w},\ b}$$

при ограничениях

$$y_i(\mathbf{w}^T\mathbf{x}_i + b) \geq 1$$



Решение оптимизационной задачи

- Линейная разделяющая функция

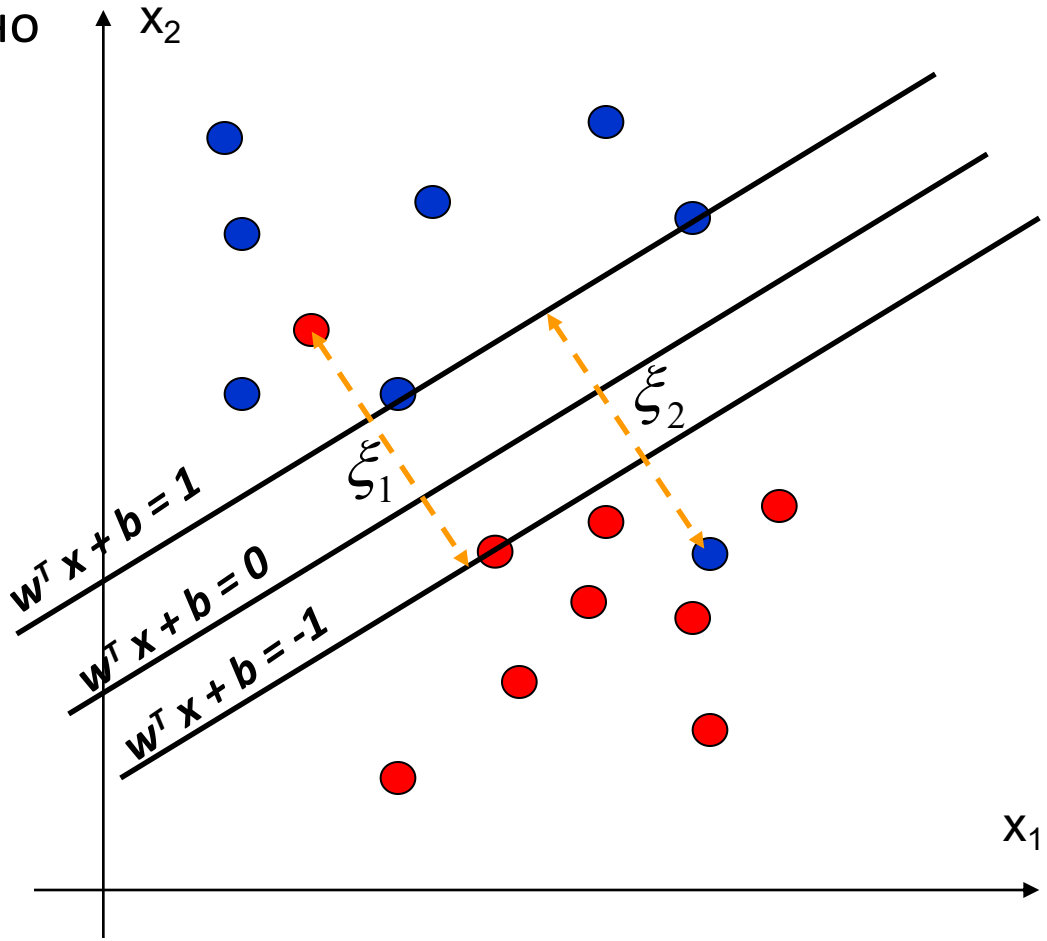
$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = \sum_{i \in \mathrm{SV}} \alpha_i \mathbf{x}_i^T \mathbf{x} + b$$

- Важно: выражается через *скалярное произведение* тестового вектора ***x*** и опорных векторов $\boldsymbol{x}_i$

- Важно: при решении оптимизационной задачи необходимо вычисление *скалярных произведений* $\boldsymbol{x}_i^T \boldsymbol{x}_j$ всех пар векторов из обучающей выборки

Линейный классификатор, максимизирующий отступ

- Как быть, если данные линейно не разделимы (из-за шума, выбросов и т.п.)?
- Могут быть использованы фиктивные переменные ξ_i, позволяющие описывать «нарушителей» линейной разделимости



Линейный классификатор, максимизирующий отступ

- Задача

$$\text{minimize} \quad \frac{1}{2}\|\mathbf{w}\|^2 + C \sum_{i=1}^{n} \xi_i$$

при ограничениях

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \quad 1 - \xi_i$$

$$\xi_i \quad 0$$

- Параметр C может использоваться для контроля гибкости модели (для борьбы с переобучением)

Линейный классификатор, максимизирующий отступ

- Двойственная задача Лагранжа

$$\text{maximize} \sum_{i=1}^{n} \alpha_i - \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

при ограничениях

$$0 \quad \alpha_i \quad C$$

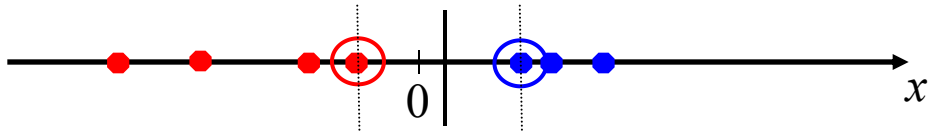
$$\sum_{i=1}^{n} \alpha_i y_i = 0$$

Метод опорных векторов

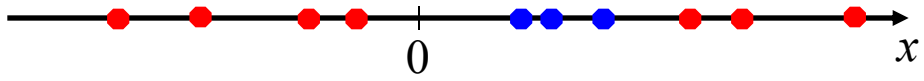
НЕЛИНЕЙНАЯ КЛАСИФИКАЦИЯ

Нелинейный МОВ

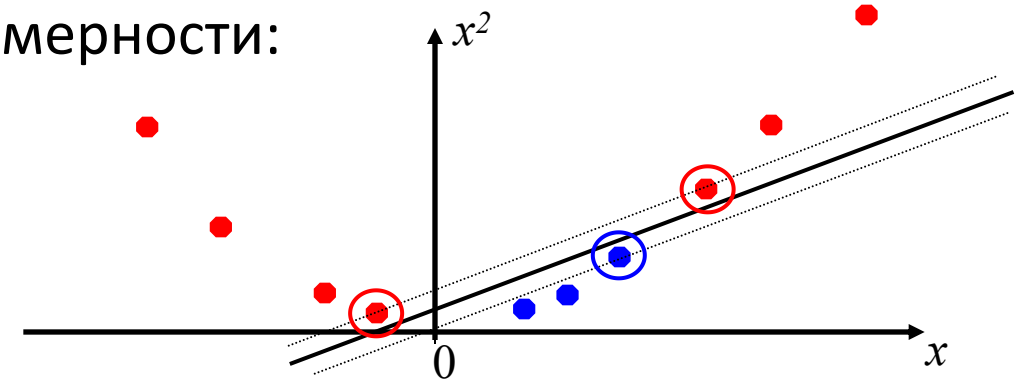
- Линейно разделимые данные с шумом обрабатываются отлично:



- Что делать с более сложными данными?

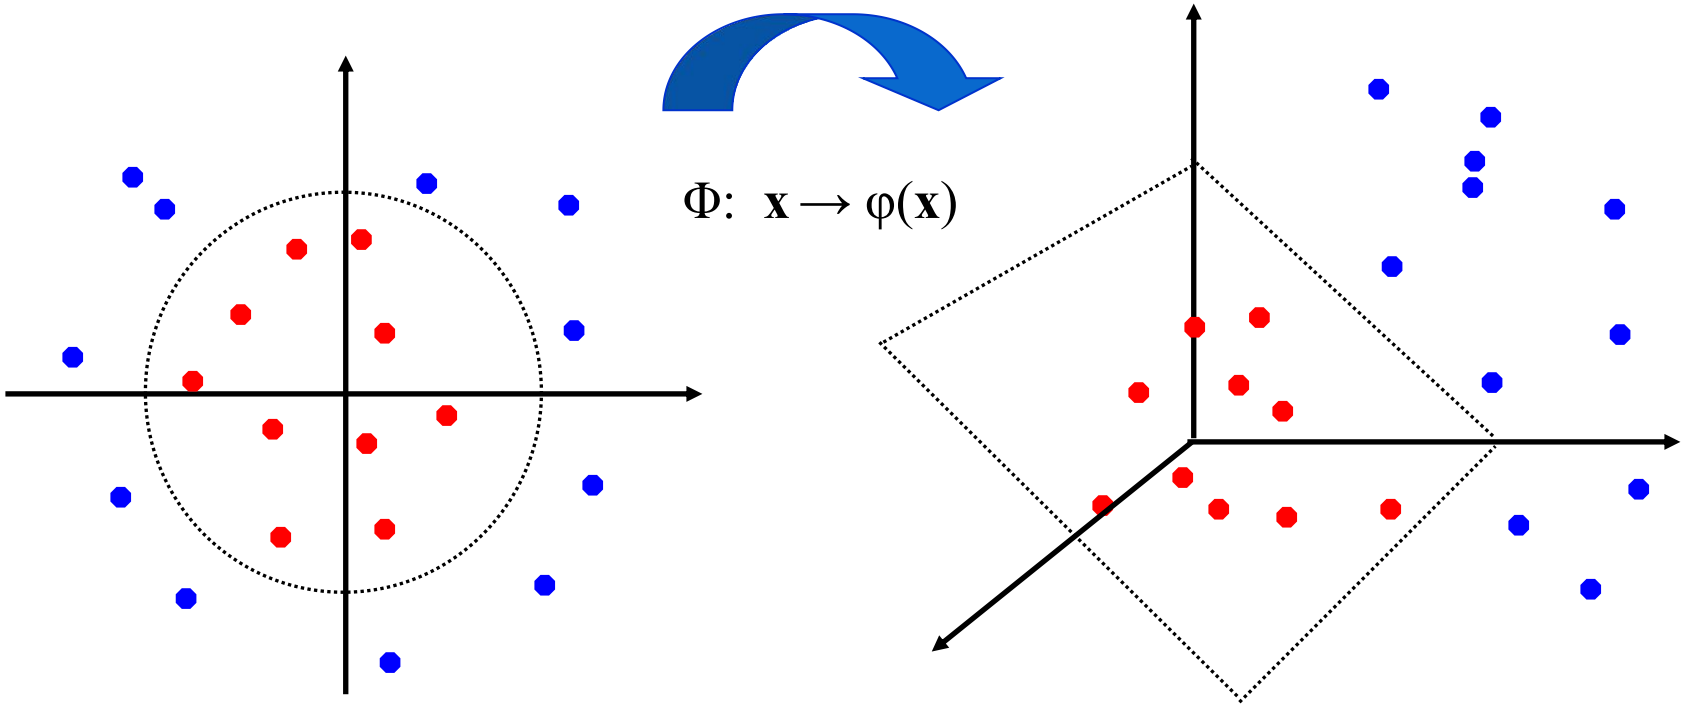


- Один из выходов – отобразить данные в пространство более высокой размерности:



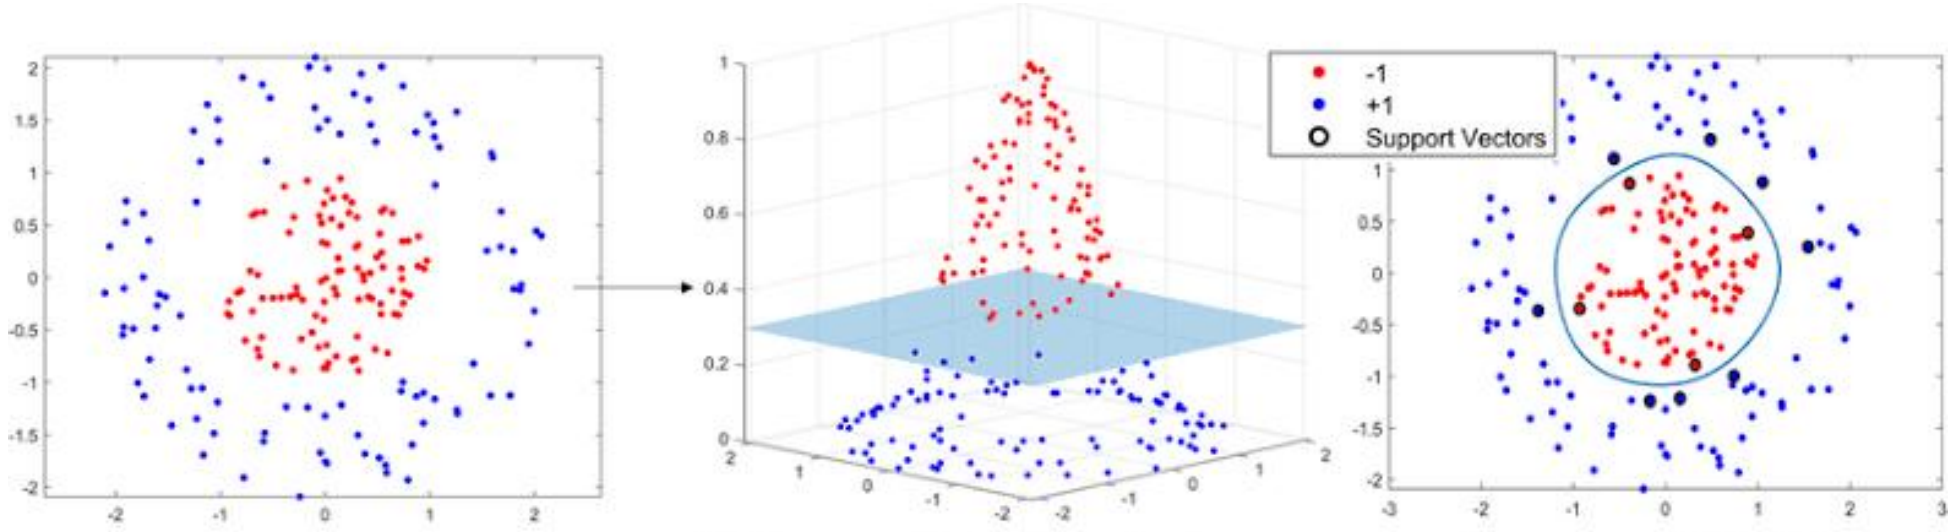
Нелинейный МОВ: признаковое пространство

- Общая идея: исходное пространство признаков может быть отображено в некоторое пространство более высокой размерности, где данные будут разделимы



Нелинейный МОВ: признаковое пространство

- Общая идея: исходное пространство признаков может быть отображено в некоторое пространство более высокой размерности, где данные будут разделимы



(a) 2D non-linear training data

(b) 3D mapped data points using the Gaussian kernel and separating hyperplane

(c) non-linear SVM with the Gaussian kernel training result

Нелинейный МОВ: использование ядер

- При использовании отображения разделяющая функция примет вид:

$$g(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + b = \sum_{i \in SV} \alpha_i \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) + b$$

- Не обязательно знать отображение явно, т.к. используется только *скалярное произведение* признаковых векторов из обучающего и тестового набора.

- *Функция ядра* (kernel function) определяется как функция, являющаяся скалярным произведением двух признаковых векторов в некотором расширенном пространстве признаков:

$$K(\mathbf{x}_i, \mathbf{x}_j) \quad \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$$

Нелинейный МОВ: использование ядер

- Примеры часто используемых «ядровых» функций:
  - Линейное ядро: $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$
  - Полиномиальное ядро: $K(\mathbf{x}_i, \mathbf{x}_j) = (1 + \mathbf{x}_i^T \mathbf{x}_j)^p$
  - Гауссиана (Radial-Basis Function (RBF)):

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\left\|\mathbf{x}_i - \mathbf{x}_j\right\|^2}{2\sigma^2}\right)$$

  - Сигмоида:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta_0 \mathbf{x}_i^T \mathbf{x}_j + \beta_1)$$

- Вообще говоря, в качестве ядра может использоваться функция, удовлетворяющая условию Мерсера.

Нелинейный МОВ: задача оптимизации

- Двойственная задача Лагранжа:

$$\text{maximize} \quad \sum_{i=1}^{n} \alpha_i - \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j)$$

при ограничениях

$$0 \quad \alpha_i \quad C$$

$$\sum_{i=1}^{n} \alpha_i y_i = 0$$

- Разделяющая функция принимает вид

$$g(\mathbf{x}) = \sum_{i \ \text{SV}} \alpha_i K(\mathbf{x}_i, \mathbf{x}) + b$$

- Методы оптимизации – те же самые.

Метод опорных векторов

ОБЩИЙ АЛГОРИТМ

Метод опорных векторов: алгоритм

1. Выбрать функцию ядра

2. Выбрать значение параметра *C*

3. Решить задачу квадратичного программирования

4. Построить разделяющую функцию по опорным векторам

Метод опорных векторов: нюансы

- Выбор ядра
  - По умолчанию следует использовать гауссиану или полиномиальное ядро
  - В случае их неэффективности, приходится отыскивать более сложное
  - Эксперты в предметной области могут помочь в выборе подходящих мер подобия
- Выбор параметров ядра
  - Например, σ для гауссианы: σ есть расстояние между ближайшими точками различных классов
  - При отсутствии надежных критериев для выбора значений параметров на практике полагаются на проверку на тестовой выборке или перекрестную проверку
- Критерий оптимизации – жесткий (hard) или мягкий (soft) отступ (margin)
  - Значения параметров проверяются и выбираются по результатам длинной серии экспериментов

Метод опорных векторов: итоги

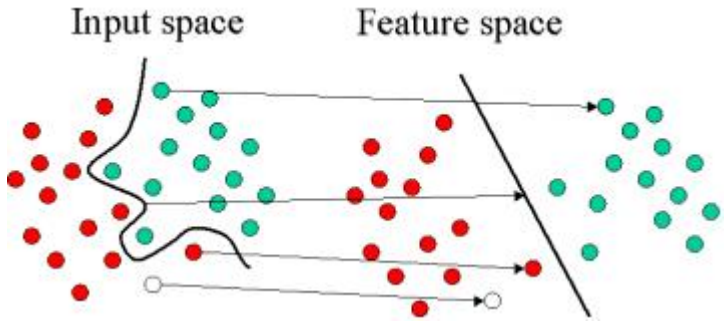
1. Линейный классификатор, максимизирующий отступ

   Хорошая обобщающая способность и более слабая угроза переобучения

2. Использование функций ядра

   Отображение данных в пространство более высокой размерности, чтобы добиться линейной разделимости.

   Поскольку все алгоритмы зависят лишь от скалярных произведений, нет необходимости в явном знании отображения.



Метод опорных векторов: итоги

- Плюсы
  - Однозначность решения (глобальный минимум)
  - Теоретически доказана минимальность оценки общего риска (Вапник)
  - При помощи ядровых преобразований обобщается на случай сложных поверхностей
- Минусы
  - Требует подбора множества параметров (ядро, параметры ядра, штраф за ошибки)
  - Теоретические оценки верны только для случая разделимости (схема со штрафами - эвристика)
  - Очень чувствителен к нормализации данных!

Метод опорных векторов: итоги

- Метод являлся наилучшим методом классификации до, примерно, 2000 года наголову обгоняя нейронные сети и т.п.
- Фактически, метод опорных векторов – практический выход теории Вапника-Червоненкиса
- Однако, необходимость подбора большого числа неинтуитивных параметров сильно снижала его применение в простых разработках (требовала наличия эксперта)